



IMT-2030 (6G)推进组
IMT-2030 (6G)Promotion Group

无线AI技术研究报告



2022

2022 年 9 月

版权声明 Copyright Notification

未经书面许可 禁止打印、复制及通过任何媒体传播

© 2022 IMT-2030（6G）推进组版权所有

前 言

无线人工智能是指内生于无线通信系统，通过机器学习等手段深度挖掘利用无线数据和无线模型，由此形成的涵盖新型智能无线架构、无线空口、无线算法和无线应用在内的人工智能技术体系。它主要包括：一是内生智能的新型空口，即深度融合人工智能/机器学习技术，将打破现有无线空口模块化的设计框架，实现无线环境、资源、干扰、业务、语义和用户等多维特性的深度挖掘和利用，显著提升无线网络的高效性、可靠性、实时性和安全性，并实现网络的自主运行和自我演进。二是内生智能的新型网络架构，即充分利用网络节点的通信、计算和感知能力，通过分布式学习、群智式协同以及云边端一体化算法部署，实现更为强大的网络智能，支撑未来各种智慧应用。

无线 AI 自 2016 年前后开始蓬勃发展，当前已掀起全球学术界和工业界的研究热潮。IEEE 通信学会启动“Machine Learning For Communications Emerging Technologies Initiative”，欧盟 Horizon 2020 启动“智能网络与服务”6G 研究项目，重点发展 AI 增强的通信与网络技术。欧美一批著名高校和企业研究机构均开展了大量的研究工作，部分机构还推出了无线 AI 原型系统。国内主要高校和部分行业领先企业围绕无线智能网络架构、无线智能空口、无线 AI 算法、无线 AI 数据集、无线语义通信等基础理论和关键技术展开了深入研究和探索，并取得了丰富的成果，部分成果还完成了测试，有效验证了无线人工智能的技术可行性和应用潜力，并初步形成了如下基本结论和重要共识：

1) AI/ML 能很好地表征和重构未知无线信道环境、有效跟踪预测反馈信道状态、挖掘利用大状态空间内在统计特征，大幅度提升物理层信号处理算法的性能。

2) AI/ML 能够智能挖掘利用无线网络时空频通信、感知和计算资源，有效协调干扰，实现多用户、多目标、高维度、分布式、准全局优化调度决策。

3) 若干 AI/ML 架构能够很好地与无线网络拓扑、无线传输接入协议、无线资源约束、无线分布式数据特征相适配，从而有潜力建构新型无线智能网络架构；在此基础上进一步利用网络分布式算力和动态运力，自主适应无线网络分布式计算业务需求，实现网络高效资源利用、自主运行和智能服务。

4) 无线语义通信作为一种全新的智能通信架构，通过将用户对信息的需求和语义特征融入通信过程，有望显著提升通信效率、改进用户体验，解决基于比特的传统通信协议中存在的跨系统、跨协议、跨网络、跨人机不兼容和难互通等问题。

5) 无线数据隐藏结构特征复杂, 跨时空分布式小样本问题突出, 无线数据集的构建、访问、训练、迁移及其隐私安全保障将显著影响无线 AI 系统的架构设计和算法部署。

无线 AI 将是未来 6G 中渗透性最强的核心技术之一, 涉及空口、网络、协议和算法的各个层面, 也将深度影响感知、通信、计算、控制等网络功能, 其性能潜力已得到证实。相关研究成果在感知、预测、定位、跟踪、反馈、调度、优化、调控等方面的应用潜力巨大, 初步形成了未来标准化和产业化的基础, 部分技术已在 R17、R18 中得到初步研究和应用。

下一步宜深入探索无线智能通信系统在数据和算力需求、AI 通信计算综合效能方面的极限理论, 重点推进无线智能网络架构、无线智能空口、无线 AI 算法、无线 AI 数据集、无线语义通信等方面的标准化, 着重解决如下核心难点: 适用于无线的通用 AI 架构、数据和算力约束的高效无线 AI 算法, 支撑 AI 算法高效部署的无线协议, 以及无线 AI 性能(界限)的精准分析预测等等。

目 录

图目录	6
表目录	8
第一章 引言	11
第二章 基于 AI/ML 的物理层技术	12
2.1 基于 AI/ML 的无线环境建模与感知	13
2.2 基于 AI 的信道估计、预测及反馈	15
2.2.1 信道状态信息估计	17
2.2.2 信道状态信息预测	19
2.2.3 信道状态信息反馈	21
2.2.4 导频、信道估计、信道反馈、预编码联合设计	23
2.3 AI 使能的端到端设计	24
2.4 基于 AI/ML 的信道编译码技术	26
2.4.1 基于 AI/ML 的信道编码方案设计	26
2.4.2 基于 DNN 的编译码算法	27
2.4.3 基于 CNN 的译码算法	27
2.4.4 基于 LSTM 网络的译码算法	28
2.4.5 基于对抗生成网络译码算法	30
2.5 基于 AI/ML 的调制与波形技术	31
2.6 基于 AI/ML 的信源信道联合编码技术	32
2.7 基于 AI 的 OFDM 接收机设计	34
2.8 基于 AI 的多天线收发技术	35
2.8.1 基于 AI 的 MIMO 检测	36
2.8.2 单用户毫米波 MIMO 混合预编码	37
2.8.3 多用户毫米波 MIMO 混合预编码	39
2.8.4 移动自适应协同波束成形	40
2.8.5 基于 AI/ML 的波束漂移抑制技术	41
2.8.6 基于 AI/ML 的波束跟踪技术	42
2.9 基于 AI 的多用户接入技术	43
2.10 基于 AI 的活跃用户检测	44
2.11 基于 AI 的定位技术	46
2.12 小结	47
第三章 基于 AI/ML 的链路层技术	48
3.1 基于 AI 的功率分配	48
3.2 基于 AI 的信道分配	49
3.3 基于 AI 的接入控制	50
3.4 基于 AI 的链路调度	51
3.5 基于智能体(smart agent)的无线资源调度	52
3.6 基于 AI 的网络切片无线资源分配	54
3.7 小结	56



第四章 基于 AI 的网络上层技术.....	57
4.1 基于 AI 的无线网络架构.....	57
4.2 基于 AI 的传输层拥塞控制技术.....	58
4.3 基于 AI 的业务速率控制.....	60
4.4 基于 AI 的需求预测与缓存技术.....	61
4.5 基于 AI 的无线分布式计算.....	63
4.6 小结.....	65
第五章 基于 AI 的语义通信.....	66
5.1 基于 AI 的语义通信系统架构.....	66
5.2 基于 AI 的高效语音语义通信系统.....	66
5.3 基于 AI 的图像语义通信系统.....	68
5.4 基于 AI 的语义通信系统资源调度.....	69
5.5 小结.....	70
第六章 无线 AI 研究数据集.....	71
6.1 无线 AI 研究数据收集和利用.....	71
6.2 无线 AI 研究数据集的共建共享.....	72
6.2.1 定位.....	73
6.2.2 智能波束预测.....	74
6.2.3 模型泛化与迁移.....	75
6.3 无线 AI 伦理规范及隐私保护.....	77
6.4 小结.....	78
第七章 研究总结及产业化前景分析与展望.....	79
7.1 AI 赋能无线技术的潜能及优势.....	79
7.2 AI 赋能无线技术的产品成熟度.....	80
7.3 AI 赋能无线技术的标准化和产业化影响.....	81
7.4 AI 赋能无线技术未来研究工作展望.....	82
参考文献	83
贡献单位	97
附录：缩略词表.....	98

图目录

图 2-1	无线通信链路	12
图 2-2	基于 seq-to-seq 模型的信道预测器	13
图 2-3	多维信道嵌入	14
图 2-4	系统框架图	17
图 2-5	DL 和传统算法的比较	17
图 2-6	复合神经网络仿真结果	18
图 2-7	小样本 AI 信道估计仿真结果	19
图 2-8	基于深度学习的信道选择联合信道外推网络	20
图 2-9	左：均匀选择图案 中：网络学习到的图案 右：信道外推误差比较	20
图 2-10	用于静态信道预测的 C-GRBF 网络结构	21
图 2-11	基于 AI 的全信道信息反馈架构	21
图 2-12	基于 AI 的隐式反馈架构	22
图 2-13	32 天线 UMa 加噪信道数据仿真图	22
图 2-14	导频设计、信道估计、信道信息反馈、预编码的联合设计	23
图 2-15	基于 AI 的端到端收发机设计（针对 AWGN 信道）	24
图 2-16	基于 AI 的端到端收发机误消息率性能比较（AWGN 信道）	25
图 2-17	卡尔曼滤波和 AI 结合的端到端收发机	25
图 2-18	基于 AI 方法设计的 Polar 码性能优于 DE/GA 方法	27
图 2-19	BP-CNN 译码算法	28
图 2-20	BP-CNN 译码性能对比	28
图 2-21	LSTM-aided SCF 算法示意图	29
图 2-22	LSTM-aided SCF 性能对比	29
图 2-23	LSTM-Aided CA-SCLF 算法性能比较	29
图 2-24	基于对抗生成网络的低密度奇偶校验码译码模型	30
图 2-25	对抗生成网络的 LDPC 码译码结果	31
图 2-26	基于 autoencoder 的调制解调联合设计	31
图 2-27	基于 AE 的低 PAPR 波形设计	32
图 2-28	基于 AI 的智能波形识别网络	32
图 2-29	基于 AI 的信源信道联合编解码方案的神经网络结构图	33
图 2-30	基于 AI 的信源信道联合编码方案的性能	34
图 2-31	基于模型驱动的 OFDM 接收机	35
图 2-32	基于数据驱动的 OFDM 接收机	35
图 2-33	时变信道条件下各检测算法的误码率性能比较	36
图 2-34	MMNet 算法性能	37
图 2-35	基于波束训练与跟踪的毫米波单用户混合预编码原理图	38
图 2-36	不同算法的有效可达速率性能比较	38
图 2-37	基于智能交互式学习范式的毫米波多用户预编码算法	39
图 2-38	毫米波协同波束成形系统框图	40
图 2-39	（左）在线学习阶段模型	41

图 2-40	(右) 深度学习预测阶段模型	41
图 2-41	波束漂移效应抑制的方法原理图	42
图 2-42	有效可达速率-数据传输波束宽度固定与自适应优化	42
图 2-43	基于 AI 方法的多用户接收机	44
图 2-44	DNN-MP-BSBL 结构 ($N = 3; K = 6; L_t = 2; d_c = 2$)	45
图 2-45	D-AUD 与传统检测算法性能比较	45
图 2-46	不同场景下 LOS 的概率	46
图 3-1	Actor-critic 强化学习框架	49
图 3-2	物联网中的联合信道接入和包转发	51
图 3-3	基于 DRL 的 full-buffer 场景用户调度	52
图 3-4	可扩展的神经网络设计	53
图 3-5	深度强化学习算法性能	53
图 3-6	面向业务流的网络切片资源分配仿真结果	55
图 4-1	无线 AI 架构	58
图 4-2	实验结果	60
图 4-3	基于 AI 的业务层速率控制	60
图 4-4	网络测试结果	60
图 5-1	语义通信模型的一般框架	66
图 5-2	高效语音语义通信系统结构	67
图 5-3	语音语义通信系统测试集错误率	67
图 5-4	语音语义通信系统语义相似度	67
图 5-5	基于多级特征的图像通信系统	69
图 5-6	系统支持用户数随功率变化图	70
图 6-1	无线 AI 研究数据集的收集和利用举例	72
图 6-2	内生 AI 架构与无线 AI 研究数据集	72
图 6-3	RT 仿真信道数据 (左: BS/UE 部署 右: BS5 和 UE7 RT 仿真结果)	72
图 6-4	基于无线 AI 研究数据集的定位任务训练结果	74
图 6-5	波束预测性能对比	75
图 6-6	波束预测模型迁移性能	76
图 6-7	预训练模型部署和迁移验证	76
图 6-8	三种模型迁移策略的波束预测准确率对比	76



表目录

表 2-1	AI 定位精度性能评估结果.....	14
表 4-1	传输层拥塞控制主要 AI 算法.....	59
表 5-1	高效语音语义通信系统对于传输一段音频信号所需要的序列长度.....	68
表 5-2	高效语音语义通信系统对于传输一个隐变量所需要的通信量.....	68
表 6-1	自定义参数配置.....	74
表 7-1	典型的复杂神经网络的复杂度列表.....	81
表 7-2	主要贡献单位.....	97

第一章 引言

伴随着人工智能（artificial intelligence, AI）三大驱动力——算力、算法和数据相关技术的不断发展，AI 技术正在人类社会中掀起新一轮的技术革命。特别地，作为 AI 技术的一个重要研究方向，机器学习（machine learning, ML）利用了深度神经网络（deep neural network, DNN）的非线性处理能力，成功地解决了一系列从前难以处理的问题，在图像识别、语音处理、自然语言处理、游戏等领域甚至表现出强于人类的性能，因此近来受到了越来越多的关注。

AI/ML 技术发展的同时，无线通信系统也在持续高速发展中。第 5 代移动通信（5G）支持增强移动通信（enhanced mobile broadband, eMBB）、超高可靠低时延（ultra-reliable low latency communications, uRLLC）和海量机器类型通信（massive machine type communications, mMTC）等三大应用场景，而未来的无线通信系统必将向更大吞吐、更低时延、更高可靠性、更大连接数、更高频谱利用率等方向演进。已有的研究工作表明，AI 在复杂未知环境建模、学习，信道预测，智能信号生成与处理，网络状态跟踪与智能调度，网络优化部署等许多方面具有重要的应用潜力[1]-[228]，有望促进未来通信范式的演变和网络架构的变革，对 6G 技术研究具有十分重要的意义和价值。由此催生了无线 AI 技术的蓬勃发展。

无线 AI 将是未来 6G 中渗透性最强的核心技术之一，涉及空口、网络、协议和算法的各个层面，也将深度影响感知、通信、计算、控制等网络功能，其性能潜力巨大。学术界和产业界围绕无线智能网络架构、无线智能空口、无线 AI 算法、无线 AI 数据集、无线语义通信等基础理论和关键技术展开了深入研究和探索，取得了一系列重要进展。

在 IMT-2030（6G）推进组的统一安排下，无线技术工作组无线 AI 任务组就人工智能技术在 6G 无线空口和无线组网中的应用开展了深入调研分析，以为下一步开展相关研究提供指导和思路。本报告在对当前国内外的主要研究状况进行调研分析的基础上，结合部分成员单位在无线 AI 上的一些研究工作，对无线 AI 的若干研究方向及其关键技术进行了较为全面地分析和讨论，同时探讨了无线 AI 的难点、挑战和产业化前景。

第二章 基于AI/ML的物理层技术

传统通信链路设计时，人们采取分而治之的方法，将各功能模块进行独立的设计和优化如图 2-1 所示。在某些功能模块的设计和优化过程中，可能存在着性能损失。例如，为了降低设计复杂度，将某些非线性处理简化假设为线性操作。又如，一些模块的设计理论仍然缺失或难以分析，只能借助于启发式算法。此时，使用 AI/ML 方法替换这些模块可以带来性能的提升以及处理时延的降低。这也是将 AI/ML 方法用于空口技术设计的最直接方式。

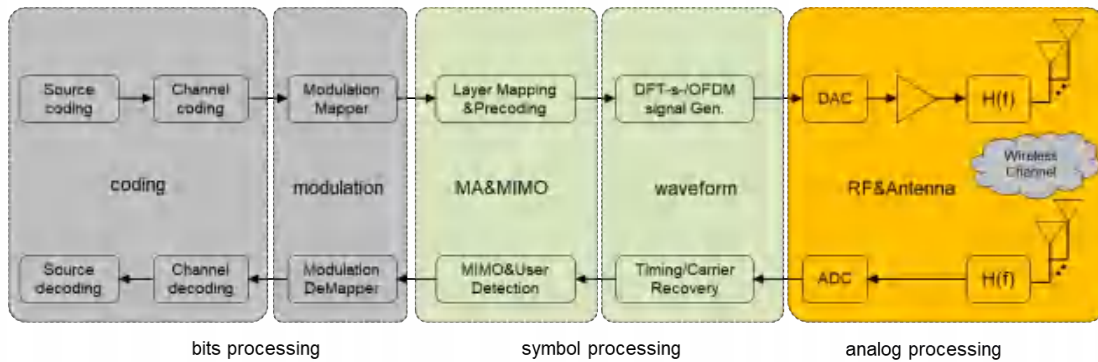


图2-1 无线通信链路

目前，AI/ML 在无线物理层中的应用包括利用神经网络来取代传统发射机和接收机中的基本功能模块，或者将物理层通信看作一个端到端的信号重构问题，并应用自编码器概念来表示物理层通信过程，进行端到端通信的联合优化。目前现有的深度学习网络大多数是基于这种方式的，使用标准的神经网络结构作为黑匣子并通过大量数据进行训练[4][9][12][33][60]。训练标准的神经网络除了需要庞大的数据集之外，还需要大量的训练时间。然而这些资源在某些情况下是极其稀缺的，尤其是在无线通信领域。与数据驱动的方法相比，模型驱动深度学习方法基于已知的物理机制和领域知识构建网络拓扑[5]。因此需要较少的训练数据和较短的训练时间，成为实现智能通信的有效手段。基于此，研究模型驱动深度学习的无线物理层设计[6]，也是面向 6G 的智能通信发展提供理论支撑并指明技术方向的一大重要方式。一般构造模型驱动深度学习的方法有以下三种：1) 将迭代算法形成信号流程图；2) 将算法作为初始化步骤，并将其与神经网络相结合；3) 模仿模型驱动方法中的传统结构。针对模型驱动深度学习的无线物理层设计问题，研究者分别研究了基于模型驱动深度学习的大规模 MIMO 信道估计[75][76]、信号检测[134]、信道译码[25][26]、CSI 反馈[85]和多用

户预编码[7][8]。以下将会针对物理层的不同模块分别详细介绍基于这两种方式的各种 AI/ML 实现方案。

2.1 基于 AI/ML 的无线环境建模与感知

大部分现无线环境建模的工作侧重于无线信道的建模。传统的随机信道建模[1]归纳总结大量实测信道的统计特性，得到的信道模型主要用于为不同空口技术算法对比提供一致的信道环境。随机信道模型归纳总结了信道的统计特性，然而无法提供特定场景下的信道信息。另一种传统的信道建模方式为确定性信道建模[2]，它基于特定传输场景的 3D 地图，通过射线追踪的方式得到场景中的无线信道。这种建模方法以给定场景的 3D 地图为基础，因此其模型具有场景关联性，不同场景下的信道模型无法复用。

对于未来的无线通信系统，无线信道模型以及无线场景模型将不再简单地作为各种算法对比的环境基础。我们期望可以通过对无线传输环境的学习和总结，帮助通信系统更加智能地完成调度、功控、波束管理、参数选择与配置等任务。通过采集大量的传输环境信息数据（包括信道数据、感知数据等），借助 AI/ML 技术的学习和提炼能力，建立“无线电地图”，给系统的设计和决策提供辅助信息，并降低系统的测量反馈开销。

现有工作中，人们尝试了各种结构的模型对无线信道信息进行学习、总结和建模。例如，在文献[3]中，作者使用了自回归（auto-regressive, AR）模型学习信道的时间相关性，可以将信道作为时间序列，利用这些回归模型进行建模和预测。多种神经网络结构都曾被尝试用于无线信道的建模，以及基于模型的信道估计和信道预测[4]-[20]。

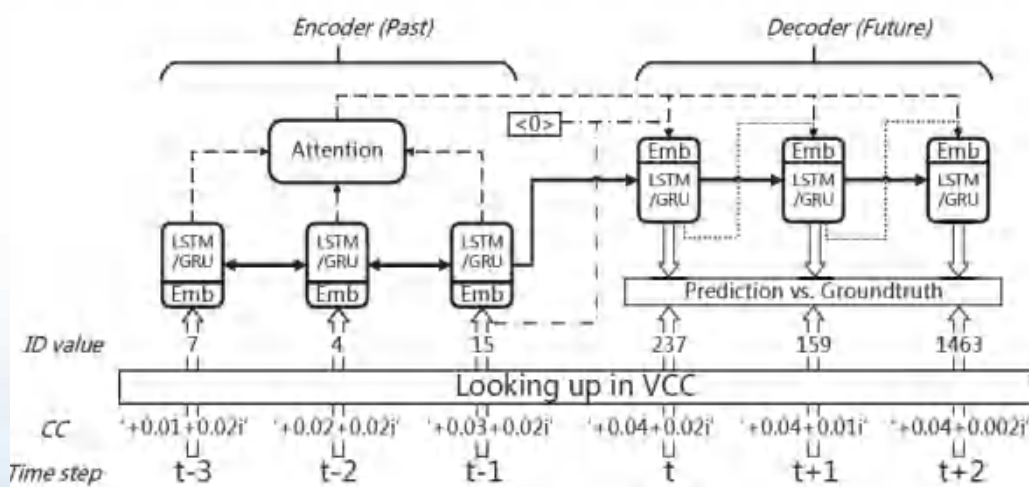


图2-2 基于seq-to-seq模型的信道预测器

如图 2-2 所示，作者使用 seq-to-seq 模型[21]，将信道信息作为时间序列，进行预测[22]。实验发现，当信道存在深衰时，传统的基于参考信号的信道估计方法将出现明显的性能下降，因为此时受到深衰的影响，接收到的参考信号能量极低，无法准确估计信道的幅度和相位信息。而基于 seq-to-seq 模型的信道预测器则可以提供较为准确的信道信息，使得系统解调性能优于传统信道估计算法。

进一步的，考虑信道信息在多个维度上的相关性，可以进行多维的信道嵌入操作。如图 2-3 所示，将信道的位置、频率、时间、空间属性同时进行嵌入操作。将嵌入升维后的信道信息输入注意力（attention）网络，得到信道模型。这一信道模型可以用于多种信道相关的任务，例如定位、信道压缩、信道指纹等。为了更加快速有效地完成这些任务，可以使用历史信道数据，对信道模型进行预训练。预训练的信道模型连接不同的下游任务网络，再进行进一步训练和调优。作者发现，这种预训练的信道模型具有良好的迁移特性[23]，即在特定场景下预训练的信道模型可用于相似场景（例如同一幢建筑的不同楼层）的信道相关任务。




图2-3 多维信道嵌入

中国电信提出了基于信道指纹特征的 AI 直接定位技术，其主要原理是通过对大量信道信息学习，将信道特征与位置坐标进行映射，用于解决重 NLOS 场景室内难点难题。由于该场景与基站具有 LOS 径的测量信号很少，传统定位算法将不再适用，传统定位技术定位精度严重下降。室内场景采用 3GPP InF 模型，开源数据集，传统 AI 全连接神经网络模型，评估结果显示可显著提升定位精度。

表2-1 AI定位精度性能评估结果

定位精度 CDF@X%	AI+DL-TDOA	AI + TOA	传统 TOA 定位
50%	0.38m	0.37m	>11m

67%	0.49m	0.46m
80%	0.59m	0.57m
90%	0.73m	0.69m

实验表明，面向未来网络演进，与反向散射、通感技术的结合将会极大丰富训练数据集，通过 AI 实现多维特征信息的感知与融合，从而实现基于 AI 的精准感知定位。

2.2 基于 AI 的信道估计、预测及反馈

在信道状态信息已知的情况下，MIMO 通信系统的容量会随着发送或接收天线的数目线性增长。但是要得到这样的好处，一个很关键的要求就是要在接收端和发送端获得准确的信道状态信息（channel state information, CSI）。因此信道状态信息的估计（estimation）以及预测（prediction）是 MIMO 系统中一个非常重要的任务。信道的估计问题主要是在接收端根据导频序列来估计发送端和接收端之间的信道状态信息的问题，而信道状态信息的预测问题主要是根据部分（时间、空间、频率角度）的信道状态信息来预测和映射其他信道状态信息的问题。此外，在频分双工（frequency division duplexity, FDD）制式下，下行 CSI 需要先由用户端（user equipment, UE）通过反馈链路传回基站。在下面分别介绍信道状态信息的估计问题、预测问题以及反馈问题。

首先，针对信道状态信息的估计问题。由于传统的基于压缩感知，最小均方误差的方法在 MIMO 中存在很高的计算复杂度，因此近些年来有很多的工作通过人工智能的方法来进行信道状态信息的估计[57]-[78]。同样地，这些工作也可以被分为两类：数据驱动（data-driven）的方法[57]-[74]和模型驱动（model-driven）的方式[75]-[78]。在数据驱动中，[57]最早提出了用神经网络估计信道状态信息的方式，也奠定了之后的大部分工作根据已有信道模型生成训练数据、离线训练的思路基础。在这一类问题中，研究者重点关注的是如何通过改善神经网络，将这种数据驱动的方式应用在不同要求的场景下[58]-[74]。特别地，由于数据驱动方式对训练数据的较高要求，导致这种[74]数据驱动的方式在实际的应用中受限，[74]给出了一种基于强化学习的非监督式的信道估计方法，主要的方式是通过选择性地探索检测到的符号向量作为额外的导频信号，从而来更新最小均方误差的信道估计，强化学习主要用于最优化对符号向量的选取，以一种高效计算的方式来解决这个问题。这种方式可以降低信道估计的误差。另一部分是模型驱动的方式，这种方式的特点是会根据模型来应用神经网络，或是算法来设计神经网络的结构，他们最重要的是没有完全地抛弃传统方法的对应的模块，而是有选择地应用在新的算法中。[75]给出了一种通过学习得到的基于降噪的近似消

息传递网络。这个网络可以从大量的训练数据中学习到信道的结构并且实现信道估计，给出了波束域的信道信息。[77]实现了联合的信道估计和信号检测，其中信号检测考虑到了信道估计的误差和统计信息，同时信道估计通过检测到的数据以及信号检测的误差来进行优化。[78]首先根据最简单的最小二乘法得到一个粗略的信道矩阵，然后再使用一个基于 CNN 的超分辨率网络(super resolution network, SPN)来学习他和信道矩阵之间的联系，从而增加准确性。

信道状态信息的预测问题，根据时间、频率和空间的关联性，可以分为四类。第一类是根据前段时间的信道状态信息来预测下一时间的信道状态信息，主要是应用在随时间变化的信道或者高速移动的场景下，这类问题主要是通过神经网络来刻画和捕捉信道在时间前后的关联性[81]-[83]，由于RNN对时间序列很好的处理属性，很自然的，有工作[81][82]基于RNN对信道的前后状态信息进行了捕捉，基于前几个时间的信道状态信息预测出了后一时刻的信道状态信息。第二类信道预测问题关注于频率角度的相关性[84]-[87]，应用在根据FDD的上行信道状态信息来预测下行信道状态信息的问题上。其中[84]将迁移学习的方法应用到了FDD下行信道的预测问题上，根据全部之前环境中的数据来推测新的环境（频率）中的数据，[86],[87]则使用了传统的CNN来根据上行信道信息映射和预测下行信道的信息。第三类是根据空间角度的预测问题。[87]实现了根据基站部分天线与用户的信道状态信息来预测和映射全部天线与用户的信道状态信息，刻画了信道的空间关联性。第四类是根据相邻用户的信道信息相关性进行预测。对于在同一个场景中并且在同一个基站服务范围内的用户，他们的信道往往也具有很强的相关性，且在不同位置的用户所享有的信道强弱可能不同。因此可以通过部分用户的信道来预测区域所有用户的信道。这一技术在未来万物互联时代将有无限的潜力。

最后，针对信道状态信息的反馈问题。传统反馈方案采用矢量量化或基于码本的方法减少反馈开销，主要分为隐式反馈（Implicit Feedback）和显式反馈（Explicit Feedback）。其中，隐式反馈将预编码矩阵索引（Precoding Matrix Index, PMI）、信道质量指数（Channel Quality Indicator, CQI）等部分信道信息进行量化后反馈，显式反馈是对完整信道矩阵进行量化后反馈。上述两种反馈方案的性能依赖于码本的设计，且其码本设计复杂度和相应的反馈量会随着天线数量增加而显著增长，因此大规模MIMO给基于码本的反馈方案带来了极大的挑战。近年来，随着人工智能技术的迅猛发展，诞生了基于AI的CSI反馈方案，并成为当下CSI反馈研究的热点。其中有基于AI的全信道信息反馈[91][92][93][94]和基于AI的隐式反馈两种反馈方案，将在以下分别介绍。

2.2.1 信道状态信息估计

首先介绍数据驱动模型的典型工作[57]。这个工作基于一个正交频分复用（orthogonal frequency-division multiplexing, OFDM）系统，所提的框架图如下图 2-4 所示。在该文献中将 OFDM 的解调和无线信道都视为黑盒，考虑如何直接从接收到的

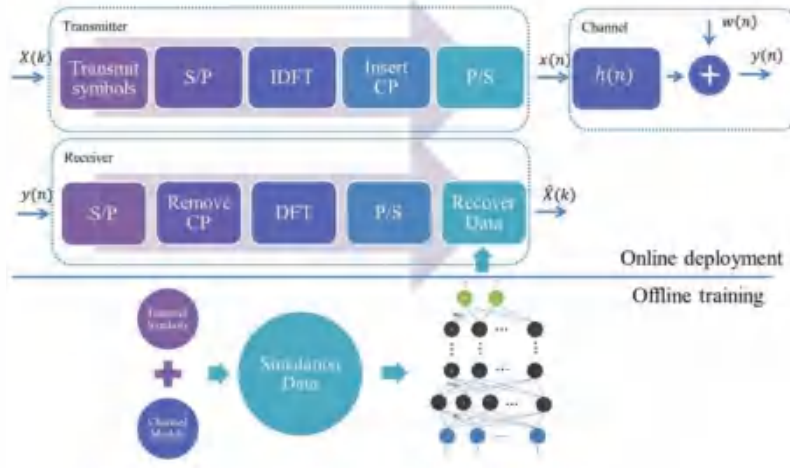


图2-4 系统框架图

数据恢复原始的传输数据，其中包括了解调以及信道估计的过程。他将接收到的信号和原始的传输数据作为训练数据，神经网络的输入是接收到的数据，训练的目标是最小化神经网络的输出和原始传输数据的距离。仿真比较了基于传统的最小平方差（least square, LS）和最小均方误差（minimum mean square error, MMSE）的信道估计和检测方法，得到的结果如下图 2-5 所示。从图中的结果可以看出，LS 表现最差，因为没有用到信道的统计信息，同时 MMSE 有最好的表现，因为此时二阶的信道统计信息假设已知并且被用于检测，可以看出基于深度学习（deep learning, DL）的方法要比 LS 好很多，并且近似于 MMSE 的表现。

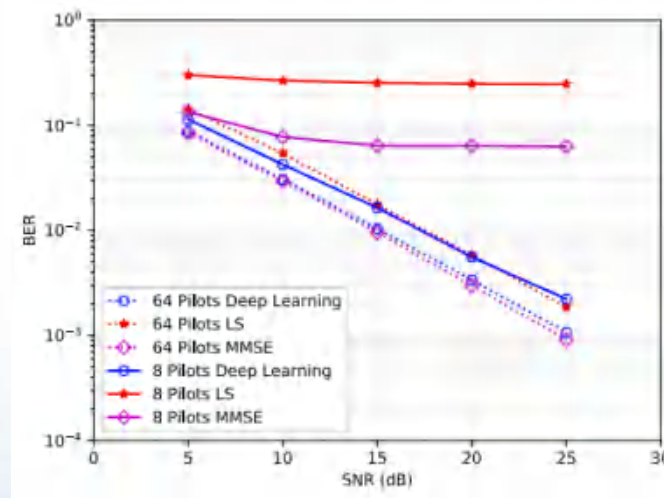


图2-5 DL和传统算法的比较

近期，诺基亚上海贝尔研究如何在高多普勒的场景下，把辅助信息耦合入信道估计中，从而在对信道进行完美估计的同时，减少对参考信号开销的需求。进而提出一种基于超分辨率神经网络的复合结构，仅使用一个参考信号，在时、频维度上对信道进行准确估计，并对多普勒效应进行自适应补偿。方案1的特点是与特定环境高度相关，并且支网络结构简单，我们仅使用若干 FC/CNN。方案2以欠完美的星座图作为神经网络的辅助信息，通过机器学习图像识别的方式，对多普勒进行自适应补偿。

方案1是在 ray tracing 的信道模型中进行验证的，如图 2-6 的左图所示，无论是传统方法或者单一的超分辨率神经网络，在仅用一个 DMRS 的情况下，都无法很好地处理多普勒效应。然而在语义信息输入的复合结构中，即使是未经训练的条件下，多普勒影响可以被很好的补偿，对星座图旋转进行有效修正。方案2是在 38.901 定义的信道模型上进行的仿真验证的如图 2-6 的右图所示仿真结果证实，通过对星座图识别，可以有效对多普勒影响进行补偿，对星座图旋转进行有效修正，达到接近基于完美信道估计的表现，并优于传统的信道估计方法。

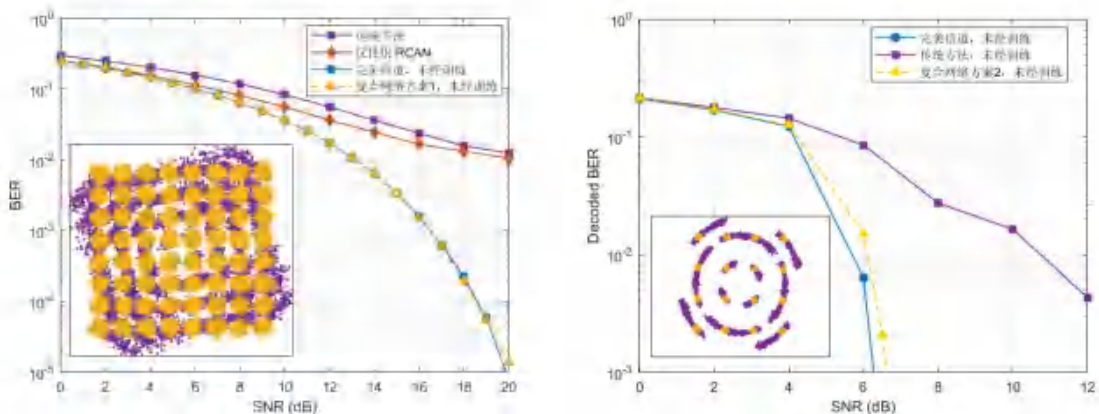


图2-6 复合神经网络仿真结果

此外，就现有的信道估计方法而言，有粗略型和精准型两种形态。粗略型计算相对简单粗暴但精准度相对较差，实际应用广泛。精准型估计的计算量非常大，特别是信道矩阵 H 求逆过程十分复杂，实际的总时延会使信道估计的意义降低，实战意义较低。随着通信的发展，导频开销日益严重，如果单纯的依赖增加导频密度来应对更多场景的信道估计方面的挑战，代价是很大的。

设计一种 AI 算法，降低对信道测量数据的依赖，比较高效精准的实现信道预测是我们研究的焦点。小样本 AI 应用于信道估计的思路如下。单纯的 HI 算法（传统经验公式法）随着导频稀疏程度增大误差也随之增大。通过小样本 AI 算法可以快速捕获信道变化特点，配合 HI（以曲率圆估计方法为例）来实现信道的快速准确估计。曲率圆估计方法应用在由信道 H 的实部、虚部以及时间构成的三维空间坐标系上，通过

曲率圆弧的插值方式实现信道估计。小样本 AI 算法重点学习曲率圆的主要特征为：(1) 曲率半径；(2) 波动周期“T”；(3) 曲率圆心位置；(4) 包络。小样本 AI 需要通过邻近的历史数据学习这四方面的特征及变化趋势，但是区别于传统 AI，这种抽象学习不需要大量历史数据，因为大量的历史数据（时间或空间差异大）对当前信道估计有效性差。

最后，仿真结果如图 2-7 所示，其中，混合速度（50、60、70KM/h）+多径+噪声（10dB）+节省导频开销（25%，50%、75%、95%。结果显示，HI+AI 模型显然对抗导频超稀疏场景的能力更强。多项实验证明该模型在传统导频减少超过 90%时，性能还能保持优良。同时，该工作也给出了未来深度探索的方向。包括（1）相同开销的导频，不同发送策略会产生不同性能效果；（2）不同场景动态调整不同的导频；（3）导频开销节省的极致边界。

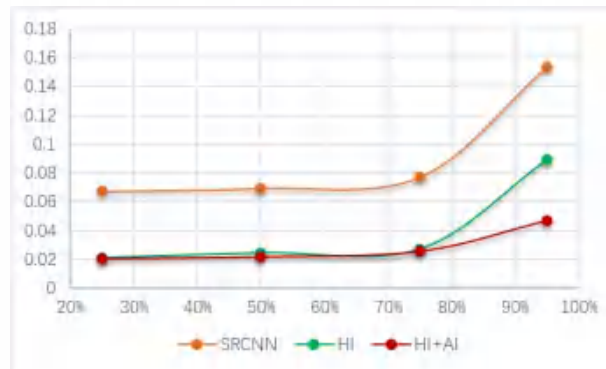


图2-7 小样本AI信道估计仿真结果

2.2.2 信道状态信息预测

考虑随时间变化的信道，由于反馈的延迟会导致得到的信道状态信息不再准确，尤其是在快衰落的信道中。为了解决这个问题，[81]应用 RNN 网络来建立一个长范围的信道预测器。对于一个快衰落信道，通过应用一个多步 RNN 就可以准确地预测信道的增益以及系数。同样是从已知信道预测未知信道，文献[87]则考虑了信道在空间和频率上的相关性，应用这种相关性实现了信道的映射和预测。这个工作解决的问题是如何根据一部分天线和一部分频带的信道状态信息，预测或映射得到全部天线、全部频带的信道状态信息，并且证明了这种映射的可实现性。文献[88]同样也考虑了信道时域相关性，即通过一部分天线的信道，去预测所有的天线信道。不同的是，作者同时提出了一个基于深度学习的信道选择子网络，在训练信道预测网络的同时训练最优的天线选择方案。所提的网络结构如图 2-8，其中信道选择子网络实现天线子集的选择，而信道外推子网络则实现从这一天线子集的信道信息到全部天线信道信息的预测。仿真结果如图 2-9 所示。




图2-8 基于深度学习的信道选择联合信道外推网络




图2-9 左：均匀选择图案 中：网络学习到的图案 右：信道外推误差比较

这个工作所提出的信道选择联合信道外推技术减少了大规模天线系统的导频开销，节约了频谱资源和能效。其所使用的信道选择方法也可以用于其他需要进行选择操作的通信问题中。但该信道选择方法仍有待进一步改进，如信道选择网络输出一个信道选择向量 \mathbf{s} ， \mathbf{s} 与 \mathbf{h}_A 按元素相乘后得到的信道向量包含大量0元素，这给信道外推子网络带来了一定程度的冗余，可以进一步研究可以消除这些0元素的方法来降低信道外推子网络的规模。

文献[90]提出一种针对于准静态环境的信道预测网络。在实际的通信场景下，基站总是服务于某个固定的区域。在该区域中，散射体的数量、位置、电磁特性也可以认为是准静态的。因此，发生在固定区域中的所有通信过程都受到同样的散射环境影响，不同位置处的静态信道可以认为是高度相关的。利用在固定区域内随机获取的一组CSI-位置坐标样本，可以通过学习的方式预测该场景中任意一个位置处的静态CSI。其中，CSI-位置坐标数据可以通过历史的通信过程中的记录获得，因此不会带来额外的信令开销。因此通过特殊设计的学习网络，能够仅通过用户所处位置坐标信息预测用户所处位置的静态信道冲激响应(CIR)。

所提出的C-GRBF网络的学习架构如图2-10所示。整个结构由三部分组成：深度前馈神经网络、C-GRBF层和加权输出线性层。首先位置坐标输入到深度神经网络中，深度神经网络输出由一系列神经元组。每一组包含三个神经元，用于表征某一条传播路径所对应的关于用户坐标的反射像点。在径向基函数层，将输出的坐标输入到余弦高斯核函数中，是C高斯核函数的可学习中心，通过得到相关核函数输出的加权和，可以得到某一路径的最终幅值部分。经过充分的训练后，参数 \mathbf{W} 将收敛到一个固定值，即电磁波的频率除以光速。参数 \mathbf{a} 被设计周期函数核的中心，以拟合由传播距离引起的相移。最后，线性层用于组合核函数的输出结构，并重构信道响应向量。

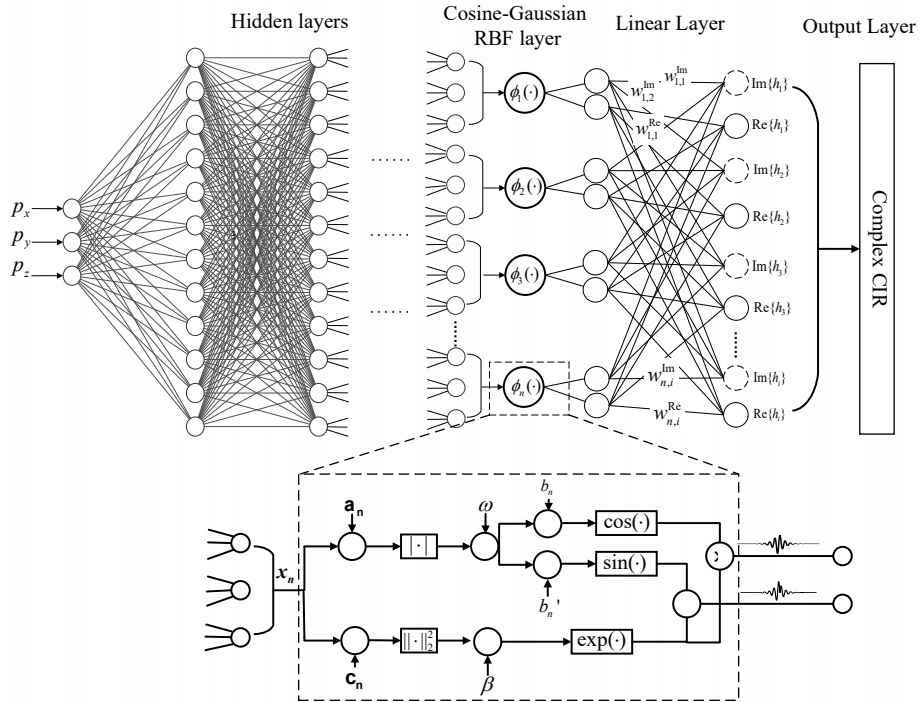


图2-10 用于静态信道预测的C-GRBF网络结构

这个工作具有很好的意义，揭示了无线通信场景可以通过物理启发的学习结构和算法来学习，并且说明了如何设计特定的学习结构来适应无线通信中的特殊问题。此外，说明了针对具体无线通信场景设计的网络结构有更大的潜在在具体任务上超过通用学习网络与架构。

2.2.3 信道状态信息反馈

基于AI的信道状态信息反馈方案有全信道信息反馈和隐式反馈两种方式。首先介绍基于AI的全信道信息反馈方案。这种方案将通信系统建模为端到端的CSI图像重构任务。其结构如图2-11所示，是一个基于自编码器(autoencoder, AE)的网络架构。位于UE端的编码器将完整CSI视为图像并压缩为一个满足反馈比特要求的压缩编码，再通过反馈链路反馈到基站(base station, BS)端；BS端则利用译码器进行解压和重建任务，输出为CSI的重建图像。使用AE实现端到端的无线通信系统，在训练过程中能够通过优化器共同优化编码器与译码器网络，从而获得最优的CSI重建模型。




图2-11 基于AI的全信道信息反馈架构

基于AI的全CSI反馈架构CsiNet[91]，其编码器包括特征提取、特征压缩两个模块，译码器包括特征解压缩和信道重建两个模块，其中全连接层完成特征压缩与解压任务，信道重建部分则包含两个由三层卷积组成的残差模块，用于细节上的重建。实验表明，相较于基于压缩感知的反馈方案，其重建精度大幅提升，同时运算速度提升近100倍。面对时变信道，CsiNet-LSTM[92]在CsiNet的译码器中利用LSTM的记忆特性有效提取CSI序列的时间相关性，进一步提升了网络的重建性能。CsiNet+ [93]提出了一种多速率反馈架构，并对编码器输出的压缩编码进行非均匀量化，生成比特流便于实际传输。CsiFBnet [94]则是提出了一种结合波束成型技术的反馈模型，最大化利用波束成型技术带来的性能增益来提升系统表现。

接下来介绍基于AI的隐式反馈方案。现有5G系统的CSI反馈依赖特征向量等间接信息的反馈与利用，从经典模型的角度出发，利用Type I/II码本实现特征向量的反馈与恢复。为了更直观平等地比较基于AI的反馈方案和5G NR中基于码本的反馈方案，考虑将AI与隐式反馈相结合，通过提取完整信道矩阵的特征向量，并送入神经网络进行压缩反馈，从而减少反馈开销。

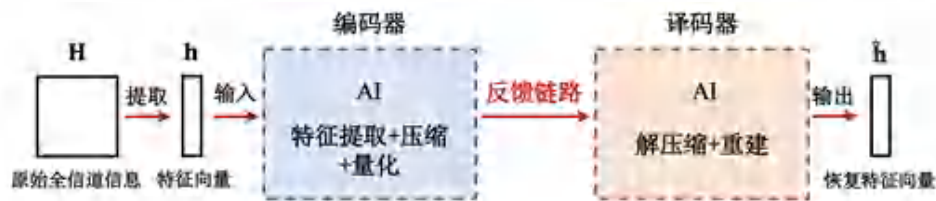


图2-12 基于AI的隐式反馈架构

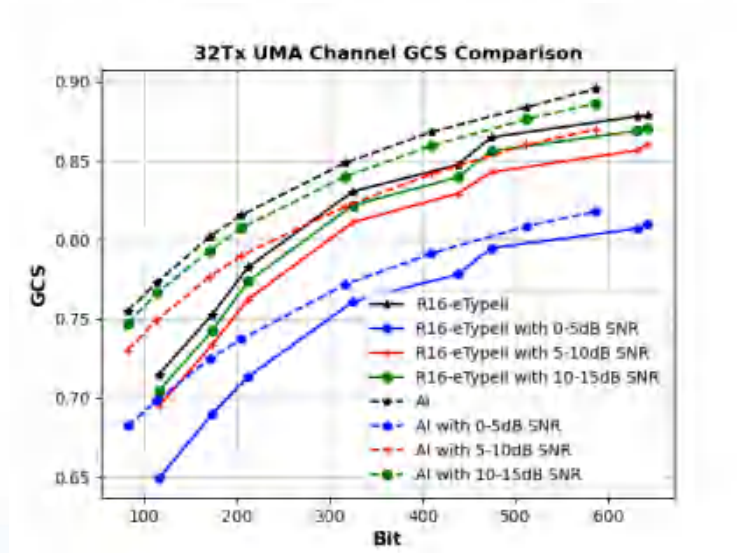


图2-13 32天线下的UMA加噪信道数据仿真图

图2-12所示为基于AI的隐式反馈架构，在信道信息压缩反馈前，需要先利用奇异值分解（singular value decomposition, SVD）等算法提取原始全信道信息的特征向量，再将特征向量作为神经网络的输入。UE端的编码器网络用于对特征向量进行特征提取和

压缩，再通过一个量化模块生成传输的比特流并反馈回BS；BS端的译码器网络用于解压缩和重建特征向量。实验结果表明，基于AI的隐式反馈方案在相同余弦相似度下，所需反馈比特数明显少于Type I/II码本。为了验证基于AI的隐式反馈性能，中兴移动通信设计了接近于实际情况的加噪信道隐式反馈实验：仿真场景为3GPP中系统级UMA(urban macro honeycomb)信道，天线采用32T1R配置，对不同信噪比的高斯白噪声污染的信道数据情况下进行仿真，如1.1.1所示。结果表明，AI网络对不同噪声功率污染下的CSI反馈性能均有鲁棒性，AI方法在反馈准确性与开销性能上均超过eTypeII码本反馈方式。总体来说，基于AI的CSI反馈方案为进一步降低CSI反馈开销与提升反馈精度提供了新的可能性，具有极大的研究价值和发展前景。

2.2.4 导频、信道估计、信道反馈、预编码联合设计

在无线通信系统中很多模块实际上都是关联的，如MIMO系统的系统容量与预编码有关，预编码是基于信道估计（TDD系统基于互易性、FDD系统基于信道信息反馈）生成，信道估计又与导频序列的设计相关。单模块的AI优化虽然可以提升每个模块的性能，但从整体系统性能来讲并不能实现全局最优。因此，可以考虑将多个相关的模块用一个AI网络进行联合模拟并优化，实现多个参数的联合设计。

文献[71]考虑一个FDD massive MIMO系统，实现导频序列设计和信道估计的AI网络联合优化。文献[72]将导频设计、信道估计、信道信息反馈、预编码等模块进行了联合设计；通过理论分析证明，在FDD多用户massive MIMO系统中，上述“导频设计、信道估计、信道信息反馈、预编码”是一个分布式源编码（distributed source coding）问题，在多个用户端分别进行信道估计且不做信息交互，也可获得逼近多用户联合编码反馈时的最优性能。但目前分模块优化的方案相比上述最优性能还有一定的差距，多模块联合设计有较大的性能提升空间。

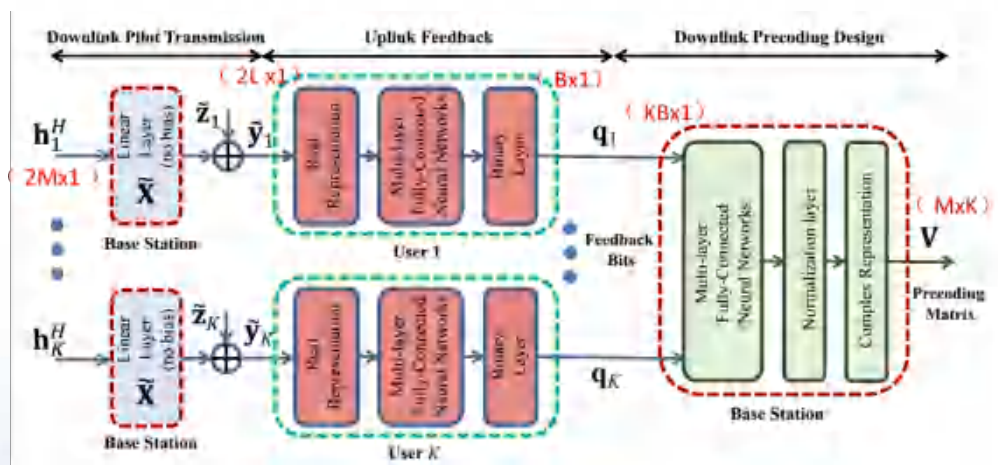


图2-14 导频设计、信道估计、信道信息反馈、预编码的联合设计

值得注意的是，信道信息反馈子网络的最后一层是一个量化函数，该函数只有在输入为0时有梯度（且梯度为无穷大），在其他输入处梯度为0。因此，在反向梯度传播时

会造成无梯度可以传的问题。对此，需要对该函数进行梯度重写，正向传递的时候仍进行正常的量化，但在反向梯度传播时以重写的函数的梯度替代原函数的梯度。常用的重写方法有直通估计器（straight through estimator, STE），sigmoid调整的直通估计器和退火sigmoid调整的直通估计器等。可根据量化函数的输入取值范围和训练的收敛速度等具体情况，选择不同的梯度重写方法。

2.3 AI 使能的端到端设计

此类研究的目的是在特定的信道环境下联合优化发射机和接收机[96][97][98]。与传统人工设计相比，基于 AI 的端到端收发机设计往往呈现出不太一样的编码和/或调制样式[97][98]。端到端优化设计更适合于具有各种非线性效应的非典型信道，因为神经网络可以学习这些非理想的信道效应，而传统优化方法面对较多的非线性因素时往往出现性能下降的现象[96][97][98]。最初的基于 AI 的端到端收发机设计示意图如图 2-15 所示。该系统考虑一种在加性高斯噪声信道上进行通信的场景，其中收发两端的信号处理都通过神经网络实现。在仅考虑高斯信道时，我们可以直观地将神经网络学习的信号处理过程理解为编码加调制的结合，通过调整输入消息的种类和输出符号的比，可以实现不同码率的传输。可以发现，神经网络学习的星座图与传统意义上的正交幅度调制（quadrature amplitude modulation, QAM）星座图会有一定的差别，这种区别在调制阶数较高的时候会更加明显。图 2-16 给出简单的误消息率结果，可以发现神经网络学习得到的信号处理过程可以达到甚至能够超过一些人类专家设计。相关思路不仅可以实现在 AWGN 信道下的消息传输，还可以实现在典型衰落信道下的消息传输^[11]。




图2-15 基于AI的端到端收发机设计（针对AWGN信道）




图2-16 基于AI的端到端收发机误消息率性能比较（AWGN信道）

在进行端到端学习时，可以将实际系统的物理器件非线性和特殊需求作为约束条件。例如，文献[97]提出将控制 OFDM 峰值平均功率比（peak-to-average power ratio, PAPR）和相邻频道泄漏比（adjacent channel leakage ratio, ACLR）作为约束条件，通过端到端学习设计新波形，得到优化系统性能的目标。




图2-17 卡尔曼滤波和AI结合的端到端收发机

尽管基于 AI 的端到端收发机可以在离线训练时适应特定类型的已知和静态多维信道，然而，实际部署时，时变的、受噪声干扰的无线信道会导致预先训练的收发机出现性能次优的情况。此外，当不可预测的信道条件出现（等同于训练数据集出现异常值的情况），预训练的收发机的性能将急剧下降。产生此种情况的主要原因是因为组成收发机的神经网络单元在推理阶段都被冻结，且不具有适应环境变化可调整性。在线重新训练基于 AI 的收发机开销较大，因此文献[229]提出一种新型的端到端收发机设计方法。如图 2-17 所示，在自编码器结构中的编码器之后，级联基于卡尔曼滤波算法的控制层，形成卡尔曼滤波-自编码器级联结构。将该控制层的每个参数建模为随机游走的变量，并将其视为控制量，通过卡尔曼滤波的方法跟踪其参数变化并进行参数估计和训练，无需获取信道模型。区别于现有自编码器方法对信道模型已知的依赖，

该方案是一种高鲁棒性、快速收敛的端到端智能空口结构与训练方法。

2.4 基于 AI/ML 的信道编译码技术

自香农提出信道编码定理以来，学界致力于寻找能够逼近香农限的编码方案。随着时间的推移，学者们提出了汉明码、循环码、卷积码、Turbo 码、低密度奇偶校验（low density parity check, LDPC）码以及极化码（Polar code）[2]。其中 LDPC 码能够在码长趋于无限时，性能无限逼近香农限；而 Polar 码是目前唯一一种被证明能够在特定信道下达到香农限的编码方案。随着深度学习在无线通信物理层研究中的逐步应用，深度学习在信道编译码问题上已经有了一定的突破。与传统的信道译码方法相比较，基于深度学习的译码器在性能上有显著的改善，但同时由于维度爆炸，深度学习应用于编码技术也存在一定的局限性。

目前，学界涌现出一批性能优异的基于深度学习的编译码算法。Nachmani 等提出了一种基于深度学习的改进置信传播算法（belief propagation, BP）[101][107]。Cammerer 等提出了一种基于深度学习的 Polar 码分段译码算法[109]。Liang 等提出了一种基于 CNN 的迭代 BP-CNN 结构[110]，用于相关噪声下的信道译码。Wang 等提出了一种 LSTM 网络辅助的 SCF 译码算法[111]。Chen 等提出了一种低复杂度的 LSTM 网络辅助的 CA-SCLF 译码器[112]。

AI/ML 在信道编译码方面的应用主要体现在两个方面。一方面，可以将 AI/ML 算法和神经网络直接嵌入通信链路，替代译码器。例如，在文献[24]中，DNN 被用于 Polar 码和随机码的译码，可以以更低的复杂度达到最大后验概率算法（maximum a posteriori, MAP）性能。文献[25]使用 DNN 进行 turbo 码译码，解决传统 max-log-MAP 算法将非线性简化为线性导致的性能损失问题。另一方面，也可以利用 AI/ML 方法进行信道编码方案的设计。

2.4.1 基于 AI/ML 的信道编码方案设计

注意到利用 AI/ML 方法的学习能力，可以设计信道编码方案，特别是在一些没有理论指导的场景中（例如在列表译码算法下的 Polar 码设计），AI/ML 可以找到比人工设计性能更好的码。例如，文献[27]使用遗传算法（genetic algorithm, GA）进行 Polar 码设计，而文献[28]利用 RNN 进行 LDPC 码的度数分布设计。在文献[44][45]中，作者使用遗传算法和强化学习（reinforcement learning, RL）框架进行 Polar 构造序列的设计。如图 2-18 所示，基于 AI 设计的 Polar 码性能优于 DE/GA 方法得到的 Polar 码。

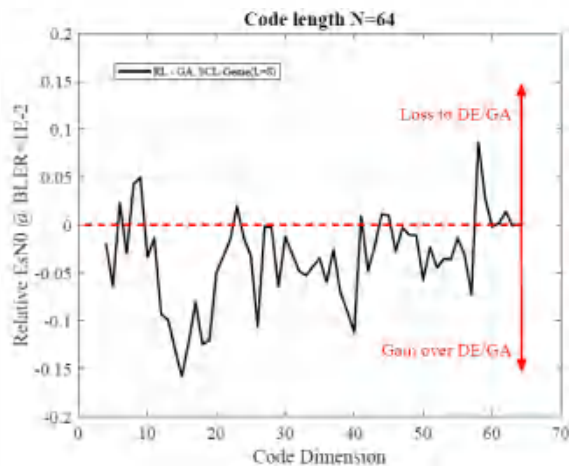


图2-18 基于AI方法设计的Polar码性能优于DE/GA方法

2.4.2 基于 DNN 的编译码算法

Nachmani 等提出了一种基于深度学习的改进 BP 算法[101][107]，该方法通过对 Tanner 图的边赋予权值，推广了标准的置信传播算法。然后，作者使用深度学习的方法训练这些边缘的权值。置信传播算法的一个众所周知的特性是性能对传输码字的独立性。基于深度学习的改进 BP 算法的一个关键特性就是译码器保留了这个特性。此外，此属性允许网络只学习单个码字，而不需要学习随码长增加数量指数级增加的全部码字，能够很大程度上解决编译码过程中的维度爆炸问题。

Cammerer 等提出了一种基于深度学习的 Polar 码分段译码算法[109]。在这项工作中，作者证明了当译码器的子块被神经网络取代时，能够提升传统的极化码迭代译码算法的性能。因此，作者将编码图划分为更小的子块，并分别对它们进行训练，接近每个子块的 MAP 性能。所得到的解码算法是非迭代的，并且固有地实现了高水平的并行化，同时其误比特率（BER）性能十分优异。

2.4.3 基于 CNN 的译码算法

Liang 等提出了一种基于 CNN 的迭代 BP-CNN 结构[110]，用于相关噪声下的信道译码。本文设计了一种新的接收机结构来解决信道噪声中存在相关性时的译码问题。这种结构将一个经过训练的 CNN 与一个标准的 BP 译码器连接起来，接收到的符号在 BP 和 CNN 之间迭代处理，因此被称为迭代 BP-CNN。在接收端，首先由 BP 解码器对接收到的符号进行处理以获得初始解码结果。然后，从接收到的符号中减去估计的发射符号，而得到信道噪声的估计。由于编码误差的存在，信道噪声估计不准确。然后，将信道噪声估计输入到 CNN 中，进一步消除了 BP 译码器的估计误差，并利用噪声相关性得到更准确的噪声估计。BP 和 CNN 之间的迭代将逐步提高译码信噪比，从而获得更好的译码性能。其算法示意图如图 2-19 所示。

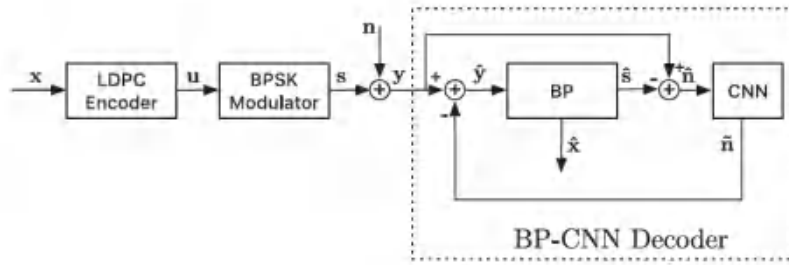


图2-19 BP-CNN译码算法

为了训练一个性能良好的 CNN 模型，作者定义了一个新的损失函数，它不仅涉及噪声估计的精度，而且还涉及估计误差的正态性检验，即测量估计误差服从高斯分布的可能性。在 CNN 训练中引入正态性检验，与使用标准二次损失函数相比，进一步降低了迭代译码的误码率。

该算法性能如图 2-20 所示。可以看到基线 BP-CNN 和增强后的 BP-CNN 在相关噪声下都取得了显著的性能提升。在强相关情况下，当 $\eta=0.8$ 时，BP-CNN 在误码率为 10^{-4} 时可将译码性能提高约 3.5dB。需要强调的是，在标准 BP 译码器中，这种性能增益不能通过更多的迭代来补偿，因为 BP (50) 已经达到饱和性能。在 $\eta=0.5$ 的中等相关性情况下，性能增益变小，因为相关性较弱，采用 CNN 的好处较小。对于 $\eta=0$ 且噪声变为独立同分布（即标准 AWGN 信道）的特殊情况，所提出的方法与标准 BP 译码的性能类似。




图2-20 BP-CNN译码性能对比

2.4.4 基于 LSTM 网络的译码算法

Wang 等提出了一种 LSTM 网络辅助的 CA-SCF 译码算法[111]。极化码串行抵消（successive cancellation, SC）翻转译码的关键是准确识别第一个错误位。由于缺乏解析解，最优翻转策略被认为是难以实现的。为解决这个问题，作者提出了一种深度学习辅助的 SC-flip 算法。其系统示意图如图 2-21 所示。

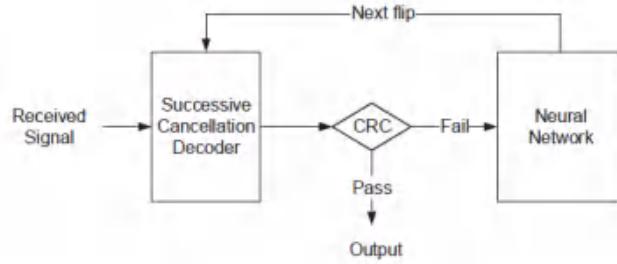


图2-21 LSTM-aided SCF算法示意图

具体地说，在每次 SC 译码尝试之前，利用 LSTM 网络来定位第一个错误位，或者撤消先前的“错误”翻转。在每次 SC 译码尝试中，利用在上一次 SC 译码尝试中导出的对数似然比（log likelihood ratios, LLRs）序列来决定要采取的操作。据此，作者提出了一种 LSTM 网络的两阶段训练方法，即在第一阶段学习定位第一个错误位，然后在第二阶段学习撤销“错误”翻转。仿真结果如图 2-22 所示。显然，与传统 SCF 算法相比，该方法能更准确地识别错误比特，并获得更低的块错误率（block error rate, BLER）。

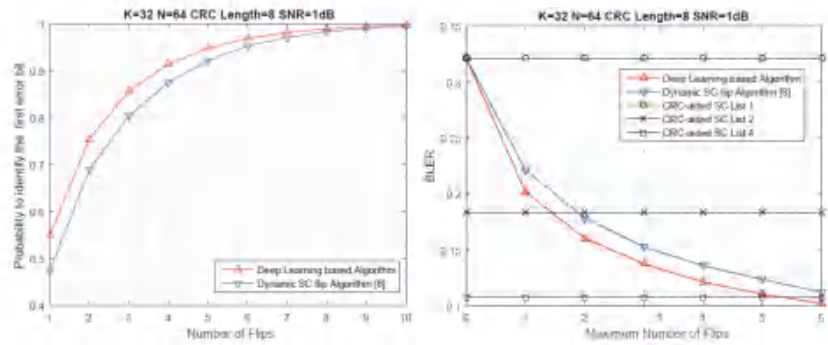


图2-22 LSTM-aided SCF性能对比

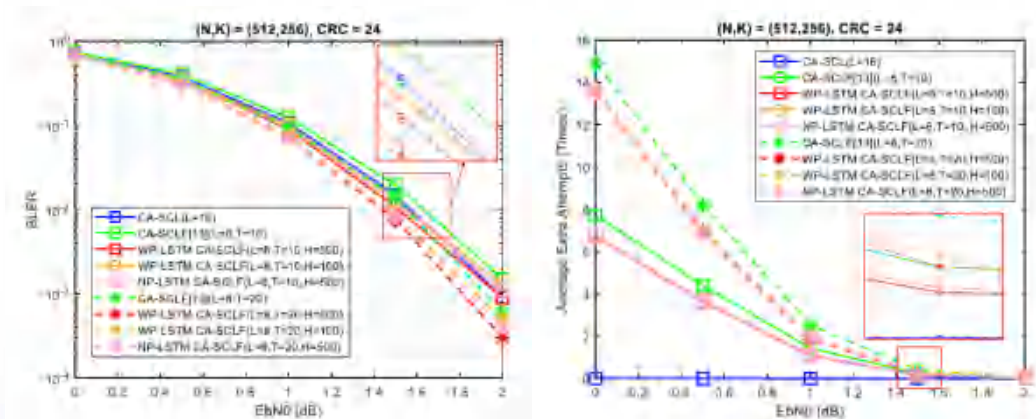


图2-23 LSTM-Aided CA-SCLF算法性能比较

Chen 等提出了一种低复杂度的 LSTM 网络辅助的 CA-SCLF 译码器[112]。其将 LSTM 应用于 CA-SCLF 译码器，可以有效地从顺序译码的过程中产生的 LLR 中提取特征，增强误码预测能力。实验结果如 1.1.1 所示，该算法能有效地提高 BLER 性能

0.11dB。同时，对输入数据进行预处理和输出降维，可以显著降低 30%以上的内存需求和计算复杂度，使其设计更适合于硬件实现。

2.4.5 基于对抗生成网络译码算法

针对 DNN 信道解码的局限性，小米公司提出一种基于生成对抗神经网络进行低密度奇偶校验码译码的方法。提出的基于对抗生成网络的低密度奇偶校验码译码模型如图 2-24 所示。生成器接收到经过 BPSK 调制后通过 AWGN 信道的含有噪声的码字，在生成网络端学习低密度奇偶校验码的译码规则，并生成译码结果。初步生成译码结果。并将此结果输入判别器，对译码结果和真实信息序列进行比对，判别器给出是或非的结果，得到结果后进行反向传播，进行反向传播时首先判别器不更新，生成器更新，更新之后对判别器更新，生成器不更新。生成端和判别端更新后，继续输入数据来训练对抗生成网络的低密度奇偶校验码译码算法。对译码生成器以及译码判别器进行更新后，如果用于本轮训练的一个或多个信息序列样本中存在尚未经过译码生成器和译码判别器处理的信息序列样本，则将从尚未处理的信息序列样本中任意一个获得的接收码字样本输入译码生成器以获得与该信息序列样本对应的译码码字样本，并将该信息序列样本和译码码字样本输入译码判别器以确定能够区分该二者，如果能够区分，则再次对译码生成器和译码判别器进行更新，直至用于本轮训练的一个或多个信息序列样本中没有未经过译码生成器和译码判别器处理的信息序列样本，即用于本轮训练的所有信息序列样本均已被使用，则可以开始下轮训练。如果确定无法区分译码码字样本和信息序列样本，结束迭代训练并获得预训练的 GAN 模型。如果译码判别器无法区分出译码码字样本和信息序列样本，这表明译码生成器能够根据接收码字样本还原信息序列样本。

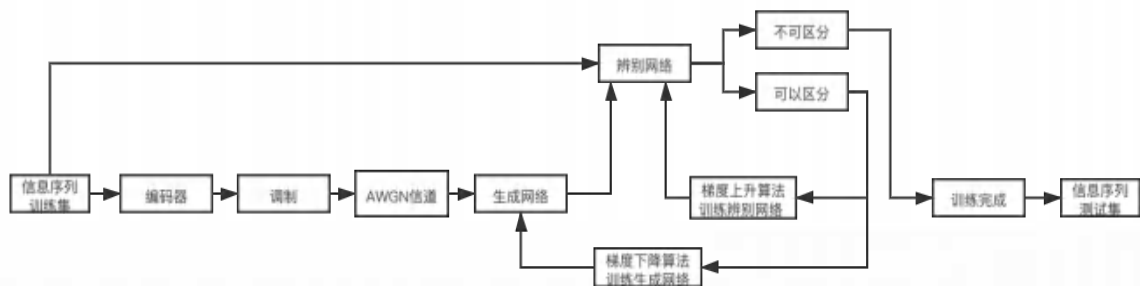


图2-24 基于对抗生成网络的低密度奇偶校验码译码模型

仿真结果如图 2-25 所示，结果表示了基于对抗生成网络的 LDPC 码的译码结果，并与 LDPC 码传统的译码算法 BP、LLR-BP、Min-Sum 译码进行了比较。通过仿真图可以看出，网络实现了对 LDPC 码的译码，其译码误码率优于传统译码算法。




图2-25 对抗生成网络的LDPC码译码结果

2.5 基于 AI/ML 的调制与波形技术

早期的工作中，AI/ML 方法主要用于在多种调制方式混合的信号中识别调制方式 [29]，这种应用在无线通信领域实际场景并不多。和信道译码一样，神经网络也被用于替代通信链路的解调模块[30]。对调制解调模块的优化还体现在星座图的设计上，此时，调制和解调常常联合优化。文献[31]使用如图 2-26 所示的自编码器进行调制星座的位置整形和概率整形联合优化，并得到相应的解调神经网络。这个方法得到的调制解调模块性能非常接近香农极限。 AI/ML 方法还可以针对特定场景进行星座图设计，例如文献[32]中，使用 AE 结构设计光纤通信中使用的调制星座图，以对抗光纤信道的非线性。

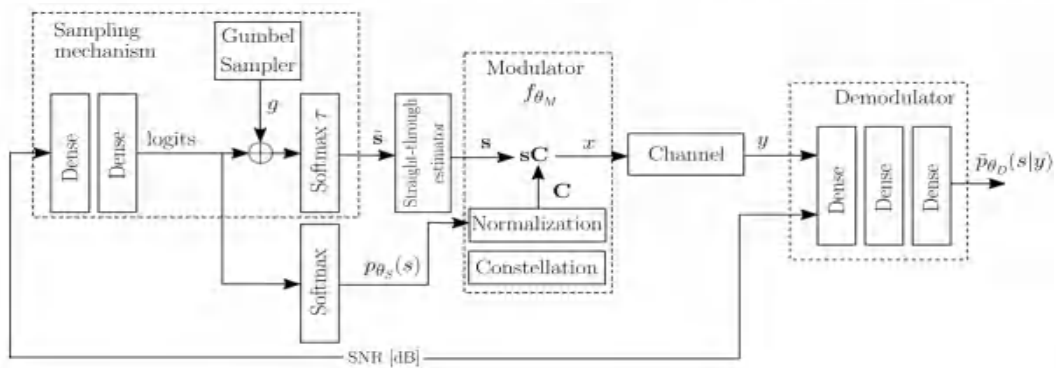


图2-26 基于autoencoder的调制解调联合设计

AI/ML 方法可以用于直接进行类似 OFDM 波形的设计，例如文献[38]中，不使用 DFT 操作，可以直接用 DNN 得到信号的波形。AI/ML 方法也用于低峰均功率比 (peak to average ratio, PAPR) 波形的设计，例如，文献[39]使用如图 2-27 所示的 AE 结构，设计得到低 PAPR 波形。此外，AI/ML 方法也被用于作智能波形的识别网络，如图 2-28 所示。

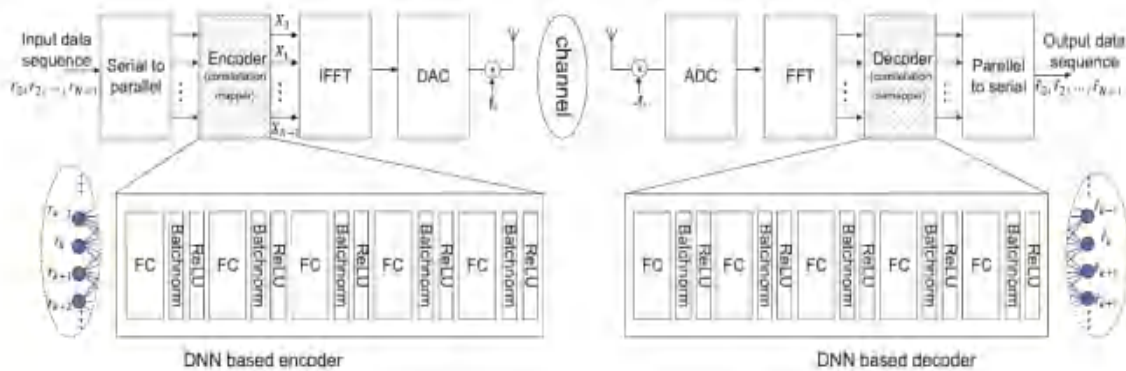


图2-27 基于AE的低PAPR波形设计




图2-28 基于AI的智能波形识别网络

2.6 基于 AI/ML 的信源信道联合编码技术

传统的通信系统通过信源编码、信道编码分别实现图像/视频的压缩和传输，并将信源和信道编码划分为两个模块独立设计。信源信道分别独立编码具有设计简单、模块化的特点。基于香农分离定律，信源信道独立编码在码长无穷大的条件下是理论最优的。然而，包括物联网，自动驾驶和触觉互联网在内的许多新兴应用都要求极低延迟，带宽和能量约束的条件下传输图像或视频数据，这限制了在计算上需要依赖较长编码的信源信道独立编码技术的使用。对此，Gamal-Kim 从理论上阐述了多种信源信道联合编码模式，可以利用信源的相关性将通信系统的信源编码和信道编码作为一个整体来进行优化设计，取得比信源信道独立编码更好的性能[40]。

传统的信源信道联合编码允许用户根据信道或网络条件改变信源编码参数，或是根据信源特性选择信道编码、调制及网络参数。其本质是研究人员使用专家知识精巧的设计信源信道编码方案。其中的代表是由 Wu 团队和 Katabi 团队在 2010 年提出的 Softcast 模式[41][42]，通过变换对输入图像或视频进行处理，并将系数直接调制为密集的星座图进行传输，须进行常规的量化、熵编码和信道编码。Softcast 方案的局限性

在于需要提前获得确定的信道模型，而真实环境下的信道特性往往是不可预测的。近年来，深度学习技术在图像、语音压缩等领域的发展为 JSCC 的设计提供了新的思路。其中，自编码器作为神经网络的一种，经过训练后能尝试将输入复制到输出。自编码器内部有一个隐藏层，可以产生编码表示输入。该网络可看做由两部分组成：一个由函数 $h=f(x)$ 表示的编码器和一个生成重构的解码器 $r=g(h)$ 。在这种结构的启发下，近期有研究提出用深度神经网络代替传统编解码，设计端到端的信源信道联合编码结构 [43]。鉴于自编码器编解码器无监督联合优化的特点，可以考虑使用人工神经网络对信源压缩和信道编码进行联合设计，从而使通信系统达到端到端的最优性能。

具体的，文献[43]受无编码传输的启发，编码器完成信源编码+信道编码+调制的功能，解码器完成解调+信道解码+信源解码的功能，其系统模型如图 2-29 所示。该网络的编码器由 5 个卷积层+PRELU 激活函数的模块组成，解码器由 5 个转置卷积层+PRELU/Sigmoid 激活函数的模块组成。信道层作为不可训练层位于编码器和解码器之间。

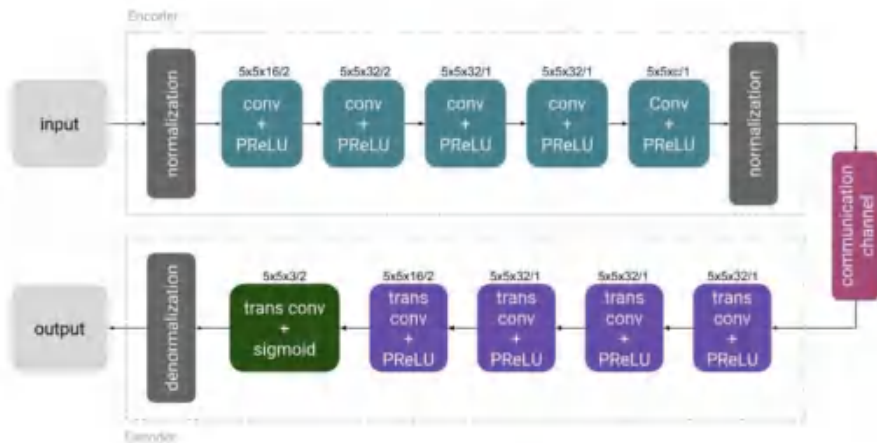


图2-29 基于AI的信源信道联合编解码方案的神经网络结构图

图 2-30 对比了 CIFAR10 数据集下评估了在不同的压缩比 (k/n) 条件下基于 AI 的信源信道联合编解码和 JPEG/JPEG200+方案的峰值信噪比 (Peak Signal to Noise Ratio, PSNR) 性能。该性能仿真表明：在恶劣的信道条件下 ($SNR=0dB$)，信源信道独立编码方案无法进行无差错传输导致译码失败，基于 AI 的信源信道联合编码方案的 PSNR 高于 20dB，可以较好地进行传输。在中 ($SNR=10dB$)、高 ($SNR=20dB$) 性噪比和有限的信道资源条件下， $k/n < 0.3$ ，基于 AI 的信源信道联合编码方案的性能也显著优于 JPEG 和 JPEG2000 方案。

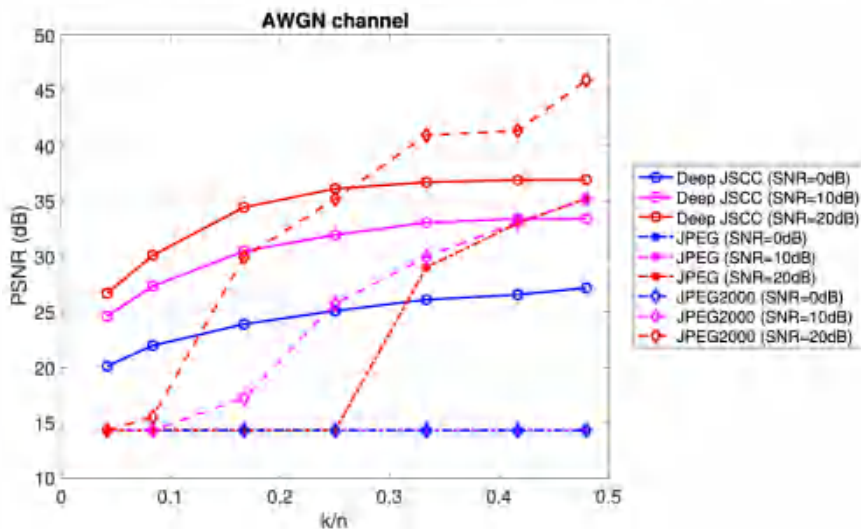


图2-30 基于AI的信源信道联合编码方案的性能

2.7 基于 AI 的 OFDM 接收机设计

由于无线信道的随机衰落、多径、干扰和噪声等因素的影响，传统的基于信号相干检测的接收机性能较差，误码率较高。因此面对 5G 及未来移动通信系统中越来越复杂的无线信道环境，设计误码率和复杂度更低的接收机，实现接收信号的高效检测至关重要。以传统的 OFDM 系统的接收机为例，其主要分为信道估计和符号检测两个模块。首先，利用接收到的参考信号与预先定义的参考信号序列，采用最小二乘法、最小均方误差等线性信道估计方法插值得到每个子载波的频域信道系数，并通过迫零和 MMSE 等信道均衡方法进行符号检测，得到估计比特流。采用如上的线性信道估计和检测方案，复杂度较低，但性能较差。而采用最大似然检测等非线性接收机算法，在多输入多输出（MIMO-OFDM）系统中，当天线数增加、调制阶数较高时，复杂度太高，难以应用。而基于 AI 的 OFDM 接收机设计，利用神经网络拟合接收机中的非线性映射，以最小化接收机的误比特率。同样也包括基于模型驱动的 OFDM 接收机和基于数据驱动的 OFDM 接收机。

基于模型驱动的设计中，利用神经网络对传统 OFDM 接收机中的部分模块进行替代或增强。通过设计合适的神经网络，可以有效降低接收机的误码率。基于模型驱动的 OFDM 接收机方法结构框图如图 2-31 所示。2.2.1 节中提到的去噪卷积神经网络 DnCNN 对接收信号 \mathbf{Y} 和估计信道 $\hat{\mathbf{H}}$ 进行去噪，能够显著提高信道估计准确度，进而降低接收机误码率。基于模型驱动的接收机对传统接收机进行分模块化增强，每个网络具有明确的物理意义，网络复杂度较低，参数集较小。但该方案受限于传统信道估计

算法和符号检测的性能。通常，信道估计利用参考信号和 MMSE 插值滤波得到所有时频位置的信道。当参考信号密度较大时，MMSE 信道估计性能较高；当参考信号密度过低时，MMSE 信道估计性能较差，因此基于模型驱动接收机性能也受限。

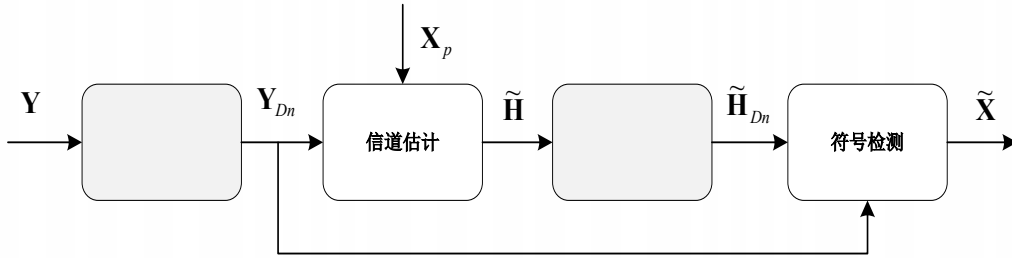


图2-31 基于模型驱动的OFDM接收机

接收信号 \mathbf{Y} 是由来自于有限固定集合的星座点经信道和噪声后得到的数据，因此接收机的设计可以等效处理为图像的分类识别问题。为解决基于模型驱动的 OFDM 接收机在参考信号密度过低时的性能问题，提出基于数据驱动的 OFDM 接收机，其结构框图如图 2-32 所示。这种接收机方案采用端到端的设计方法，输入为接收信号，输出为估计的发送符号。该方案中没有显式地信道估计与符号检测模块，所采用的 CNN 网络复杂度较高，参数集较大，但是能显著改善低参考信号密度下的接收机性能。



图2-32 基于数据驱动的OFDM接收机

2.8 基于 AI 的多天线收发技术

神经网络算法由于其强大的高维特征提取和表示能力在大维度的多天线技术领域中也受到了广泛的关注。深度学习辅助技术实现了离线学习过程，然后在线部署了经过训练的深度神经网络，不仅有效提取和表达了大维特征空间，与迭代算法相比，还大大降低了时间复杂度。因为训练后的网络仅包含简单的线性和非线性变换单元，所以它具有极低的复杂度和良好的性能。深度学习在混合预编码问题上的应用也由此受到关注。受致密全连通层启发，[113][114][115]中提出了多层感知器(multi-layer perceptrons, MLPs)。具体地说，在[113]和[114]中，MLP 仅用于单用户场景下预编码器的设计。在文献[115]中，MLP 结构被考虑用于协同波束训练，并假设完全信道信息是已知的。而在文献[116]和文献[117]中，基于不完全信道状态信息的鲁棒的深度学习

方案被提出。在文献[116]中，提出了一种基于卷积神经网络(CNN)的方法来解决联合预码器和组合器的设计问题。在文献[117]中，量化和非量化的 CNN 被用于混合预编码。此外，对于常见的多用户 MIMO 场景，文献[118]给出了基于深度学习的混合预编码器的设计方案，具有很高的实际意义。

2.8.1 基于 AI 的 MIMO 检测

早在 1994 年，就有学者提出基于 Hopfield 神经网络的码分多址制式 (code-division multiple access, CDMA) 通信系统下的多用户检测框架^[5]，但受到当时 CPU 计算能力的限制，进展缓慢，随着近年来深度学习领域的飞速发展和大规模 MIMO 技术在通信中的应用，研究者们提出了许多基于 AI 的 MIMO 检测方案。2017 年，耶路撒冷希伯来大学的学者 Neev Samuel 依据投影梯度下降法推导设计出了用于 MIMO 检测的深度神经网络 DetNet ((Detection Network)) [131][132]，并验证了其在时变和非时变信道下的性能，引起了学术界的广泛关注。仿真结果如图 2-33 所示，可以看出该算法在高斯信道条件下的 BER 性能及运算速度均优于现有的几种方法，包括迫零算法 (zero forcing, ZF)、近似消息传递算法 (approximate message passing, AMP) 和半定松弛算法 (semidefinite relaxation, SDR)。






图2-33 时变信道条件下各检测算法的误码率性能比较

文献[133]中提出了基于 DNN 的 BP 用户检测算法，通过对 BP 迭代过程的展开，分别设计了基于 Damped BP 算法和 Max-Sum BP 算法的 DNN MIMO 检测器，迭代相关的校正因子也在训练的过程中不断地更新优化。文献[134]提出基于 OAMP (Orthogonal AMP) 算法设计的 OAMPNet 检测网络，并对其在 Rayleigh 信道和基于指数分布的 Kronecker 模型下的小型空间相关信道下的性能进行了验证，在计算复杂度相似的情况下，OAMPNet 实现了比传统 OAMP 算法更低的 BER。



(a) 高斯信道下不同检测算法的 SER 性能比较



(b) 3GPP MIMO 信道下不同检测算法的 SER 性能比较

图2-34 MMNet算法性能

然而，DetNet、DNN-dBP 和 OAMPNet 的训练过程都是离线进行的，通过单一信道模型训练得到的网络难以适应实际的时变衰落信道。在这种情况下，文献[136]提出了一种支持在线学习的 MIMO 检测网络—MMNet，基于迭代软阈值算法（ISTA）理论，MMNet 利用信道在时域和频域上的局部化特性来加速网络的训练过程，使接收机可以根据实际的信道自适应地调整检测器的参数，MMNet 无论是在计算复杂度还是模型的鲁棒性上均超越了 DetNet 和 OAMPNet。各类算法在误符号率（symbol error rate, SER）上的性能对比如图 2-34 所示。

2.8.2 单用户毫米波 MIMO 混合预编码

文献[119]提出了基于深度神经网络的毫米波 MIMO 混合预编码方案，其主要的设计目标是，在保证最小化信道训练开销的基础上，通过最大化系统可达速率直接对混合预编码器以及合并器进行设计。文献[102] 利用 mmWave 信道的稀疏特性以及考虑到直达径（或路径增益最强的径）往往起主导作用，提出只需搜索出路径增益最强的径并使得波束形成向量（记作 \mathbf{f} ）与之相匹配即可，即只需要使得信道与波束方向乘积的模最大化。考虑到毫米波通信的特点，可以将波束形成向量离散化（即 \mathbf{f} 选自

于预先指定的码书)，相应地，混合预编码设计问题便转化为波束训练问题，如图 2-35 所示。

最优波束形成向量取决于信道环境，尽管信道环境不断变化因而最优波束也不断变化，但是信道环境或最优波束方向在相邻的两个时隙内的变化是有限的，因此无需搜索整个波束空间，只需搜索以前一时隙的最优波束方向为参考点的一个较小的局部范围。局部搜索范围的大小与信道环境变化模式密切相关，为了优化搜索范围以减小训练开销，文献[104]提出了波束指标差分技术及相应的学习算法。波束指标差分技术的核心是定义整数对 (a, b) ，其中 a 表示相邻两个时隙最优波束指标的偏移量，用于刻画信道环境变化的快慢程度， $b > 0$ 刻画需要进行局部扫描的波束子空间的大小。




图2-35 基于波束训练与跟踪的毫米波单用户混合预编码原理图

最优的波束扫描方案（即整数对）与环境相关，可通过使用交互式在线机器学习方法（即 Bandit Learning 方法）实现，而 Bandit Learning 方法的核心是定义行动空间和奖励函数。图 2-36 比较了不同算法的有效可达速率性能，Algorithm 1 和 2 基于波束指标差分技术并通过 Bandit-learning 实现，Bandit-learning 分别采用 贪婪搜索与置信区间上界（upper confidence bound, UCB）算法实现。由图 2-36 可以看出提出的算法可以获得接近理想算法（即 Oracle-Aided 算法，波束训练开销为零且获得最优性能）且远优于其他算法的性能。




图2-36 不同算法的有效可达速率性能比较

2.8.3 多用户毫米波 MIMO 混合预编码

多用户情况则更为复杂。文献[118]研究了基于 AI 的多用户毫米波 MIMO 系统混合预编码问题。基于不完全的信道状态信息，通过最大化可达速率来设计混合预编码器和合并器。具体的过程如下。首先解决混合预编码问题，得到训练数据样本标签，接着向网络提供不完全 CSI 来预测混合预码器与合并器。也就是说深度学习的网络提供了一种信道矩阵与预编码器之间的非线性映射关系。为了获得鲁棒的性能，在离线训练阶段向网络提供了一定比例的被噪声破坏的信道实现。因此，在测试阶段，当网络预测预码权重时，则不一定需要完美的 CSI。通过该方法能较好地处理信道矩阵损坏的情况，并实现较好的可达速率。

基于通信本质是与时变环境持续交互这一基本事实,文献[105]提出了一种基于智能交互式学习范式的毫米波多用户预编码算法如图 2-37 所示。相应的通信模型模块与自适应学习模块主要组成部分及作用如下: a) 通信模型模块主要由波束扫描模块和数字预编码器优化模块构成,主要任务是确定模拟与数字预编码器,其中模拟预编码器通过波束扫描的方式确定,而数字预编码器通过成熟的优化技术获得。由于波束扫描的范围与信道环境变化密切相关,因而由自适应学习模块提供。b) 自适应学习模块基于积累的历史经验信息实时预测最优波束子空间,由于最优波束子空间受到不断变化的物理环境的影响且不断变化,自适应学习模块必须能够实时感知环境变化的规律并从中提取所需要的概率统计信息。智能交互式学习范式可通过强化学习算法具体实现,核心是定义行动空间、状态空间及回报函数,行动空间可以通过波束指标差分技术实现[105],状态空间通过波束图像技术实现,回报通过求解相应优化问题获得。

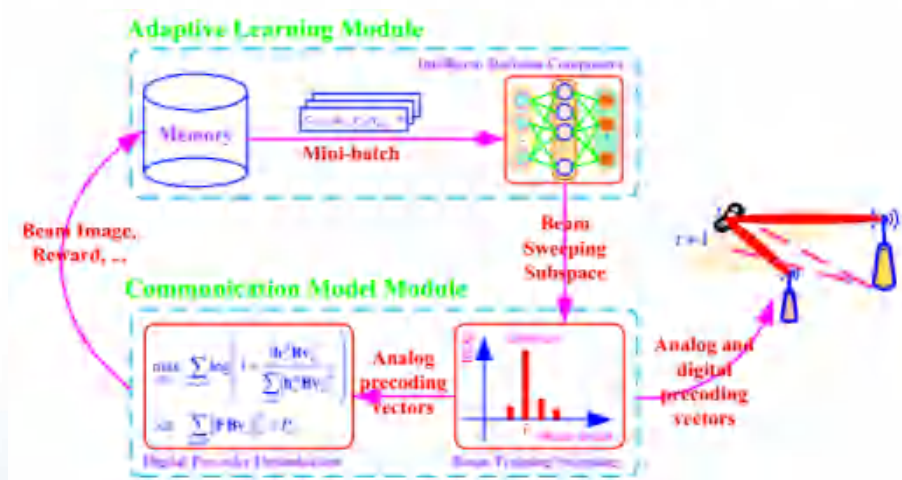


图2-37 基于智能交互式学习范式的毫米波多用户预编码算法

2.8.4 移动自适应协同波束成形

移动情况下的自适应波束成形也有学者开展了一些探索[115]。图 2-38 给出了所考虑的移动系统框图。

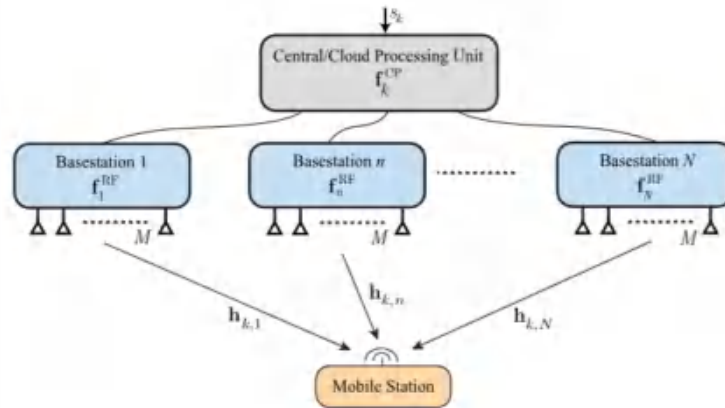


图2-38 毫米波协同波束成形系统框图

由于多个基站同时为用户提供服务，协同波束成型系统提供了抗阻塞的能力、多样性和鲁棒性，这直接提高了系统的覆盖率、可靠性和延迟性能。然而，该系统设计的主要挑战是实现高数据速率的要求，因为训练和设计 RF 波束成型的时间开销可能非常大，特别是对于高移动用户。基于这一动机，该方案着重于开发有效的信道训练和波束成型设计策略，以最大限度地提高系统的可达速率，并使高速移动场景下的 mmWave 应用成为可能。

直观上，波束训练的结果是一个关于环境设置(譬如用户/BS 位置，房间家具，街道建筑和树木等整个场景)的函数。然而，这些函数难以刻画，因为它们会涉及到很多的参数，且对于每种环境设置都是惟一的。因而文献[115]所提方案将深度学习模型与通信系统设计相结合，就是要学习波束训练结果与相关环境设置的隐式映射函数。该机器学习模型利用基站端接收到的全波束模式或准全波束模式的导频信号，预测出最优的射频波束成形矢量。这些在 BSs 接收到的导频信号是来自用户的传输信号与环境中不同元素相互作用的结果，通过传播、反射和衍射。因此，这些在不同的基站端联合接收的导频信号，刻画的是环境和用户/BS 位置的一个特征，也就是我们学习波束成形方向所需要的特征。该系统分为两个阶段运行，即在线学习和深度学习预测阶段。

(a) 如图 2-39 所示，在学习阶段，用户发送导频信号，基站端使用波束成形码本中的向量以及全向波束进行接收。因此，深度学习模型可以学习所有 BS 上联合捕获的 OFDM 全向接收信号与不同射频波束形成矢量带来的系统速率之间的隐式关系。

(b) 如图 2-40 所示，在预测阶段，系统依据训练好的学习模型，基于基站端接收到的全向信号来预测使得系统可达速率最大的最优波束成形矢量。

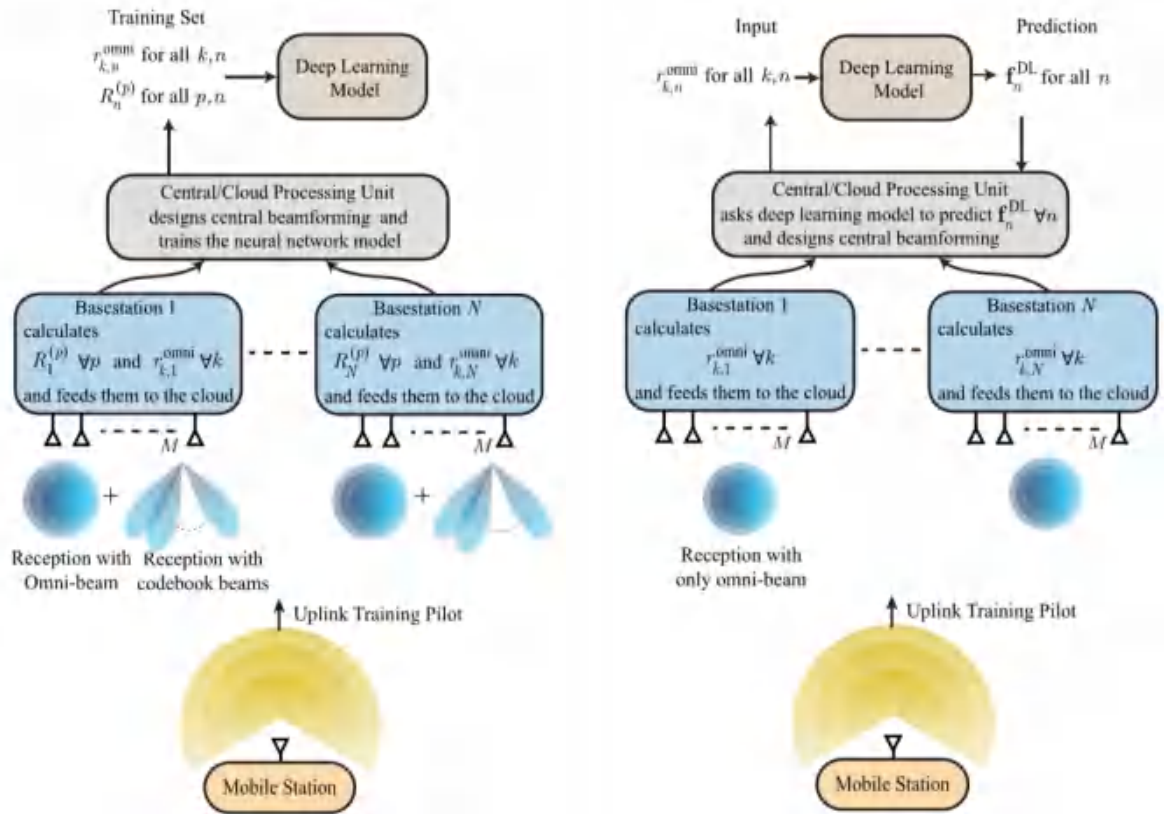


图2-39 (左) 在线学习阶段模型

图2-40 (右) 深度学习预测阶段模型

2.8.5 基于 AI/ML 的波束漂移抑制技术

现行的毫米波波束形成方案通常假设在给定的时隙中，信道路径的到达角/分离角是不变的，因此最优的波束方向也是不变的。但是由于用户不断移动等导致的信道环境快速变化，信道的到达角/分离角实际上是连续变化的，又由于实际波束的非理想性，已经对齐的波束的主瓣中心角很快偏离实际的信道方向，导致系统性能的下降，这一现象被称之为波束漂移。需要指出的是，即使环境变化极慢，波束漂移效应相对较弱，但只要发生波束切换，波束漂移效应便不可避免，因而为了获得更好的性能需要抑制波束漂移效应。在现行的技术方案中，当通过波束训练或其他方法估计出信道路径的到达角或分离角后，便基于估计的信道方向设计波束形成向量/矩阵进行数据传输，典型的方案是使用主瓣中心角匹配估计的信道方向的窄波束进行数据传输。这一方案忽略波束漂移效应会引起系统性能的下降，因而需要进一步优化波束形成方案。

由于波束漂移效应与环境变化密切相关，感知环境变化的快慢便成为抑制波束漂移效应的基础和关键。为了抑制波束漂移现象，文献[103]提出了如图0所示的通信方案，主要包括两个模块，即波束对齐/训练模块与数据传输模块。波束对齐/训练模块主要用于估计信道的方向，依据波束变化的局部性原理，即波束切换通常仅仅在以当前波

束为中心的一个较小的范围内，故可以使用窄波束进行波束训练以提高角度估计的精度。




图2-41 波束漂移效应抑制的方法原理图

数据传输模块设计的核心是感知信道环境变化的快慢，并结合估计的信道方向选择/设计适当的波束或波束子集进行数据传输，主要方法有两种：（1）依据感知的信道环境变化的快慢，自适应地调整数据传输波束的宽度，典型方法是使用多分辨率码书；（2）数据传输波束的宽度不变，但采用更高的频率进行切换，且切换的频率由信道环境变化的快慢决定。具体的实现方法是使用基于上下文的 Bayes Bandit 算法，核心是定义行动空间、状态空间和奖励等。图 2-42 提供了数据传输波束宽度固定方案（SCB）与为抑制波束漂移效应而设计的数据传输波束宽度自适应优化方案(BWO)的仿真性能比较，即采用第一种方法设计并通过多分辨码书实现。由图可以看出由于能够有效地抑制波束漂移效应，与波束宽度固定的方案相比，波束宽度自适应的方案可以获得更好的有效可达速率性能。




图2-42 有效可达速率-数据传输波束宽度固定与自适应优化

2.8.6 基于 AI/ML 的波束跟踪技术

虽然波束成形可以增强用户端的信号强度，提高覆盖，但前提是波束方向需要和目标用户对准。这一点需要通过波束训练实现。一旦波束的指向偏离用户，用户反而

接收不到高质量的无线信号，可谓是差之毫厘，谬以千里。在移动通信场景下，用户移动与随机遮挡导致信道时变，需要反复的进行波束训练获取实时准确的信道信息；但是工作在毫米波和太赫兹频段的大规模天线阵列规模较大，传统穷举式的波束训练方式会产生巨大的导频开销。因此常采用波束跟踪辅助波束训练的方式。根据信道的时变规律，以低开销快速的获取信道信息，大开销的波束训练仅在追踪失败后重新开始。可以说，快速高效的波束跟踪算法是保证移动通信质量的关键。

波束跟踪的关键在于精准的信道预测，对信道如何随时间变化进行一定的预测，以预测的结果作为先验知识，进行波束跟踪。为了减少训练开销，一个可行的方法是从以往的波束训练中提取和利用信息，以减少波束搜索空间，并为以后的训练做准备。这种想法和机器学习相结合，产生了基于 ML 的波束训练算法[122][123][124]。但是这些方法都是基于监督学习，事先需要大量的数据做神经网络的训练。最近，文[125]提出出来基于强盗测试算法（Bandit learning）的波束跟踪算法[125]：该文将波束跟踪建模为一个随机 bandit 问题。为了感知环境的变化，利用最优波束序号的偏移，提出了基于 Bandit learning 的波束跟踪算法。该算法针对基于码本的波束跟踪。波束成形的预编码取自一个预先设计的码本，一般该码本的码字是按照角度排列的 DFT 向量。

2.9 基于 AI 的多用户接入技术

随着设备数量的爆发式增长以及大规模 MIMO 系统的广泛应用，传统的多接入技术无法满足大规模设备的接入要求，非正交接入技术通过对时、空、频和功率等多个维度资源的复用，可以保证用户的接入性能，同时也使得多用户检测的计算复杂度问题变得极具挑战性。传统的压缩感知（compressed sensing, CS）方法虽然能利用稀疏性减少复杂度，但其性能和复杂度还有很大的改进空间。基于深度学习的多接入技术[126]是近年来 AI 在无线通信中应用的研究热点之一，国内外众多研究机构均对该方向开展了深入探索，相关工作集中于依据各类信号检测算法的特性设计神经网络，以实现智能化的多用户检测、用户活动性（用户激活）检测[2-4]、多用户 MIMO 检测[5-11]或多用户干扰分离[137]，提高检测性能的同时极大地降低了计算量。

如前文所述，基于 AI 的多接入技术可分为模型驱动方法和数据驱动方法。模型驱动方法的网络结构由可训练变量的迭代算法设计而成，学习时使用现有算法的结果作为初始起点，并基于反向传播算法优化变量，如智能用户活动性检测网络 DNN-MP-BSBL[127] 以及前文提到的智能 MIMO 检测网络 DetNet[131] 和 OAMPNet[134]。而数据驱动方法的网络学习过程是模型不断拟合现实数据的过程，

如智能用户活动性检测网络 D-AUD[128]和 BRNN[135] 以及智能 MIMO 检测网络 DNN-dBP[133]和 MMNet[136]。




图2-43 基于AI方法的多用户接收机

针对非正交接入（non-orthogonal multiple access,NOMA）系统中的多用户干扰问题，华为使用 AI/ML 方法设计了如图 2-43 所示的多用户接收机[46]，其性能优于传统接收机。

2.10 基于 AI 的活跃用户检测

在物联网场景下的免授权随机接入系统中，基站需要进行用户活动性检测来使识别有哪些用户处于激活状态，以便后续对传输数据进行解码，确保基站和用户之间的有效通信，因而其检测的准确度大大影响着系统的整体性能。

目前有关活跃用户检测算法的大量研究仍是基于传统的压缩感知算法进行改进，性能提升非常有限。为克服传统压缩感知算法的技术限制，解决大规模免授权接入系统的活跃用户检测问题，国内学者在深度学习的基础上构建了 LDS-OFDM（Low-density signature-OFDM）系统的活跃用户检测（active user detection, AUD）与信道估计（channel estimation, CE）方案，根据基于块稀疏表示的贝叶斯学习算法设计了 DNN-MP-BSBL（deep nneural network-aided message passing-based block sparse

bayesian learning) 框架[127]。该算法迭代一次的神经网络结构及其每层实现的操作如图 2-44 所示。

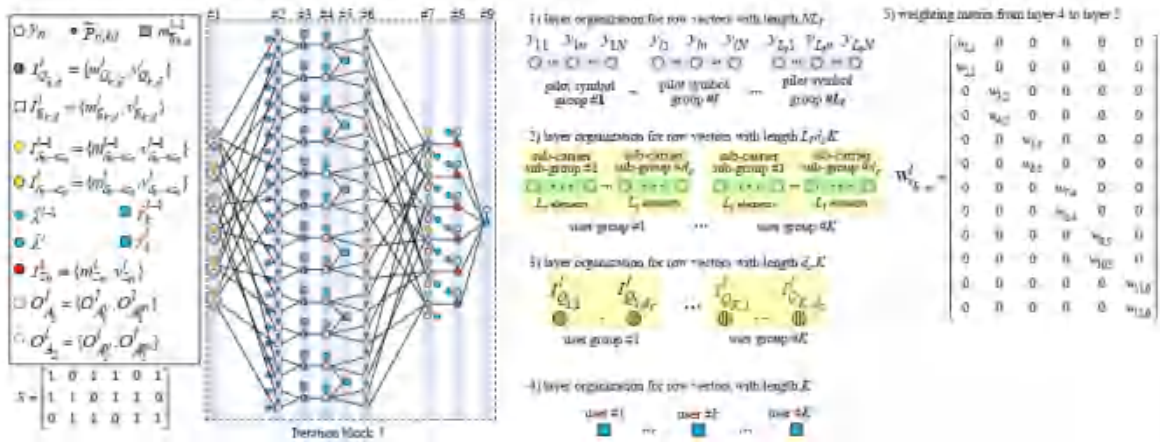



图2-44 DNN-MP-BSBL结构 (N = 3; K = 6; L_r = 2; d_c = 2)

由网络结构可知，DNN-MP-BSBL 将消息传递的迭代过程从因子图转移到神经网络中，因此促进算法收敛的同时也提高了检测结果的准确度。



(a) 不同过载因子下 AUD 成功概率比较 (b) AUD 成功概率随活跃用户数目变化曲线

图2-45 D-AUD与传统检测算法性能比较

DNN-MP-BSBL 解决的是联合 AUD 和 CE 问题，针对 AUD 问题，近期，精通压缩感知理论的韩国学者 B.Shim 的团队提出了基于 AI 的上行链路免授权 NOMA 系统的活跃用户检测方案—D-AUD (deep active user detection) [129]。利用某一个时刻活跃用户的稀疏性，活跃用户检测问题可以转化为支持向量检测的问题，并用神经网络直接学习接收信号到活跃用户索引集合间的映射关系。D-AUD 的训练是监督学习的过程，基于人工生成的大量训练数据，网络最终能收敛到一个较为稳定的状态。从 1.1 中可以看出，在不同的过载条件下 (过载因子=用户数/子载波数)，D-AUD 的活跃用户检测成功率均明显优于传统的 LS-BOMP、MMSE-BOMP 和 AMP 算法，尤其是在

过载因子较大的时候，传统算法由于感知矩阵的欠定程度严重，性能也急剧恶化，而 D-AUD 则在过载因子增大和活跃用户数目增多时表现出了较强的鲁棒性。

2.11 基于 AI 的定位技术

目前，消费者市场，比如商场导购、停车场反向寻车、家人防走散、展厅自助导游等，垂直行业，如人流监控和分析、智慧仓储和物流、智能制造、紧急救援、人员资产管理和服务机器人等，都对定位服务提出了更高精度的需求。总之，高精度定位是未来智能生活和智能工厂普及化的基石。然而，在很多应用场景中，多径,NLOS, 室内覆盖和同步问题都是实现高精度定位难以跨越的障碍。3GPP 在 NR Rel-16 标准中引入了多种定位方法，包括基于时间测量的方法和基于角度的方法。之后，3GPP 在 R17 通过定位增强的立项，旨在满足消费者市场和企业市场的高精度位置服务需求。3GPP NR Rel-17 标准的应用场景主要是商业场景以及 IIOT 场景。精度要求非常高，最高达到分米级。

特别是在 IIOT 场景，水平方向要求定位精度小于 0.2m。然而，目前经典的定位算法，比如 TDOA 算法，比较依赖场景中的 LOS 基站个数，当 LOS 基站的个数少于 4 个时，定位的精度一般都很难达到要求，而在 IIOT 某些场景中，LOS 概率都是比较小的。因此很难达到 0.2m 的定位精度要求。比如 DH（3GPP 仿真场景之一）在各种参数配置下的 LOS 概率如图 2-46。




图2-46 不同场景下LOS的概率

也就是说在 InF-DH 和 InF-DL 下，最多只能保证 1-2 个 LOS 基站，在这种情况下，定位的精度误差一般在 16m 以上。因此需要进一步研究新的定位算法，比如利用 AI 的高效的特征提取功能，来提取基站到用户信道测量信息的抽象特征，可能会对上述问题带来重大的突破。利用神经网络的非线性优势，可借助所有信道测量信息，包括非直射径的信道信息进行特征提取并训练，达到更高的定位精度要求。

2.12 小结

截止目前，AI/ML 技术已经被研究应用到无线物理层的方方面面，这包括无线环境建模与感知、信道估计、预测与反馈、端到端的设计、信道编译码、用户接入检测等等。初步的研究结果表明，AI/ML 技术在无线物理层方面具有独特的优越性。例如，通过 AI 可以实现多维特征信息的感知与融合，从而实现基于 AI 的精准感知定位，对比传统的经典算法（十几米定位误差），AI 定位的精度达到了分米级；在信道估计方面，AI 使能的技术，在各种场景下达到接近基于完美信道估计的表现，并优于传统的信道估计方法。但是随着深度学习在无线通信物理层研究中的逐步应用，深度学习在无线物理层技术方面已经有了一定的突破。与传统的模型驱动的物理层技术相比较，基于深度学习方法在信道估计、反馈、接入等方面的性能上有显著的改善，但同时由于维度爆炸，深度学习应用于编码技术、环境重建、接收机设计等方面也存在一定的局限性。

第三章 基于AI/ML的链路层技术

未来无线通信系统将由不同的接入制式，多样的网络部署方法和混合异构网络共同组成，旨在实现数据传输速率、网络覆盖率和可连接设备数量等方面的大幅提升以及网络时延和设备能耗的持续降低。在未来无线通信系统中，无线资源分配以及系统内部与系统之间的干扰协调是业界关注的一大研究热点。面对状态多变、架构复杂的未来网络，传统模型和算法难以提供高效可靠的技术支撑。基于人工设计的传统的资源管理方法将很难满足日益苛刻的通信服务质量需求。同时，下一代无线网络期望更多地考虑用户环境以及行为特征，从而提供更高质量的个性化的通信服务[11]。为解决这些问题，面向下一代无线网络的资源管理方法亟需理论和范式上的创新与突破。

另一方面，基于 AI 的最优控制方法在近几年有着迅猛的发展，其中最主要的发展方向为强化学习。强化学习能够通过与环境的交互，学习环境特征，从而自适应地实现最优决策。特别是深度强化学习（deep reinforcement learning, DRL），能够以极低的计算成本智能地处理复杂系统的最优控制问题[12]。不同于传统模型和算法，AI 技术对复杂多变的网络环境和网络结构具有很好的适应性，并且能从已有数据和先验信息中提取出未知特征以推演出高效的资源调度和干扰协调方案。由此，应用先进的 AI 技术解决异构无线资源调度和干扰协调问题逐渐发展为无线网络技术研究中一类新兴的研究手段。基于强化学习的无线资源管理作为当前的研究热点，得到国内外诸多著名研究团队与企业的推进和发展[13-23]。目前，在频谱资源分配[13]，车联网[14]，无人机通信[16]，绿色通信[17]等诸多方面，已有较为成熟的研究成果。这些研究成果表明，相比基于人工设计的传统方法，基于强化学习的无线资源管理在计算成本与服务质量上的表现均有提升。在无线通信干扰协调、资源调度（包括功率分配、信道分配、接入控制）和集中式分布式架构方面，AI 已经有了各种研究和应用。

3.1 基于 AI 的功率分配

文献[148]中，作者考虑了由单个 MBS 和若干个 SBSs 构成的混合供能异构网络，基站可以消耗传统电网的能量也可以消耗可再生的新能源。由于在移动环境中准确和完整的环境模型是未知的，论文构建了基于无物理模型（model-free）的强化学习模型用于指导网络的用户调度和能源分配，最大化系统的能量利用率。具体的，作者提出利用参与者-批评者(actor-critic)强化学习算法来得出最优随机策略。其示意图如下：




图3-1 Actor-critic 强化学习框架

该算法由于结构特征具有收敛性。仿真结果证明当网络提供更多的可再生能源时，所提出的算法可以提高资源利用率。文献[150]中，作者提出一种分布式 model-free 强化学习算法实现所有发送机的加权效用和最大化目标。具体的假设信道 CSI 的随机变化和延迟都是固有的，每个发送机收集邻居的 CSI 和 QoS，采用深度 Q-learning 决定自身的发送功率。论文提出的算法可以得到一个相比于集中式算法更快的次优算法。

文献[155]在进行功率分配的同时，考虑了信道间存在干扰，并基于此提出了一种基于 Q-learning 的功率分配策略。该策略根据所观察到的无线电环境状态和干扰功率以及描述每个状态作用对的折扣长期回报的质量函数或 Q 函数来选择发射功率。该方案在不考虑信道模型和干扰模型的情况下，在 MIMO NOMA 动态抗干扰博弈中推导出多用户最优策略。

3.2 基于 AI 的信道分配

文献[151]研究了毫米波超密集网络中的频谱管理问题，并将时空复用作为提高频谱利用率的一种方法。作者将频谱管理问题归结为设备间的非合作博弈，证明了该问题是一个保证纳什均衡 (nash equilibrium, NE) 存在的一般潜在博弈。为了帮助设备在没有全局信息的情况下实现 NE，作者设计了一种新颖的分布式 Q-learning 算法，使得设备能够从个体奖励中学习环境。每个设备的动作和回报分别是信道选择和信道容量。经过分析得出学习主体间的耦合有助于加速学习的收敛。仿真结果表明，该方案比多条对比基准线收敛更快、更稳定，且延迟小。

不同于已有工作中直接利用经典的强化学习方法，文献[152]则设计了一种全新的包含递归神经网络的强化学习方法来处理 LTE-U 系统中许可和未授权频带的管理。该问题被描述为一个以 SBSs 和 MBS 为博弈参与者的非合作博弈，且每个 SBS 已知的

网络信息有限。为了实现混合策略的 NE，提出了一种基于回声状态网络(echo state networks,ESNs)的多智能体强化学习方法。与传统的 RL 方法相比，该方法可以在不需要太多训练数据的情况下快速地学会分配资源。在算法执行过程中，每个 BS 只需要广播当前所采取的动作及其最佳动作。仿真结果表明，与 Q-learning 相比，该方法下第 50 百分位用户的速率总和提升达到 167%。

在部署异构网络时，干扰是实现高频谱效率的最大限制因素之一。文献[156]研究了一个异构网络中的多目标、频谱访问问题，旨在实现 QoS 约束下同时最小化在微蜂窝处接收的帧内/层间干扰以及从微蜂窝到演进基站（evolved node B, eNB）的层间干扰。由于缺乏全局完整的信道信息，节点数量未知等因素，作者提出了一种基于联合效用和策略估计的强化学习方法，该方法包含两个序列层次，第一级的目的是为飞蜂窝识别可用的频谱资源，第二级负责资源的优化选择。仿真结果表明，该方法使得层内和层间干扰的显著减少，从而实现更高的小区吞吐量。文献[147]提出了一个基于机器学习的多无人机管理框架减轻无人机小区之间的干扰，旨在保证地面用户所需的数据率的同时，最大限度地提高无人机小区的能源效率。该框架的关键技术包括用于控制发射功率的亲邻传播干扰管理（APIM）方案和用于位置重排的 K-means 位置调整方案。与已有的方案相比，该方案减少干扰并提高 25% 的能效。

3.3 基于 AI 的接入控制

接入控制的本质是复用，根据资源复用时是否有可能会发生碰撞冲突,我们将接入控制分为无冲突的调度和基于竞争的随机接入。文献[15]提出了一种基于深度 Q-learning（deep Q-learning, DQL）的物联网传感器的动态信道接入方案。在每一个时隙，传感器选择 M 个信道中的一个来传输它的数据包。信道状态低干扰，即表示成功传输，反之高干扰，代表传输失败。由于传感器在选择了通道后只知道通道状态，因此传感器的优化决策问题可以表述为部分可观察马尔可夫决策过程。文献[154]中则考虑了一种多传感器场景，并使用 DQL 处理联合信道接入和包转发。该模型如图 3-2 所示，其中一个传感器作为中继，将从邻近传感器接收到的数据包转发给接收器。该传感器装有缓冲区以存储所接收的数据包。传感器在每个时隙中选择一组信道进行数据包转发以最大化其效用，即传输数据包的数目与传输功率的比率。本文证明了传感器的效用函数是有界的，保证了算法的收敛性。




图3-2 物联网中的联合信道接入和包转发

尽管调度可以完美规避冲突，但其需要预先设计策略，导致自适应能力与可扩展性较差。相反，基于竞争的随机接入算法往往无需中心控制节点或者少量中心控制信号，通过精巧设计的分布式算法实现在复杂网络环境中的接入控制。文献[158]中，作者提出了一种基于学习的二进制指数回退算法，用以解决无线局域网内的冲突问题。不同于传统回退算法中随机选择后退时长，新算法会根据上一次成功发送选取固定值，进而可以有效减少冲突的发生频率，提升整体性能。文献[21]中，作者引入隐马尔可夫模型（hidden Markov model, HMM），并通过对频谱参数的学习，解决了次级用户接入空闲频谱资源的冲突问题。相比较次级用户而言，初级用户的突发传输会导致频谱检测误差大大增加，并严重影响次级用户随机接入的成功率。作者通过对初级用户的特征建立 HMM，设计了一种信道学习算法，可以有效的识别出初级用户的传输模式。

3.4 基于 AI 的链路调度

文献[150]研究了在密集部署的无线网络场景下无线调度问题，利用空间深度学习，对具有全频率复用的多个干扰链路提出了最佳调度的解决方案。针对此问题的经典优化方法通常有以下模式：首先估算所有干扰信道强度，然后使用该模型找到最佳解决方案。然而，传统的调度方法是计算密集的，尤其是在密集网络中，信道估计成本很高，并且链路调度的优化通常是非凸问题。研究人员采用一种深度空间学习方法来解决调度问题。完全绕过信道估计阶段，并使用深度神经网络仅基于网络中发送器和接收器的地理位置来产生接近最佳的调度。使用神经网络架构将受干扰的节点和相邻节点的地理空间卷积作为多个反馈阶段的输入，以学习最佳解决方案。

用地理位置信息（GLI）替代每个发射机和接收机的信道状态信息作为神经网络的输入，将问题的复杂度由 $O(N^2)$ 变成 $O(N)$ 。将一个网格区域的连续变量离散量化发射机和接收机的网格密度作为输入。其相比传统方法的优势在于通过使用地理空间卷积来估计每个链路周围的干扰邻居的密度以及用于逐步调整链路活动模式的反馈结构。深

度神经网络实际上可以学习网络干扰拓扑并仅根据地理空间信息就可以执行调度到接近最佳状态，从而省去了昂贵的信道估计阶段。

3.5 基于智能体(smart agent)的无线资源调度

AI/ML 方法中的 RL 算法可以通过智能体与环境交互，动态调整自身的决策策略，获得最优的期望收益。它无需对系统进行显式建模，因此非常适合用于解决复杂通信系统中的参数选择、跨模块联合优化、跨层资源分配和决策类任务。

现有工作中体现的 RL 对空口的影响主要体现在将其用于解决功控、调度、资源分配等决策类任务时，空口参数的优化配置。例如，文献[47]使用 DRL 方法解决车辆到基础设施（vehicle to infrastructure, V2I）场景下设备调度问题，通过控制设备开启和休眠，使得系统在满足 QoS 需求的情况下延长路边单元的电池使用时间。文献[48]使用 DRL 方法实现 IoT 设备的调度，在不影响正常语音业务的情况下，最大化 IoT 业务的吞吐。文献[49]联合优化了调度和内容缓存策略。文献[50]则在给定功率限制下优化用户的上行调度流程，最大化系统的上行吞吐。文献[55]的作者尝试使用 DRL 方法解决蜂窝网络用户调度问题。考虑了两种流量模型，其中全缓存（full-buffer）流量模型下，可以通过优化算法得到问题的最优解；而非全缓存（non-full-buffer）流量模型下，最优解则无法显式获得。




图3-3 基于DRL的full-buffer场景用户调度

对于 full-buffer 流量模型，文献[55]基于 DRL 框架，提出了如图 3-3 所示的三种学习方法。由于比例公平（Proportional Fair, PF）调度策略在该场景下为最优方案，因此将 PF 调度策略作为专家知识训练智能，可以达到最优性能且收敛速度较快。当专家知识难以获取时，则可以采用对偶学习的方法，使用两个智能体互相学习互相促进的方式，防止算法像直接学习一样落入局部最优。对于 non-full-buffer 流量模型，无法获得显式的最优算法。文献[56]使用 DRL 方法，结合 n 步回退、熵正则化、动作掩码（masking）等训练方法，可以得到优于现有算法的性能：在不损失公平性的情况下，

实现吞吐的提升和丢包率的下降。作者还将在单 RBG (resource block group) 条件下训练的智能体用于多 RBG 场景的调度推理, 同样可以获得类似的优于传统算法的性能, 这说明了这种方法的泛化性能有一定保证。

基于智能体解决无线资源调度问题时的另一个挑战是通信系统的高度动态性, 参与调度的用户数随着时间变化, 这就要求智能体可以处理不同用户数的调度问题而无需频繁重新训练。为此, 文献[230]提出了一种可扩展的神经网络设计方法, 用于基于策略的 advantage actor-critic (A2C) 架构, 解决高动态用户数可变场景下的无线资源管理问题。如图 3-4 所示, 同一个策略网络被重复使用 K 次 (K 为参与调度的用户数量), 用以处理用户设备的每一个状态; 价值网络则只被使用一次, 用以处理所有用户设备的平均状态。所有用户设备共享同一个策略网络。用户设备的数量值只影响策略网络的使用次数, 这称为用户调度的置换不变性。结合离线训练, 在线推理方法, 该方案可以进一步加快智能体的部署流程。

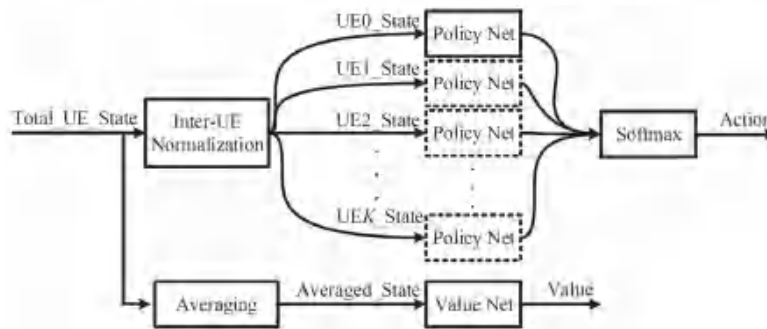


图3-4 可扩展的神经网络设计




图3-5 深度强化学习算法性能

图 3-5 刻画了在单蜂窝、5 用户设备、单蜂窝、50 用户设备、3 蜂窝、每个蜂窝 10 用户设备三种场景下可扩展神经网络的性能。相比于传统的 PF 调度算法, 基于深度强化学习的调度算法可以在几乎不损失公平性的前提下达到更高的吞吐量和更低的

丢包率。相同的神经网络设计用于不同场景可以获得类似的性能增益，体现了基于强化学习方的资源调度的有效性和可扩展性。

当考虑多个小区的联合资源分配问题时，则需要使用多智能体 RL (multi-agent RL, MARL)。根据多智能体的实现方式不同，可以将这些工作大致分为两类。

第一类工作中，多个智能体采用各不相同的神经网络参数。这些智能体在同一个环境中进行训练，它们各自的决策需要考虑其他智能体可能的动作情况，同时会对其他智能体产生影响。例如文献[51]基于 MARL 中常用的单 critic 网络+多 actor 网络结构解决异构网络中的功控问题。中心式的训练过程中，中心 critic 网络可以获得全局信道，多个 actor 被部署在多个网络 AP 上，各自根据 critic 的指导和本地信息进行训练。文献[52]中，各用户基于深度 Q-learning 网络 (deep Q-learning network, DQN) 训练自身的智能体，完成 AP 关联和资源分配。

另一类工作中，多个智能体使用相同的神经网络结构和参数。不同智能体从本地局部环境中收集的经验增加了神经网络的训练样本，帮助网络更快收敛。训练好的神经网络也可以直接下发给新入网的智能体，解决了扩展性问题。文献[53]使用这种方法解决了物与物 (device-to-device, D2D) 场景中的功率分配问题。文献[54]则用于解决蜂窝网络多小区联合调度和功控问题，建模过程中，考虑系统状态收集和交互的时延，即智能体智能通过一些过期的信息进行决策。

利用智能体/多智能体技术，完成参数配置、跨模块优化、资源分配等任务一直是研究的热点和方向。

3.6 基于 AI 的网络切片无线资源分配

基于 AI 的网络切片无线资源分配大规模机器类型通信 (mMTC) 被认为是未来数字世界的革命性技术之一，可在当前的 5G 和即将到来的超越 5G (B5G) 网络中实现广泛的应用，包括工业自动化、智能交通、智能电网等。随着众多具有多样化 QoS 需求的 MTCD 接入网络，传统的面向 HTC 的蜂窝网络面临着巨大的挑战。

第一个关键挑战源于不同 mMTC 应用程序的差异化 QoS 要求。在多应用共存的 mMTC 网络中，不同应用在时延、可靠性、移动性、能耗等方面对服务质量 QoS 的需求是不同的。此外，支持这些应用程序的底层协议可能非常不同，例如设备的激活周期、帧大小、前导码格式等。然而，在传统的网络架构下，物理设备与网络中的业务高度耦合，无法为不同的 mMTC 应用提供差异化的服务。mMTC 的另一个主要挑战是来自这些 MTCD 的大量访问请求。在 RA 过程中涉及的资源中，有两种资

源会限制大量 MTCD 接入请求时系统的性能:即用于识别发起 RA 请求的 MTCD 的前导码资源和为物理下行链路控制信道 (PDCCH) 保留的 RB 资源。中国电信提出“6G 多维信息感知的无线 AI 技术”,通过场景与业务的深度感知,进行网络业务协同优化,实现深度感知的智能无线资源管理。中国电信联合电子科技大学设计基于网络切片的 mMTC 智能接入控制与资源分配机制和控制信道资源分配机制。

具体而言为了克服上述 mMTC 随机接入上的述挑战,我们将网络切片引入 mMTC,并提出了一个支持网络切片的 RA 框架。借助网络软件的可编程性、灵活性和模块化等特点,可以为不同的 mMTC 应用提供细粒度差异化的服务。此外,通过引入网络切片,可以将具有海量 MTCD 的单个庞大的物理网络切分为多个独立的轻量级网络切片,每个切片内只接入原 MTCD 集合的一个子集,从而减少了冲突域,使得每个网络切片内的冲突概率大大降低,从而可以有效地减少随机接入时延。

然而,虽然每个网络切片内的冲突域减小了,但可用前导码和 PDCCH RB 资源也减少了,因为网络切片的资源是从物理网络中分割出来的。因此,与禁用网络切片的解决方案相比,冲突概率和访问延迟的降低并不显著。为此,我们提出了一种支持网络切片的 mMTC 随机接入框架,该框架结合了切片前导码 (sliced Preambles, sPreambles) 的概念和基于 Actor-Critic 的 RB 资源共享方案。一方面, sPreamble 的引入显着扩展了每个网络切片中可用的前导资源,从而有效地降低了冲突概率和接入延迟。另一方面,我们提出的基于 Actor-Critic 的 RB 资源共享方案可以实现网络切片之间 PDCCH 资源的智能复用,从而有效地提高它们的接入能力。如图 3-9 所示,与传统的贪心算法(每条业务流选择满足约束条件的最大路径带宽)、固定分配算法(业务流保持初始状态不变,即不采取 重新配置)和随机分配算法(随机分配路径带宽以及节点 VNF 实例处理资源)相比,基于 AC 的重配置算法可以有效地提升用户的效用增益约为 30%,同时可以有效地提升资源的利用率约 40%。




图3-6 面向业务流的网络切片资源分配仿真结果

3.7小结

初步研究表明，AI 技术对复杂多变的网络环境和网络结构具有很好的适应性，并且能从已有数据和先验信息中提取出未知特征以推演出高效的资源调度、功率分配与干扰协调等方案。目前，AI 技术在频谱资源分配、无线通信干扰协调、功率分配、信道分配、接入控制、链路调度、智能体资源调度、切片资源管理等方面已有较为成熟的研究成果，例如相比基于人工设计的传统方法，基于强化学习的无线资源管理在计算成本与服务质量上的表现均有提升。因此，应用先进的 AI 技术在解决异构无线资源调度、功率分配、线路控制、干扰协调等问题逐渐发展为无线网络技术研究中一类新兴的技术手段。尤其是基于强化学习的无线资源调度与功率分配方面具有很大的研究空间与发展潜力，且有望在不久的将来替代基于人工设计的传统方法进行无线资源管理，协助无线网络智能地学习和自适应地决策。

第四章 基于AI的网络上层技术

AI 在无线通信网络的应用层和网络层主要有两方面的应用。首先，它们可以用于预测、推理和大数据分析。在此应用领域，AI 功能与无线网络从其用户、环境和网络设备生成的数据集学习的能力有关[138][139][140][141]。例如，AI 可以用来分析和预测无线用户的可用性状态和内容请求，从而使基站能够提前确定用户的关联内容并进行缓存，从而减少数据流量负载。在这里，与用户相关的行为模式（如移动方式和内容请求）将显著影响缓存哪些内容、网络中的哪个节点以及在什么时间缓存哪些内容。第二，AI 在无线网络中的另一个关键应用是通过在网络边缘及其各网元实体（如基站和终端用户设备）上内嵌 AI 功能来实现自组织网络操作。这种边缘智能是资源管理、用户关联和数据卸载的自组织解决方案的关键促成因素。在这种情况下，AI 可以学习环境，并随着环境的变化采用不同的解决方案，使得设备自主决策成为可能，从而实现网络智能化。

4.1 基于 AI 的无线网络架构

未来网络演进的目标是通过人工智能的引入实现网络的自主决策和自主演进，达到无人自治的完全智能化网络。对现有 5G 架构，应尽量将影响降低至最小化，尽量不引入新增接口，并且能够实现和当前 RAN 的兼容和共存。此外，还需在研究中考考虑到人工智能相关数据在接口上的安全性要求，保证人工智能相关数据传输的健壮性和可靠性。基于 6G 网络的无线人工智能架构在设计时，不仅需要考虑后向兼容，即兼容基于 5G 网络的无线人工智能架构，还需要适当地考虑前向兼容，即在包括 6G 在内的未来网络中运行人工智能时，避免因未来网络演进而产生各层网元设备无法实现相关功能而进行大量改动。具体来说，未来的无线人工智能架构至少需要满足如下需求：

1. 大量不同类型数据的统一化获取、预处理、管理、共享、存储以及安全传输。
2. 增强接口功能，能够实现节点间人工智能功能的开启与关闭、人工智能模型获取和测量结果报告。
3. 能够根据应用场景和用例需求选择不同的人工智能训练模型，包括监督学习、非监督学习、强化学习等，并可以确定对应的输入与输出。

4. 支持不同应用的统一化架构，包括节能、负载平衡、资源分配、移动性管理和覆盖范围优化等。

5. 人工智能功能边缘化，从边缘获取数据后可以利用边缘资源进行实时化决策制定，提高系统能效并减少数据传输带宽需求，满足变化快、实时性较高的业务控制需求。

根据上述需求，未来的无线 AI 架构的实例图之一如图 4-1 所示：

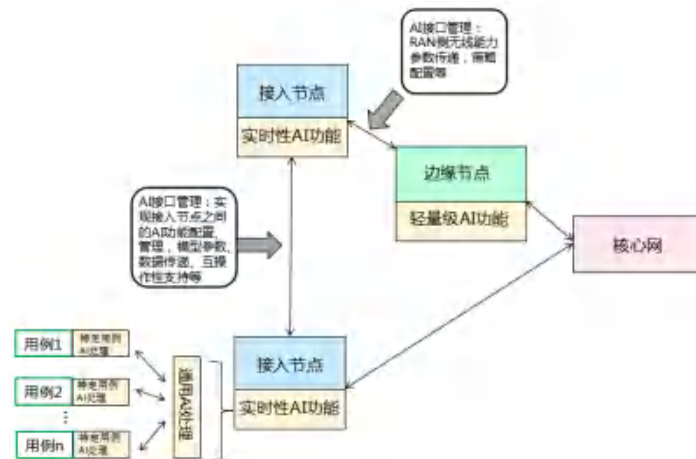


图4-1 无线AI架构

具体而言，接入节点对算力需求比较低，需要处理的数据量较小，重点实现网元级人工智能策略的执行，提供实时性 AI 处理能力。同时，需支持接入节点之间的人工智能互操作性，实现分布式的 AI/ML 算法。边缘节点实现轻量级 AI，运行轻量级的机器学习模型，具有一定的计算和决策的能力，以满足敏捷连接、实时业务、安全与隐私保护等方面的需求。RAN 侧的人工智能功能从层次上来说分为：通用 AI 处理和特定用例 AI 处理。通用 AI 处理包括根据特定用例进行的模型选取和调用、底层软硬件资源的统一分配和算力编排等。特定用例 AI 处理包括：针对特定用例（移动轨迹预测、Massive MIMO 增强等）进行数据规范化处理和智能分类等。

4.2 基于 AI 的传输层拥塞控制技术

传输层拥塞控制技术作为网络领域最重要的技术之一，对于提升网络效率和降低时延起着至关重要的作用。最早拥塞控制是从传输控制协议(transmission control protocol, TCP) 开始的，TCP Tahoe 于 1988 年由 Jacobson 提出，是最经典的传输层拥塞控制算法，引入了慢启动和拥塞避免，快速重传等机制。后来 TCP Reno 引入了快速恢复机制。TCP new Reno 维护了快速恢复状态，避免了因为连续丢包导致的连续砍

窗口的问题。TCP SACK 加入了选择确认(selective ACK, SACK)与重传机制，避免了累计确认(cumulative ACK)与重传机制带来的低效的回退问题。

后来数据中心的兴起，由于数据中心属于单一自治域的同构网络环境，有相对固定的拓扑和相同的网络配置，比如显式拥塞通告(explicit congestion notification, ECN)，于是基于数据中心的拥塞控制技术研究成为热点，比如最有代表性的 DCQCN[160]算法，实现了交换机端的 ECN 标记和主机端的速率控制。但是仍然存在以下问题：1) 已有的方法只考虑了有限的输入和数学建模，比如 ECN，丢包，往返时延(round-trip time, RTT)，实际网络非常复杂，需要考虑更多因素（比如动态业务模型）和复杂建模。2) 由于获取的网络信息有限，导致收敛速度慢，容易导致网络排队时延增大。3) 由于算法的状态多和优化的参数众多且复杂，使得算法调优非常复杂。为了解决存在的问题，由于 AI/ML 技术可以解决多维度复杂场景下的建模，开始引入 AI/ML 到传输层拥塞控制算法的研究中。主要的研究方法包括基于离线训练的有监督学习、深度强化学习、在线训练的学习。

基于 AI 的传输层拥塞控制技术主要有以下方向：离线训练的有监督学习、深度强化学习、在线训练的学习。每种算法主要的区别在于不同的目标函数的选择，不同的输入输出和 AI/ML 模型的选择。下表列出了主要 AI 算法的比较[161]：

表4-1 传输层拥塞控制主要AI算法

Congestion control	ML method		Objective function (Utility function)	Action	Experimental environment
Remy	Offline learning	A tabular method	Throughput and delay	Cwnds and pacing	NS-2
Indigo		Imitation learning	The ideal cwnds	Cwnds adjustment	Mahimahi
Custard		Trust region policy optimization (TRPO)	Throughput, delay and loss rate	Sending rate	Emulab
Auraro		Proximal policy optimization (PPO)	Throughput, delay and loss rate	Sending rate	Mininet
PCC	Online learning	Rate probing	Throughput and loss rate	Sending rate	GENI Emulab Planetlab
Vivace		Convex optimization	Sending rate, RTT gradient and loss rate	Sending rate	Emulab Mahimahi

Remy 和 Indigo 算法是典型的基于离线训练的有监督算法，把业务模型和对网络资源消耗作为先验信息，在离线训练阶段，将吞吐率和时延最优作为目标函数，将最优的拥塞窗口作为训练模型的输出。基于离线学习的算法好处在于收敛速度快，但由于需要获取较多的离线数据用于模型的训练，完整的数据集成为了在实际应用过程中的一个瓶颈。从下图的实验结果表明[146]，基于 AI 的拥塞控制方法在不同的带宽，时延，队列大小，丢包率下，相比传统 TCP CUBIC 而言，性能都有了不错的提升。

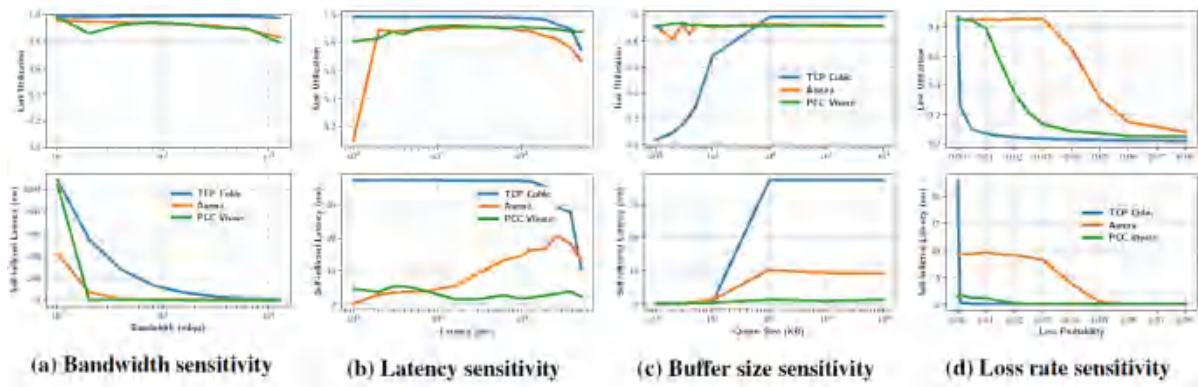


图4-2 实验结果

4.3 基于 AI 的业务速率控制




图4-3 基于AI的业务层速率控制




图4-4 网络测试结果

类似的思路还可以用作业务层的速率控制,比如Pensive[144], 视频码率的动态选择。如图4-3所示, 带宽、速率、终端缓存作为码率选择模型的输入, 输出为动态码率选择。然后与实际的视频体验质量 (quality of experience, QoE) 运行环境结合, 将QoE (考虑视频码率、视频卡顿率和码率切换) 作为收益反馈到AI模型中, 不断完善码率选择模型。通过实际网络的测试结果如图4-4所示, 结果表明从视频码率, 卡顿率和视频切换顺畅度各维度进行评估, 都表现出了良好性能。

4.4 基于 AI 的需求预测与缓存技术

随着智能终端设备的快速发展与普及，诸如短视频等新型移动多媒体业务不断地涌现，人们对于无线数据服务的需求呈现出爆炸式的增长[165]。然而，由于频谱的稀缺性，现有的无线网络难以支撑移动多媒体业务的持续增长，需要我们提出新的解决方案。得益于大数据技术的高速发展，广义认知网络可以将认知对象从电磁环境拓展到用户需求。同时，也得益于存储技术在过去二十年中的长足进步，目前的网络边缘设备均配置了一定容量的存储介质。因此，可以将热门文件与用户未来可能请求的文件主动缓存至移动网络边缘的存储介质中。在用户发起真实请求后，可以直接从网络边缘的存储介质或本地缓存区中读取，从而降低用户的请求时延和移动网络的峰值功率。要想尽可能地提高缓存系统的能效与谱效，需要解决的问题包括：如何提高文件热度预测与用户请求预测的准确性？如何基于预测的文件热度和用户请求在有限的缓存区内制定缓存策略？如何基于缓存策略制定相应的推送与服务策略？国内外众多学者围绕上述问题以 AI 为手段开展大量的研究，下面简要介绍。

a) 蜂窝网络内容热度预测和缓存策略设计

在文献[166]中，康奈尔大学的 Krishnamurthy 教授提出了一种适应性缓存方案以解决蜂窝网络中的文件缓存问题，首先通过机器学习方法，基于用户行为和文件特征等估计内容热度，再结合蜂窝网络相关参数，通过解混合整数线性规划问题得到具体的缓存策略，该方案得到的缓存策略可以根据网络参数如网络拓扑、通信链路、路由策略的变化而进行调整，相比于单一固定的缓存策略，该方案可以更好地适应复杂的网络环境变化。

b) 雾无线接入网络用户偏好预测和缓存策略设计

在文献[167]中，东南大学尤肖虎教授团队研究了雾无线接入网络中的缓存问题，文中考虑了内容流行度在时间和空间上的变化，使用在线梯度下降（online gradient descent, OGD）方法和 FTRL-Proximal 方法提出了对用户偏好的低复杂度在线学习算法，更准确高效地预测用户需求的变化，进一步以用户个体的偏好为基础，预测给定空间范围或时间范围内的内容流行度，从而得到有效的缓存策略。

c) D2D 通信中用户偏好分析

在文献[169]中，悉尼大学 Branka Vucetic 教授考虑基于个人的内容请求概率，而非整体的内容请求概率来设计缓存策略，以此更准确地反应用户个人的偏好而非整体的内容热度，从而实现更准确高效的缓存策略。作者引入了评分矩阵的概念，并对矩阵进行分解得到内容特征与用户偏好的对应关系，通过贝叶斯学习方法预测用户个人

对不同特征的偏好程度，并据此设计缓存策略。该方案还可扩展到 D2D 通信中以进一步降低延时，提高预测准确度。

d) 协同缓存的最优策略

在文献[171]中，伦敦玛丽皇后大学的 Yue Chen 教授研究了协同缓存中内容放置的优化问题，其目的是最大化移动用户的总平均意见得分（MOS）。首先，作者利用递归神经网络（RNN）来预测用户的移动性和内容的热度。然后，作者提出了一种基于学习自动机的 Q-learning 协同缓存算法，该算法通过调用学习自动机进行 Q-learning 来获得在随机和平稳环境下的最优决策。仿真结果显示协同缓存优于非协同缓存和随机缓存。

e) 移动边缘网络文件热度预测与缓存设计

在文献[172]中，德克萨斯 A&M 大学的 Ning Zhang 助理教授使用循环神经网络模型对内容热度进行预测，并基于热度的预测更新缓存策略，通过缓存降低核心网的拥挤程度和降低用户服务延时。循环神经网络模型可以有效捕捉用户请求在时间上存在的内在关联性，并依据用户请求在时间上的相关性更准确地预测用户未来的请求。仿真结果表明该方案会随着更深的神经网络层数以及更长的时间步长而提升性能。

f) 内容推送技术

利用无线传输的多播特性将内容推送到多个用户设备端进行主动缓存，能够有效缓解中心网络负载，提升用户体验。有限的无线传输资源和缓存资源导致内容推送决策之间相互耦合。有限的无线传输资源下，系统每个时隙内只能推送有限的内容到特定的用户设备端。过早的内容推送将带来用户设备端额外的缓存代价，而过迟的内容推送将面临错过用户请求的风险。亟需利用有限的网络资源，实现最大化数据卸载量和最小化缓存代价的平衡。文献[168]提出了一种基于结构化卷积神经网络的内容推送策略。

g) 基于相关性和因果性的业务预测技术

文献[170]提出利用无线业务的两个本质属性，相关特性和因果特性，以准确预测无线业务。1)无线业务相关特性：无线业务具有空时相关特性，即相同小区不同时间段以及不同小区业务之间的相互关系。人们一般使用相关系数来衡量两个变量之间的相互关系，其取值范围在 $[-1,1]$ 之间，其中 1 代表完全正相关，而-1 代表完全负相关，而 0 意味着没有相关性。根据实测无线网络业务的相关性分析可知，无线网络业务在同一地点不同日期的同一时段的业务量呈现很强的相关性（时间相关性），相邻小区同一时段的业务量呈现一定的相关性（空间相关性），因此有效利用无线业务的时空相关性有助于预测无线业务的规律项，提高预测精度。2)无线业务因果特性：无线业务因

果特性揭示了网络业务变化的原因。根据格兰杰因果检测方法可知，如果一个平稳时间序列 X 的历史值有助于提高另一个平稳时间序列 Y 的预测值，则 X 是 Y 的格兰杰因果，也称预测性因果。例如，大型活动、上课、航班起飞/降落等都是无线网络业务变化的原因，具备一定的因果性。探索和利用无线业务的因果性将有助于预测无线业务的变化量，提高预测精度。

4.5 基于 AI 的无线分布式计算

随着移动互联网的飞速发展，各类互联网应用产生的数据量呈爆炸式增长。面对如此巨大的数据量，传统的依托于数据中心进行集中数据分析与处理这种模式逐渐难以满足业务需求。在传统模式中，网络的边缘节点只负责数据收集与用户交互行为，并将所有原始数据上传到数据中心进行处理，这将导致巨大的通信消耗例如带宽占用和能量消耗等，此外，对原始数据的上传还可能导致用户的隐私泄露。目前移动设备的快速发展与普及使得网络的边缘节点具有较强的计算能力与储存能力，可以胜任针对本地的小规模数据量的分析与计算。因此，为了解决这些问题并且更高效地完成大规模数据的分析与处理，我们可以采用分布式计算的思想，借助移动边缘计算和人工智能算法，将庞大的计算任务分发给网络边缘节点完成，而后由中心服务器将各个节点的计算结果进行整合统一，从而形成全局的计算模型。因此，AI 在未来无线计算中的应用成为了一个重要的研究课题，而联邦学习（federated learning, FL）能够在无线计算任务中实现分布式训练与训练结果的集中整合，有望有效地解决大规模数据处理的资源消耗与隐私保护问题。

当前的研究主要包括如下方面：

a) 基于 AI 的移动边缘计算技术

在边缘节点执行数据压缩可以有效地减少需要传输的数据量，大大缓解了网络负载。如何联合优化系统中的数据压缩和传输成为了一个亟待解决的问题。以往的研究工作解决的都是单时隙之间数据压缩和传输的耦合问题。然而在大数据背景下，考虑到数据压缩时间不可忽略，数据需要在压缩完成后的时隙传输，因此时隙间耦合使数据压缩和传输问题更为复杂。文献[172]在考虑传输资源和计算能力受限的情况下，提出了一个分布式的数据压缩和传输调度算法。为了描述实际等待的数据包数量，此研究建立了原始数据队列和压缩数据队列之间的队列映射关系。以吞吐量最优为目标，其利用原始数据队列设计了基于李雅普诺夫优化的传输调度算法。为了解决数据传输决策与数据压缩决策解耦过程中产生的长期收益问题，利用深度 Q 网络估计每个节点对压缩方案的偏好，并提出一种最优的数据包替换算法。

b) 基于 MIMO 空中计算的 ML 模型分割

在传统 ML 模型分割任务中，通信往往被视为一个管道，只负责准确地传输神经网络计算过程中的一部分中间结果。由于在模型分割中，每组数据的前向计算、反向传播中间结果均需要进行传输，这需要大量的通信开销。在文献[196]中，作者提出可以通过使用空中计算(over-the-air computation)技术的 MIMO 系统高效实现与无线通信高度耦合的模型分割学习系统。

由于模拟信号在空中的叠加，基于 MIMO 系统的空中计算可以看作一个带噪的线性变换，其具体参数由信道参数本身决定。通过这一技术，可以利用 MIMO 系统同时发送多路模拟信号以代表多维数据，大大提高系统效率。由于神经网络本身具有良好的泛化能力和对噪声的容忍能力，噪声对这一系统的影响不如普通模拟系统中大。同时，通过调整预编码与合并矩阵，可以实现对空中计算所对应的线性变换的控制。由于神经网络中存在大量的线性操作，这一可控线性变换可以很容易地与神经网络耦合。

c) 联邦学习中的调度策略

最小化损失函数/最大化模型精度：在文献[25]中，由于无线网络中的联邦学习需要通过无线连接来传输参数，所以会受到无线资源的限制，需要选择合适的用户子集、资源分配方式以及学习的策略。针对 OFDMA 传输，作者提出了一个存在误包的情况下的本地模型丢弃策略，和一个在延时、功率以及能量约束条件下的最小化损失函数的优化问题，并使用二分图匹配算法进行了求解，得到了用户选择和资源配置策略。实验结果表明作者提出的算法和基线方法相比，损失函数更小，预测精度更高。

最大化收敛速度：在文献[26]中，同样由于无线资源的限制，需要选择合适的用户子集和资源分配方式。针对 OFDMA 传输，作者提出了一个概率用户选择策略，对全局模型有较大影响的用户被选择的概率较高，且每个用户被选择的概率均大于 0 的。同时作者还提出利用神经网络来表示不同的用户本地模型之间的关系，并利用它来估计那些未被选择的用户的本地模型，以此利用更多的用户数据集信息。在给定用户子集的基础上，优化无线资源块的分配，最小化收敛时间。

d) 计算资源与通信资源联合调度

在文献[195]中，作者研究了在联邦学习中如何有效利用边缘节点有限的计算资源与通信资源达到最优的学习性能。模型聚合的频率是可以控制的，而非最优的聚合频率可能导致大量的资源浪费。作者从理论角度分析了基于梯度下降算法的联邦学习收敛界，并据此提出了一种控制算法来动态控制模型聚合的频率，以在有限的资源预算下最小化损失函数。通过实际数据集仿真验证，该控制算法在多种不同情况下都能达到近乎最优的性能。

在文献[199]中，作者研究了在无线网络中的联邦学习延时最小化的问题。在联邦学习中，本地计算时延与通信时延都取决于目标学习准确度，通过联合考虑这两方面的时延，作者建立了一个联合传输与计算优化问题以最小化联邦学习延时，并理论证明了延时是学习准确率的凸函数。而后，基于这一凸函数性质，作者提出一种二分查找算法得到最优的学习准确率。

e) 自适应分簇的分级联邦学习系统

在大规模联邦学习系统中，各用户本地数据分布呈现较强的互异性。为避免数据非独立同分布特性带来的负面影响，传统联邦学习系统要求各用户频繁上传本地训练结果到中心端基站执行全局模型融合。然而，广大 UE 的异构性致使频繁通信场景缺乏足够的可靠性；用户群体的巨大数量及模型规模的日益增长使得系统通信损耗急剧增加，进而导致涉及频繁通信的分布式架构在实际场景中缺乏实用性。文献[198]在分级联邦学习架构的基础上，提出了自适应分簇算法，对用户接入基站的选择以及通信资源的分配。

在分簇方案的决策过程中，系统将综合考虑各用户的本地数据分布及其地理位置等信息，一方面通过促使各簇内的联合数据分布趋于独立同分布来进一步提高簇内局部模型融合的可靠性，另一方面通过对系统内可用通信资源的合理分配来降低系统整体通信时延，从而寻求学习增益与通信增益的联合最大化。在构建的优化问题中，决策变量包括分簇策略及通信资源分配策略，通过联合优化二者来达到提升系统整体训练效率的目的。

4.6小结

相比于 AI 技术在物理层技术的研究，AI 在无线通信网络上层技术方面的研究较少，目前主要是集中在无线通信网络的应用层和网络层两个方面。初步的研究结果表明，AI 技术可以用于无线网络架构的设计、传输层拥塞控制、业务速率控制、网络/用户需求预测、以及无线分布式计算等领域。例如，AI 被应用于分析和预测无线用户的可用性状态和内容请求，从而使基站能够提前确定用户的关联内容并进行缓存，从而减少数据流量负载，并扩展到业务层速率控制算法。此外，AI 还被用在学习环境，并随着环境的变化采用不同的解决方案，使得设备自主决策成为可能，从而实现网络智能化。

第五章 基于AI的语义通信

近年来，随着人们对无线通信智能化需求的提升，各种基于无线通信技术的新兴智能业务（如工业互联网、车联网、远程医疗/手术、虚拟现实及全息投影技术等）层出不穷。这些新兴业务不再仅仅依靠高速率的数据传输，而逐渐对网络智能化和服务多样性等方面提出更多要求。在这一发展趋势的推动下，未来通信网络将开始逐步向高度自动化、智能化且可提供更贴近人类用户需求和体验的万物智联全新架构转变。

语义通信是一种全新的通信架构，它通过将用户对信息的需求及语义融入通信过程，将有望大幅度提高通信效率、改进用户的体验质量（QoE, quality of experience），并从根本上解决基于数据的传统通信协议中存在的跨系统、跨协议、跨网络、跨人—机不兼容和难互通等问题，真正实现“万物透明智联”的宏伟愿景，即通信网络、计算和存储等软/硬件设备无缝融入人们的生活。人们无须携带手机或计算机等专属计算和通信设备也可以享受无处不在的计算、存储和通信等服务。

5.1 基于 AI 的语义通信系统架构

语义通信模型的一般框架如图 5-1 所示，与传统通信系统相同，语义通信系统包含发送端、信道与接收端三个部分，主要区别在于语义通信系统所采用的编解码方式。语义通信系统的发送端包含语义编码与信道编码部分，接收端包含信道解码与语义解码部分。在已有的工作中，文献[204]将深度学习与联合信源信道编码结合，通过语义信息的传递在接收端恢复文本信息。文献[205]将联合信源信道编码用于图像的传输中，并取得了较好的效果。文献[206]出了内容为语音的语义通信方式，验证了语义通信对语音的有效性。



图5-1 语义通信模型的一般框架

5.2 基于 AI 的高效语音语义通信系统

现有针对图像、文字的语义提取主要使用全连接层获取低维度的隐变量，这种隐变量相较于信源编码具有更低维度从而可以传递更少的数据量。更进一步地，可以使用不同模态的数据作为可解释性表征去提取语义信息，[204]针对语音传输任务的语义通信，

使用语音中对应的文字信息作为语义信息提取目标，实现语音到文字之间的跨模态对齐，从而不仅降低了隐变量的维度，而且还大幅缩短了序列长度，从而进一步地去除通信中的冗余，实现更高效的语义通信系统。

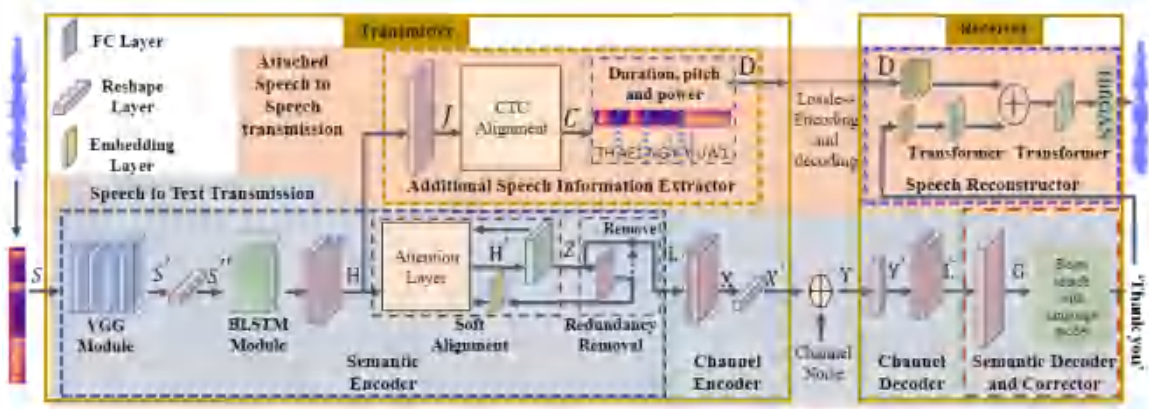


图5-2 高效语音语义通信系统结构

图 5-2 为所提出的系统结构图。整体结构分为两个部分，分别为发射端和接收端，而接收端可以分为语义编码器、信道编码器和额外语音信息提取器，接收端可分为信道解码器、语义解码器、语义纠正器和语音重建器。其中系统输入的语音信号首先转换为对应的频谱信号，然后输入语义编码器，在语义编码器中使用卷积模块和双向 LSTM 模块获取中间隐变量，该中间隐变量由软对齐模块和额外语音信息提取器分别转换为文字隐变量和额外语音信息。文字隐变量经由发送端的信道编码器、带噪信道和接收端的信道解码器得到带噪声的文字隐变量。在接收端使用基于束搜索的语义解码器，同时使用基于 LSTM 的语言模型辅助纠正信道噪声带来的语义错误，得到对应的准确文字信息。如果要获得重建的语音信号，我们将获得的文字信息和额外的语音信息输入一个非自回归的语音生成模型，并通过 HIFIGAN，获取与输入语音近似的重建语音信号，完成高效的语音传输。

从图 5-3、图 5-4 可以看出，对于语音到文字传输，本系统在测试集的准确率远高于其他通信系统，尤其是在低信噪比区域，本系统不会出现大幅度的性能下降，在词错误率和语义相似度上都保持了更稳定的表现。




图5-3 语音语义通信系统测试集错误率




图5-4 语音语义通信系统语义相似度

表5-1 高效语音语义通信系统对于传输一段音频信号所需要的序列长度

Example 1	The number of speech spectrum frames: 497 Transcription: (Length:36) BOS RANDAL HE SAID YOU KNOW WHERE SYDNEY IS EOS x 27 Transcription after the redundancy removal module: (Length:8)RANDAL HE SAID YOU KNOW WHERE SYDNEY IS
saved: 77.8%	

表5-2 高效语音语义通信系统对于传输一个隐变量所需要的通信量

	The length of each transmitted symbol vector	The average numbers of transmitted symbols per sentence
Proposed	32	1120
DeepSC-SR	20	7143
SE-DeepSC	128	2225
DeepSC-S	16384	655360

表 5-1 和表 5-2 分别给出了本系统对于序列长度冗余的去除和平均通信量的对比，可以看出本系统通过软对齐和冗余消除，大大缩短了需要传输的序列长度，同时获取了最小的平均通信量。在和语音到语音传输系统的对比中，我们仅需要使用 0.2%的通信量就可以实现相近的效果。

5.3 基于 AI 的图像语义通信系统

深度学习在图片语义通信模型中得到广泛的应用，通过其良好的特征提取和学习能力，对图片包含的语义信息进行提取和通信。相较于数字通信通信模型，基于深度学习的图片通信模型不会遭遇“悬崖效应”[204]。基于联合信源信道编码的图片语义通信模型（joint source and channel coding, JSCC）[204]，已经用于具有非线性信号的多径衰落信道中的无线图像传输，该通信系统利用卷积神经网络联合设计和优化信号的编解码和通信过程。同时，在[204]中提出了一种基于深度学习的 JSCC 方案，用于在具有非线性信号的多径衰落信道上进行无线图像传输。所提出的编码器和解码器使用卷积神经网络将源图像直接映射到基带进行正交频分复用（OFDM）传输。该模型基于机器学习方法不需要单独的源和信道编码，同时集成 OFDM 数据路径以应对多路径衰落信道。

[204]提出一种多级别语义通信系统（MLSC-image），该通信系统由两部分组成如图 5-5 所示：(i)编码器，从输入图像中提取语义特征并将其编码为符号信号以实现无线信道传输；(ii)解码器，从接收到的信号中解码语义特征，以重构源图像。编码器由两部分组成：多级语义特征提取器和联合语义信道编码器。首先编码器的输入图像 I 由标准化层预处理，使得图像中的每个元素都在 $[0,1]$ 范围内。然后通过多级语义特征提取

器提取输入图像不同层级的语义特征。联合语义信道编码器将这些语义特征编码为符号，并通过无线信道发送给接收器。解码器由两部分组成，联合语义信道解码器和图像重建模块。联合语义信道解码器能够有效缓解信道噪声对传输信号的影响，并恢复多级语义特征。图像重建模块融合不同层次的语义信息，进而重建目标图像。最后，反标准化层对重建结果进行像素映射(0-255)。

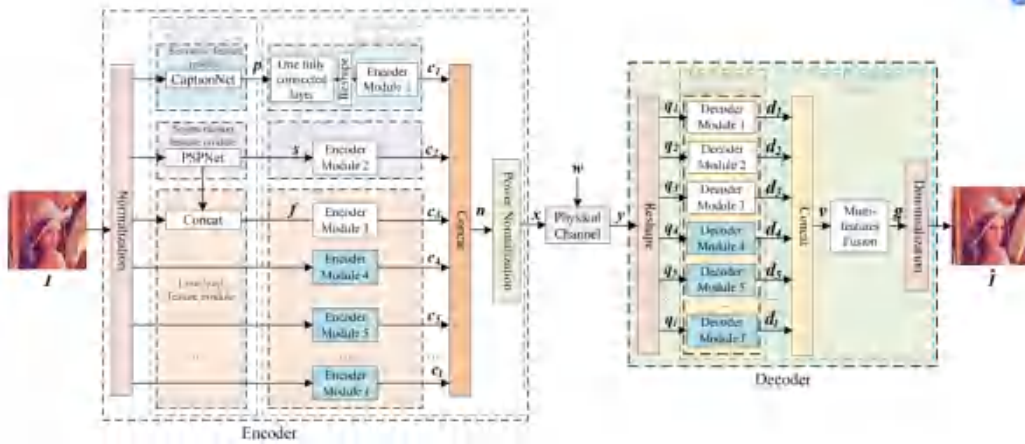


图5-5 基于多级特征的图像通信系统

随着物联网设备的广泛部署，图片语义系统的高效性使其能够大规模部署在设备端。[204]提出一种在物联网设备上使用两个深度神经网络作为编解码器的联合传输和重识别（re-ID）方案，在低信噪比的情况下与部署在物联网设备上的传统方案（JPEG 和基于压缩感知的方案）相比，所提出的系统能够实现具有更好的识别精度。在计算资源有限的边缘服务器上通过联合特征压缩和传输系统来处理图片，实现高效可靠的推理和识别任务[204]。该系统结合 JSCC 方案，同时考虑特征压缩和信道编码，并结合新型滤波器修剪策略减少神经网络冗余复杂性，该方案不仅提高了端到端的可靠性，而且降低了计算复杂度。

5.4 基于 AI 的语义通信系统资源调度

语义通信是一种新型通信范式，不同于现有通信系统中不考虑任务语义的信源信道编解码，语义通信系统提取任务相关的语义信息进行编码传输，可以有效降低通信量，并且可以在窄带宽、高噪声的情况下进行通信。目前大部分与语义通信相关的工作都集中在语义信息的提取，对其在资源分配相关的研究比较少。而有效的资源分配对通信系统性能的提升有着重要的影响，因此，关于语义通信系统的资源分配的研究很有必要。我们提出了一种语义通信场景下的下行资源分配算法。在该场景中，每个用户都有一个时延的约束和一个通信性能的约束。文献[224]提出一种联合语义压缩和资源分配算法，在满足用户时延和性能需求的情况下，最大化系统所能服务的用户数。仿真结果如图 5-6 中所示，可以看出所提出的算法在相同功率的情况下，能够支持更多的用户数，其中，

Greedy 代表将问题 3 用匈牙利算法求解，得到每个用户所需的功率，然后根据贪婪算法选择用户的结果，Uniform 表示功率平均分配，资源块随机配对。




图5-6 系统支持用户数随功率变化图

为了探究自适应压缩方案与固定压缩方案的性能差距，我们将所提出的方案与固定压缩比的方案进行了比较，这些算法的压缩比是固定的，资源分配方案与所提出的算法一致。可以看出，固定压缩比方案的算法性能有所下降，这是因为固定压缩比有时候会传递更多冗余的信息，造成功率损耗。而压缩比为 1/24 的算法性能明显下降，这是因为其压缩比过低，对于对性能要求比较高的用户，过低的压缩比无法满足其需求。

5.5 小结

目前，基于 AI 的语义通信的研究刚刚起步，主要集中在语义通信系统框架、高效的语义通信系统(语音语义系统、图像语义通信系统)、语义的资源调度等方面的研究。初步的结果表明，基于 AI 的语义通信系统具有一定的可行性，能够提取并恢复多级语义特征，实现初级的基于图像语义、语音语义的信息传输。但是大量的基础概念和基础问题亟须大量的研究和完善，例如如何量化语义信息，如何压缩语义信息，如何设计通用语义通信知识库与更新，如何实现高效的多模态信源语义编解码等方面。

第六章 无线AI研究数据集

无线 AI 研究需要高质量的数据，如何共建共享无线 AI 研究数据集是无线 AI 研究向前推进需要迫切解决的问题。一种典型的无线 AI 研究数据集可以包括如下 5 个子数据集：1) 信道数据集，包括对信道状态的记录；2) 环境数据集，包括对客观环境的描述；3) 经验数据集，包括无线网络状态、决策和性能的记录；4) 用户画像数据集，包括对用户属性、行为的描述；5) 预训练模型数据集，包括预先训练好的可用于通信任务的神经网络模型及参数。其中，信道状态可以是信道估计得到的信道系数，也可以是 CSI 测量信息等信道相关的信息。环境数据则可以包括用于描述客观传输环境的图像、点云数据等。用户画像可以包括用户使用的终端型号、位置等用户属性和行为信息。而预训练模型则可以是在不同场景下的信道预训练模型、信道数据的分布模型或无线网络优化模型等可用于特定场景特定任务的预先训练的神经网络模型集合[208][209]。

6.1 无线 AI 研究数据收集和利用

无线 AI 研究数据集可以通过仿真、实测或者两者结合的方式进行构建。仿真数据的获取灵活性更高，可以通过修改场景配置和通信参数的方式生成多种多样的数据样本。实测数据则更贴近算法的实际应用场景，能够为算法提供更加准备有效的评估。两者的结合可以通过互相校准的方式实现。

仿真数据集的构建主要有两种方式。一种是利用 3GPP TR38.901[210]等标准提供的统计模型，在给定场景和通信参数下生成信道、信号强度等数据。统计模型生成的数据往往无法与具体的场景设置（如建筑物布局、BS/UE 位置等）一一对应，因此无法用于特定场景设置相关的具体任务。另一种是在给定场景设置下，通过 ray-tracing 方式生成数据[211][212][213]。这种方式得到的数据与其生成场景强相关，可用于研究具体环境对无线通信的影响。

还可以在无线通信的过程中，实时的收集无线 AI 研究数据集中的各个子数据集数据，甚至通过预训练模型的训练和推理，这些数据可以用于辅助通信中的各个任务，让网络变得更加智能。图 6-1 展示了一个实时收集并利用各个子数据集的例子，通信中历史采集得到的信道数据可以预先训练好一个信道模型，这个信道模型学习了信道状态在时、频、空域的变化规律，根据实时信道状态的输入，可以输出信道的压缩表示。该信道表示数据再拼接环境数据、用户画像等信息，就可以足够充分的表达当前场景，输入下游用于具体任务的神经网络模型，可以输出智能决策用于执行智能空口配置、资源管

理调度及智能环境感知等任务。收集这些任务执行后的状态、决策和性能指标等可以得到经验数据集，经验数据集可反馈用于模型的持续在线训练过程。

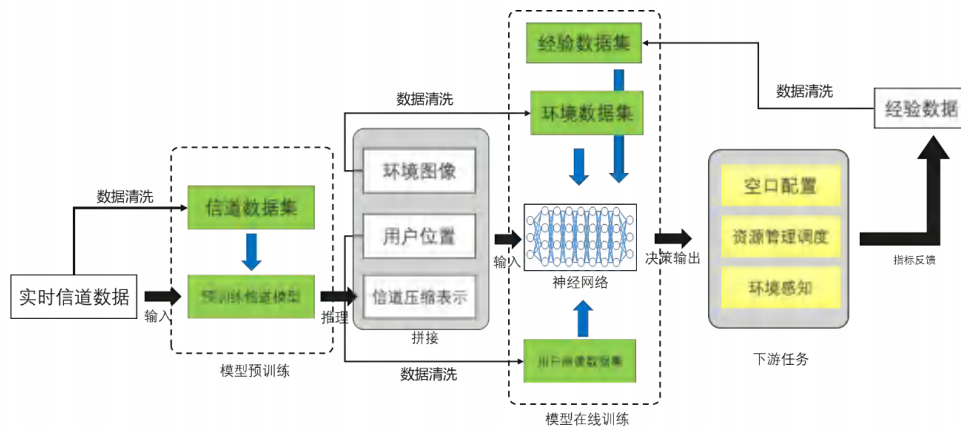


图6-1 无线AI研究数据集的收集和利用举例

6.2 无线 AI 研究数据集的共建共享

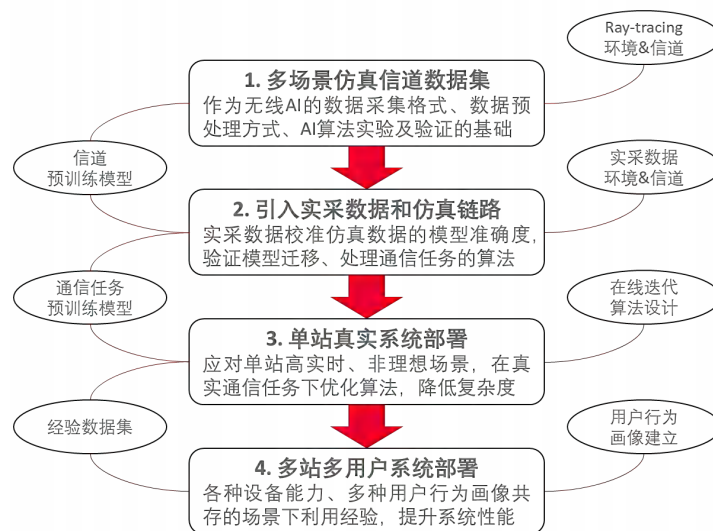


图6-2 内生AI架构与无线AI研究数据集



图6-3 RT仿真信道数据（左：BS/UE部署 右：BS5和UE7 RT仿真结果）

无线 AI 研究在数据集的建立上也面临很大的挑战。不同于互联网上随处可见的图像、语音、文本等数据，真实无线传输环境下的数据采集往往需要昂贵的专用设备和大量的人力和时间。而采集到的数据也面对着诸如数据种类繁多，数据质量参差不齐，数

据处理方法和数据格式多种多样，体量巨大等一系列问题。在此种情况下，讨论如何共建共享无线 AI 研究数据集，并发展一套与之匹配的系统性的评估理论和方法，是需要各研究单位协同参与并一起解决的关键问题。

在内生 AI 网络中的相关建立和部署方法如图 6-2 所示，可以分为以下四个步骤：

步骤 1：建立多场景仿真信道数据集。首先建立统一的大规模仿真信道数据集，用于 AI 算法的验证以及模型的预训练。仿真信道数据的产生可以采用射线追踪（Ray-tracing）方法，并在信道数据产生的同时记录反映通信场景的信息，例如环境中的建筑物布局、设备位置等。

步骤 2：引入实采数据和仿真链路系统。在少量实测场景中采集实际数据，验证在该场景下信道预训练模型的性能，并尝试在真实数据上进行模型迁移，提升当前场景下的模型性能。同时，研究实采数据的分布，校正仿真信道数据生成模型，提升仿真数据集的真实性。

步骤 3：单站真实系统部署。通过单站、小规模真实系统的部署，对预训练的模型和算法进行初步验证、调优，并把经验数据收集起来。

步骤 4：多站多用户系统部署。将模型部署在多站多用户真实系统中进一步验证模型的泛化能力以及多站多用户之间的联合学习、多智能体强化学习等算法。

在示例中，相关数据集的建立过程如：1）通过在全球 40 多个大城市的公开地图上进行采样，可获得 10000+真实建筑物布局，每一个建筑物布局可以看作一个环境；然后在每个环境里随机撒点，可获得 5 个基站和 30 个终端的位置；2）利用射线追踪方法仿真基站和终端的所有 150 种组合，得到 150 个组合场景的数据。这样，我们可以得到了 150 万+的场景，每个场景包括环境信息（建筑物布局）、基站和终端的位置，以及仿真信道。其中，仿真信道包括了当前基站和终端链路的所有射线信息，每条射线又包括出发角、到达角、时延以及不同频点的频率响应等。如图 6-3 所示，在给定建筑布局场景中进行 BS 和 UE 撒点，其中 UE 的撒点位置为随机，BS 的撒点则要求在建筑附近的街道上，以保证一定的合理性。3）获得 BS 和 UE 之间的射线追踪仿真结果。如图 6-3 中所示的 BS5 和 UE7 之间的射线情况，其中，颜色越深代表射线的路损越小。采用该方法获得的信道数据除了具有场景多样、贴近真实的特点，还可以提供和数据集配套的数据预处理代码，对频点、系统带宽、OFDM 参数、天线数、天线间隔等参数进行自定义配置，并输出与此参数对应的信道冲击响应。

6.2.1 定位

以定位任务为例，由于多径信道受到通信设备周边的环境影响，理论上结合环境信息，即使只有单站的信道，也可以实现具有一定精度的定位。定位实验的参数配置如表 6-1 所示，数据集中的每份数据包含：时延角度域的信道冲击响应、当前的环境以及设

备位置等信息。读取的数据按照 9:1 的比例分成训练集和测试集，训练时以信道冲击响应、环境、发射设备位置作为神经网络的输入，以接收设备位置作为神经网络的输出。

表6-1 自定义参数配置

频点	带宽	载波数	接收天线数	发射天线数	天线间距
2.16GHz	5M	25	2/4	8/32	半波长

示例中的训练可采用卷积神经网络和全连接网络提取信道、环境和发射端位置的特征，并输出预测的接收端位置。用于定位的神经网络的从数据集预处理得到的输入数据经过 DNN 或 CNN 后得到不同特征并拼接，再经过 DNN 推演，得到接收端的预测位置。

在对比实验中，我们尝试了有环境信息和没有环境信息、以及 8T2R 和 32T4R 的天线数组合。从图 6-4 中可以看出，有环境信息的实验无论是训练集还是测试集，定位精度都要高于没有环境信息的实验。当天线数从 32T4R 降为 8T2R，由于角度分辨率降低，定位精度下降，但是有环境信息的实验训练集下降很少，测试集的定位精度下降也少于没有环境信息的实验。另外从上述实验结果中可以看出，环境信息的引入对于定位精度的提升有一定帮助。




图6-4 基于无线AI研究数据集的定位任务训练结果

高质量的无线 AI 研究数据集中含有丰富的信道、环境、场景信息等，对于未来无线 AI 的研究有极其重要的基础价值。

6.2.2 智能波束预测

空域波束预测是指利用已知部分的稀疏波束功率测量结果，预测出其它未知部分的波束功率，进而从中挑选出最优波束的过程。传统算法对未知部分的波束功率的预测不准确导致挑选的波束和最优波束之间有一定的功率差，而遍历所有未知波束的扫描开销是不能接受的。

因此，探索利用 AI 方法进行空域波束预测并考虑两种方案：只基于稀疏波束测量结果的预测；基于稀疏测量结果和环境信息的预测。假设完整的波束集合包含 64 个窄波束，在波束扫描的第一阶段，先等间隔测量 M （以 $M=16,8$ 为例）个波束，再基于该

稀疏测量结果，从完整的波束集合中挑选 K 个（以 $K=1,3,5,7$ 为例）波束以供第二阶段波束扫描。第一阶段和第二阶段的扫描组合参数取值以 $\{M\}-\{K\}$ 的形式表示。基线算法在稀疏测量结果中的最强波束附近选择 K 个候选波束，AI 方法则先预测完整波束集合的功率，再从中选出最强的 K 个候选波束。训练数据集包含 1000 个环境，测试数据集包含另外的 100 个环境。基站 64 天线、UE2 天线、带宽 30.72MHz、载波数 128 以及频点 28GHz。性能评价指标为波束预测准确率，其定义为：最优波束如果在 K 个波束中则预测正确，否则预测错误。波束扫描开销的定义为：第一阶段和第二阶段扫描的波束数量之和与波束总量的比值。




图6-5 波束预测性能对比

从图 6-5 所示的对比结果中可以看到，在同样的扫描开销下，AI 方法的预测准确率要明显高于基线方法。特别是在 K 取值较小时，仅在稀疏测量波束附近进行搜索，难以找到最优波束。对比 AI 算法的两种方案，在引入环境信息后，波束预测的准确率进一步提升。对于两阶段的波束扫描，不同的扫描配置（ M 和 K 取值）的扫描开销和预测准确率不同。波束扫描组合 8-3、8-5、8-7 的扫描开销都小于 16-1，同时具有更高的预测准确率，因此稀疏波束测量配置的不同组合具有一定的优化设计空间。

6.2.3 模型泛化与迁移

以波束预测模型为例讨论基于无线 AI 数据集训练得到的模型在不同无线场景下的泛化与迁移性能。在训练使用多场景训练数据，可以让预训练模型在不同场景下具有一定的泛化性。然而，泛化性的提升也可能导致预训练模型在某一特定场景下的性能不是最优的。在实际部署时，预训练模型可以在具体场景下进一步在线训练（微调）。相比于重新开始训练，微调预训练模型可以用很少的计算代价得到更准确的模型。

图 6-6 展示了多环境预训练模型在迁移到密集撒点环境并进行微调后的性能，其中密集撒点环境中包含 1 个 BS 和 10000 个随机撒点的 UE。第一阶段波束测量个数 $M=16$ 个，第二阶段扫描波束个数 K 为 $\{1,2,3,5,7\}$ 。可以看到，波束预测准确率随着微调训练

的进行而不断提升，说明基于多环境数据的预训练模型虽然已经收敛，但通过基于特定场景的具体数据进行微调训练可以给性能带来进一步提升。




图6-6 波束预测模型迁移性能

我们再讨论不同迁移方法的性能。如图 6-7 所示，首先考虑三种典型的模型训练和迁移方案：**Case A**：基于多场景数据的预训练模型先迁移到特定场景 1，再迁移到特定场景 2（特定场景间迁移）；**Case B**：基于多场景数据的预训练模型直接迁移到特定场景 2（多场景至特定场景迁移）；**Case C**：利用场景 2 本地数据从零开始训练模型（无迁移）。

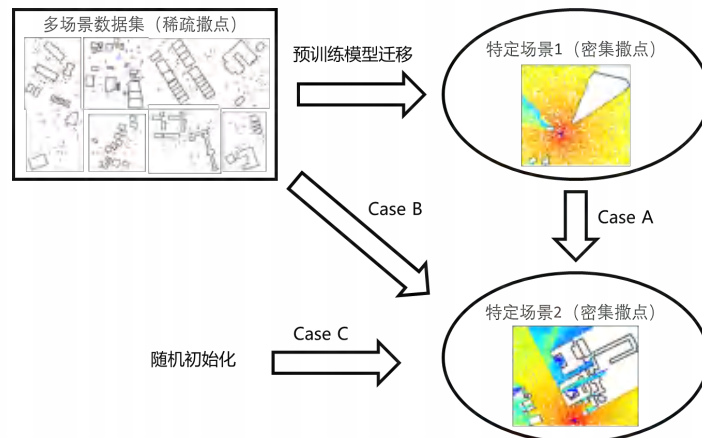


图6-7 预训练模型部署和迁移验证

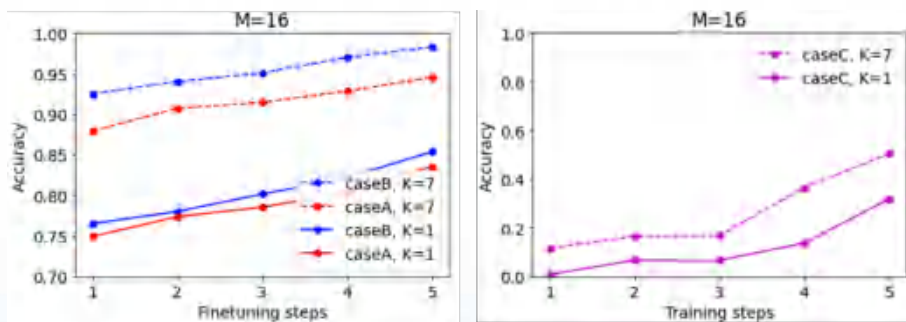


图6-8 三种模型迁移策略的波束预测准确率对比

如图 6-8 所示，对比上述三种模型迁移策略可见，无迁移的 Case C 在同样的训练计算量下，准确率远低于两种迁移方法。同时，Case A 为代表的特定场景间的迁移，其模型准确率一直低于 Case B 为代表的多场景至特定场景的迁移。可见单个环境下少量特

定场景数据的微调造成了模型在该数据分布下一定程度的过拟合，即使使用新数据训练，它的准确率也不如使用具有泛化性能的预训练模型进行迁移。

6.3 无线 AI 伦理规范及隐私保护

随着无线通信网络的迅速发展，未来无线网络的规模、接入量及复杂度将会呈指数增长。因此，无线通信网络一直在探寻将人工智能引入网络，为无线网络赋能的道路。然而，伴随着人工智能在各行各业的大规模应用，除了人工智能带来的巨大收益之外，也催生了人机关系的新变化和新挑战。随意滥用人工智能带来了一系列恶果，如深度伪造（deep fake），自动生成虚假新闻等。一些组织和机构已经开始重视应用人工智能过程中的正确态度，并对人工智能的行为规范展开了研究，总结出了人工智能的伦理规范。目前，对人工智能进行约束的首要目标是构建人工智能伦理规范及伦理体系，众多国际组织、政府机构、及公司等均发布了人工智能伦理相关文件。从发布主体分类，可大致分为三种文件：国际组织文件、政府文件、产业界文件，包括宣言、原则、指南、白皮书等多种形式。截止目前，约有 74 份人工智能伦理相关文件已发布，虽然出发点不同，但最终落脚点均落在对人类有益、保护数据安全及隐私、可靠、可解释等特点上。

由于无线通信网络属于基础设施，处于强监管领域，用于无线通信网络的人工智能需要满足严格的伦理规制和监管要求，保证其安全可靠，确保人工智能的应用受到合理约束，才能够在无线通信领域顺利应用，使人工智能真正助力无线通信系统的发展。我国从 2017 年便开始重视人工智能面临的伦理及隐私保护问题，国务院在 2017 年 4 月发布了新一代人工智能发展规划，明确指出要“制定促进人工智能发展的法律法规和伦理规范”[217]。2019 年 6 月，国家新一代人工智能治理专业委员会发布了《新一代人工智能治理原则——发展负责任的人工智能》，提出了人工智能治理的框架和行动指南，其中第四条提到“尊重隐私：人工智能发展应尊重和保护个人隐私，充分保障个人的知情权和选择权。在个人信息的收集、存储、处理、使用各环节应设置边界，建立规范。完善个人数据授权撤销机制，反对任何窃取、篡改、泄露和其他非法收集利用个人信息的行为”[218]。2020 年 8 月，我国国家标准化管理委员会、中央网信办、国家发展改革委、科技部、工业和信息化部等五部委联合发布了《国家新一代人工智能标准体系建设指南》，提到要“建立人工智能标准体系结构”，其中一个重要方面就是建立伦理与隐私保护标准，包括“基础安全，数据、算法和模型安全，技术和系统安全，安全管理和服务，安全测试评估，产品和应用安全”等六个部分，贯穿整个人工智能标准体系[219]。由此可见，我国对于人工智能伦理规范建设的需求已经刻不容缓。

世界范围内也对人工智能的伦理规范和隐私问题进行了广泛探讨，期望规范人工智能的行为。举例来说，2020 年 2 月，欧盟委员会发布了《人工智能白皮书》[220]，在《人工智能白皮书》中，欧盟提出要建立一个“受信任的人工智能环境”，要求确保隐私

和个人数据在使用人工智能的产品和服务中受到合理保护，因为人工智能增加了跟踪和分析人们日常习惯的可能性。此外，通过分析大量数据并识别数据之间的关联，人工智能还可以用于对个人的数据进行回溯和去匿名化处理，这对即使本身不包含个人数据的数据集，也带来了新的个人数据保护风险。斯坦福大学在 2019 年 3 月成立了以人为本人工智能研究院（HAI），旨在减少人工智能的危害，认为“把伦理研究纳入人工智能的研究和开发的基础中是当务之急。”

当人工智能被应用于无线通信系统时，其应当遵守的伦理规范和确保的隐私保护原则应更为严格。无论是 5G 或者未来的 6G 无线通信系统，最终愿景是从人人互联、人物互联，到物物互联，再到人网物三者的结合，最终构建万物互联的智能世界。由于未来的 6G 无线网络将支持丰富的应用服务，因此会涉及到大量的用户隐私数据，如终端硬件标识、用户的身份证（ID），以及用户的行为偏好等。同时，由于数据挖掘技术进步，使得隐私信息的提取方式变得更加强大。因此，人工智能应用于无线通信网络时，应遵守以下伦理守则：1）保护数据安全及隐私；2）鲁棒性；3）透明性；4）可解释性。

由于无线通信系统的高度重要性，无论是无线通信系统内部或者垂直应用场景下的数据安全和隐私均应当得到充分的保护：1）传统意义上的无线通信网络用户隐私数据，如用户数据、位置、行踪、通信内容、通信行为、通联关系、账号等；2）垂直应用场景中的隐私数据，如智慧工厂、智慧海洋、智慧物联中的相关敏感信息等。这些隐私信息的敏感和需要保护的程度将更为严格；3）未来无线通信网络中的隐私数据，此时无线通信网络接入的设备多样化，支撑多种业务，如无人驾驶，智慧城市，工业自动化，及超大规模物联网等。在此阶段，人工智能将会收集、存储、处理海量的数据，其数据安全和隐私保护要求将会上升到一个更高的高度。

6.4 小结

总之，面向未来无线 AI 通信系统，数据集的建立上目前面临这很大的挑战。具体而言，真实无线传输环境下的数据采集往往需要昂贵的专用设备和大量的人力和时间。而采集到的数据也面对着诸如数据种类繁多，数据质量参差不齐，数据处理方法和数据格式多种多样，体量巨大等一系列问题。在此种情况下，讨论如何共建共享无线 AI 研究数据集，并发展一套与之匹配的系统性的评估理论和方法，是需要各研究单位协同参与并一起解决的关键问题。另一方面，由于人工智能的应用伴随着大量的数据收集、存储、处理过程，数据安全和隐私保护是一个无法回避，且亟待解决的问题。无线通信系统作为基础设施，承载着海量数据传输的任务，数据安全和隐私保护应当受到高度重视，让安全，可靠，可信的人工智能系统助力无线通信系统发展，实现无线通信网络的高度智能化。

第七章 研究总结及产业化前景分析与展望

本报告结合物理层、链路层以及网络上层具体需求和问题，全面介绍无线智能网络架构、无线智能空口、无线 AI 算法、无线 AI 数据集、无线语义通信等基础理论和关键技术当前的主要研究进展。本章将总结全文内容，概述 AI 赋能的无线技术的潜能和优势，分析其产业化前景、现有的技术成熟度及其对标准化和产业化应用的影响。

7.1 AI 赋能无线技术的潜能及优势

无线 AI 将是未来 6G 中渗透性最强的核心技术之一，涉及空口、网络、协议和算法的各个层面，也将深度影响感知、通信、计算、控制等网络功能，其技术可行性和性能潜力已得到证实。本报告的研究工作初步形成了如下基本结论和重要共识：

- 1) AI/ML 能很好地表征和重构未知无线信道环境、有效跟踪预测反馈信道状态、挖掘利用大状态空间内在统计特征，大幅度提升物理层信号处理算法的性能。
- 2) AI/ML 能够智能挖掘利用无线网络时空频通信、感知和计算资源，有效协调干扰，实现多用户、多目标、高维度、分布式、准全局优化调度决策。
- 3) 若干 AI/ML 架构能够很好地与无线网络拓扑、无线传输接入协议、无线资源约束、无线分布式数据特征相适配，从而有潜力建构新型无线智能网络架构；在此基础上进一步利用网络分布式算力和动态运力，自主适应无线网络分布式计算业务需求，实现网络高效资源利用、自主运行和智能服务。
- 4) 无线语义通信作为一种全新的智能通信架构，通过将用户对信息的需求和语义特征融入通信过程，有望显著提升通信效率、改进用户体验，解决基于比特的传统通信协议中存在的跨系统、跨协议、跨网络、跨人机不兼容和难互通等问题。
- 5) 无线数据隐藏结构特征复杂，跨时空分布式小样本问题突出，无线数据集的构建、访问、训练、迁移及其隐私安全保障将显著影响无线 AI 系统的架构设计和算法部署。

具体来说，无线 AI 可以实现多模块联合优化甚至端到端通信的整体优化；数据驱动的无线 AI 模型可有效地逼近与拟合任意复杂的输入输出关系，提取与处理隐含的特征；无线 AI（如强化学习）可在多种场景和情况下不断调整、演进、修复，基于无线 AI 的系统设计思路能更好的兼容未来的多种新型场景；无线通信系统中智能化设备越来越多，数据收集和处理能力也有了质的提升；此外，网络设备可以通过各类参考信号以及终端设备的反馈信息，非常方便地获得海量的无线环境数据；最后，可以通过通用

硬件实现多种功能的神经网络，并支持未来网络的平滑升级和替换，降低网络部署和维护的成本。

AI/ML 在物理层的应用已有大量的成功案例。本报告的第二章节讨论了 AI 在物理层的各个模块，包括无线环境建模与感知、信道估计预测及反馈、编译码、调制与波形技术等方面的现有研究成果。这些成果显示 AI 特别是深度学习由于其具有端到端优化的能力可以避免传统通信链路的模块化设计，同时由于其的非线性处理能力，带来了显著的性能提升。

AI 特别是强化学习，能够通过与环境的交互，学习环境特性，从而自适应地实现最优决策，已被广泛应用到无线链路层的资源分配与调度中。本报告的第三章节概述了 AI 在干扰链路调度、功率分配、信道分配、接入控制、频谱资源检测等方面的成功应用。这些成果显示，AI 技术，特别是深度强化学习，对复杂多变的网络环境和网络结构具有很好的适应性，能够以极低的计算成本智能地处理复杂系统的最优控制问题。

AI 在应用层和网络层的应用主要有两方面。一是用于预测、推理和大数据分析。在这一方面，本报告的第四章介绍了基于 AI 的拥堵控制技术、业务速率控制技术、需求预测与缓存技术等。二是通过在网络边缘及其各网元实体上内嵌 AI 功能来实现自组织网络操作。第四章也讨论了相关的无线分布式计算技术，包含移动边缘计算技术、AI/ML 模型分割技术、联邦学习等。这些边缘智能可以学习环境，并随着环境变化而改变策略，从而实现网络智能化。

通过上述讨论可以发现，AI/ML 方法已经被用于无线技术研究的多个方面，并且相较于传统算法获得显著的性能提升。AI 的一些技术与模型（如 CNN, RNN, DRL 等）与无线技术深度融合，尤其是与物理层/链路层空口技术的结合和后续发展值得重点关注。此外，如本报告的第五章节中所探讨的，如何获取和利用研究数据集是无线 AI 研究的关键和难点之一。

7.2 AI 赋能无线技术的产品成熟度

目前手机终端的嵌入式神经网络处理器（Neural-network processor unit, NPU）的处理能力与日俱增。在 2018 年以前，手机终端尚无专门的 NPU 模块，从 2018 年开始，手机终端的 NPU 处理能力每年都提升数倍。按照这个速度，2030 年手机终端的 NPU 处理能力将持续高速提升。

表 7-1 列出了一些典型的复杂神经网络的复杂度，以及这些神经网络占据目前典型芯片的 NPU 1 秒计算能力的比例。通过将现有手机 NPU 的处理能力与经典的神经网络的复杂度进行比较，可发现目前手机 NPU 处理能力已经非常强大。神经网络的复杂度一般以 OP 为单位计算，即一次实数乘法或一次实数加法为一个 OP。以 GoogleNet 为例，

它的复杂度为 2G OPs，但它只占据目前典型芯片的 NPU 1 秒计算能力的 $1.3\text{e-}4$ （即 1 秒可以计算 7500 次，或执行一次网络只需 0.13 毫秒）。

表7-1 典型的复杂神经网络的复杂度列表

	神经网络复杂度 (OPs)	神经网络占据目前典型芯片的 NPU 1 秒计算能力的比例
Inception V2	4.1G	$2.7\text{e-}4$
Inception V3	12G	$8.0\text{e-}4$
CaffeNet	724M	$4.8\text{e-}5$
GoogleNet	2G	$1.3\text{e-}4$
MobileNet	1.15G	$7.7\text{e-}5$

无线 AI 中使用的神经网络一般是轻量级神经网络，复杂度不高。因此，在手机终端上执行基于神经网络的运算已成为现实。随着手机终端 NPU 处理能力的快速增长，在手机上支持更复杂的无线 AI 成为可能。

7.3 AI 赋能无线技术的标准化和产业化影响

无线 AI 在感知、预测、定位、跟踪、反馈、调度、优化、调控等方面的应用潜力巨大，初步形成了未来标准化和产业化的基础，部分技术已在 R17、R18 中得到初步研究和讨论。

例如在数据获取和使用方面，无线 AI 中的数据获取和 AI 模型参数更新，可能需要通信标准定义相应的流程；基于终端和网络设备的部分功能实现，要从法律法规和隐私保护方面进行规范。3GPP 当前的标准讨论中，在核心网侧，增加了 NWDAF，用于进行数据收集和分析。并且在 RAN 工作组和 SA 工作组上分别设立了一个 SI(Study Item)，分别对数据采集和 AI/ML 模型传输进行研究，并讨论下一步标准化的可能，相关的进展情况可以参考 3GPP TR 37.817“Study on enhancement for data collection for NR and ENDC”和 TR22.874 “Study on traffic characteristics and performance requirements for AI/ML model transfer”。从标准化讨论进展来看，目前 3GPP 5G NR Release 18 已在 RAN 1 开启 AI 增强无线通信空口标准化讨论，相关评估和讨论结果将在研究报告 TR 38.843 中发布。Release 18 的 study item 通过对代表性用例（CSI 压缩，波束预测和定位增强）的讨论和性能评估，研究包括无线通信网络中不同 AI 阶段定义、基站与终端的合作、AI 模型生命周期管理、标准化潜在影响等课题。而关于 AI/ML 模型传输(AMMT)的讨论则进入到第二阶段，进一步增强 AI 服务作为 3GPP 的关键应用场景。按目前的计划，R18 的讨论结果将在 R19 进行更多用例讨论和标准化，R19+可能会进行 3GPP 框架内 AI 模型训练/交互、AI 物理层信号处理等研究。由于无线 AI 可以实现相关通信模块的联合优化，传统通信标准中所涉及的内部接口将被简化，相关的信令过程也会有一定的改变，信令、参考信号的开销也将会降低。同时，不同阶段的无线 AI 对标准化和产业

化的影响不同。在初始阶段，无线 AI 将会以辅助工具或优化方案来提升现有无线通信系统的性能，其标准化影响相对较小。随着无线 AI 技术的成熟和无线通信系统对 AI 的开放性和支持度提高，多个功能模块会逐渐被性能更好的无线 AI 模块所替代，其标准化影响将会更大。

7.4 AI 赋能无线技术未来研究工作展望

当前在学术界，通信领域无线 AI 相关研究论文和 workshop 研讨会的占比持续攀升；在工业界，主要的 6G 区域组织，如 欧洲 Hexa-X、北美 Next G、中国 IMT-2030 6G 推进组等，都将 AI 作为未来 6G 核心的使能技术和应用场景。同样我们也看到无线 AI 方向上的研究后续在理论，架构与技术研究 and 实现落地等三个层面也面临着一系列挑战，比如在基础理论层面，有一些关键的科学问题需要攻克，1) 如何通过理论指导找到适合无线通信系统的 AI 模型训练和部署方法，在通信、计算与存储的开销与性能中寻找最优；2) 如何科学地评价无线分布式学习算法的性能与收敛性，从理论上刻画无线 AI 模型学习能力的度量(如模型的容量)，并建立成体系的方法与理论，评估无线 AI 算法模型的收敛性、学习速率和训练代价，以及模型推演的性能极限和可靠性等问题。在系统架构与技术方案研究层面，也面临着诸如 1) 空口智能化与极致性能的最优化技术研究问题；2) 如何找到通信协议设计与实现的新思路与新方法；3) 如何找到解决系统中广泛存在的通信，计算与存储等资源开销的最优化利用的技术方案问题；4) 如何真正实现网络智能化自治的架构设计等问题。在最终的实现落地层面，也面临着如何解决 1) AI 运算所带来的高能耗与芯片能力局限问题，2) 如何在无线动态环境下导致的学习与训练方面的通信与计算资源开销问题以及 3) 在面对网络中大量存在的异构模型时如何找到通用的训练方法问题等挑战。

下一步的研究工作宜深入探索无线智能通信系统在数据和算力需求、AI 通信计算综合效能方面的极限理论，重点推进无线智能网络架构、无线智能空口、无线 AI 算法、无线 AI 数据集、无线语义通信等方面的标准化，着重解决如下核心难点：适用于无线的通用 AI 架构、数据和算力约束的高效无线 AI 算法，支撑 AI 算法高效部署的无线协议，以及无线 AI 性能(界限)的精准分析预测等等。

参考文献

- [1] Kermoal, Jean-Philippe, et al. "A stochastic MIMO radio channel model with experimental validation." *IEEE Journal on selected areas in Communications* 20.6 (2002): 1211-1226.
- [2] Hur, Sooyoung, et al. "Proposal on millimeter-wave channel modeling for 5G cellular system." *IEEE Journal of Selected Topics in Signal Processing* 10.3 (2016): 454-469.
- [3] Sternad, Mikael, and Daniel Aronsson. "Channel estimation and prediction for adaptive OFDM downlinks [vehicular applications]." 2003 IEEE 58th Vehicular Technology Conference. VTC 2003-Fall (IEEE Cat. No. 03CH37484). Vol. 2. IEEE, 2003.
- [4] Q. Bai, J. Wang, Y. Zhang and J. Song, "Deep Learning-Based Channel Estimation Algorithm Over Time Selective Fading Channels," in *IEEE Transactions on Cognitive Communications and Networking*, vol. 6, no. 1, pp. 125-134, March 2020.
- [5] Z. Xu and J. Sun, "Model-Driven Deep-Learning," *National Sci. Rev.*, vol. 5, no. 1, 2018, pp. 22–24.
- [6] H. T. He, S. Jin, C.-K. Wen, F. Gao, G. Y. Li, and Z. Xu, "Model-driven deep learning for physical layer communications", *IEEE Wireless Communications*, vol. 26, no. 5, pp. 77-83, Oct. 2019.
- [7] H. T. He, M. Zhang, S. Jin, C.-K. Wen and G. Y. Li, "Model-driven deep learning for massive MU-MIMO with finite-alphabet precoding," *IEEE Commun. Lett.*, vol. 24, no. 10, pp. 2216–2220, 2020.
- [8] Y. He, H. He, C.-K. Wen, and S. Jin, "Model-driven deep learning for massive multiuser MIMO constant envelope precoding," *IEEE Wireless Commun. Lett.*, vol. 9, no. 11, pp. 1835-1839, Nov. 2020.
- [9] W. Jiang and H. D. Schotten, "Recurrent neural network-based frequency-domain channel prediction for wideband communications," in *Proc. IEEE Veh. Technol. Conf. (VTC)*, Kuala Lumpur, Malaysia, Apr. 2019, pp. 1–6.
- [10] T. Ding and A. Hirose, "Fading channel prediction based on combination of complex-valued neural networks and chirpZ-transform," *IEEE Trans. Neural Netw. Learn. Syst.*, vol. 25, no. 9, pp. 1686–1695, Sep. 2014.
- [11] W. Jiang and H. D. Schotten, "Multi-antenna fading channel prediction empowered by artificial intelligence," in *Proc. IEEE Veh. Technol. Conf. (VTC)*, Chicago, IL, USA, Aug. 2018, pp. 1–6.
- [12] Y. Sui, W. Yu, and Q. Luo, "Jointly optimized extreme learning machine for short-term prediction of fading channel," *IEEE Access*, vol. 6, pp. 49029–49039, 2018.
- [13] J. Yuan, H. Q. Ngo, and M. Matthaiou, "Machine learning-based channel estimation in massive MIMO with channel aging," in *Proc. IEEE 20th Int. Workshop Signal Process. Adv. Wireless Commun. (SPAWC)*, Cannes, France, Jul. 2019, pp. 1–5.
- [14] M. Mehrabi, M. Mohammadkarimi, M. Ardakani, and Y. Jing, "Decision directed channel estimation based on deep neural network k-step predictor for MIMO communications in 5G," *IEEE J. Sel. Areas Commun.*, vol. 37, no. 11, pp. 2443–2456, Nov. 2019.
- [15] J. Wang, Y. Ding, S. Bian, Y. Peng, M. Liu, and G. Gui, "UL-CSI data driven deep learning for predicting DL-CSI in cellular FDD systems," *IEEE Access*, vol. 7, pp. 96105–96112, 2019.

- [16] M. Arnold, S. Dörner, S. Cammerer, S. Yan, J. Hoydis, and S. T.Brink, “Enabling FDD massive MIMO through deep learning-based channel prediction,” Jan. 2019. [Online]. Available: arXiv:1901.036.
- [17] W. Liu, L.-L. Yang, and L. Hanzo, “Recurrent neural network based narrowband channel prediction,” in Proc. IEEE 63rd Veh. Technol. Conf. (VTC), Melbourne, VIC, Australia, May 2006, pp. 2173–2177.
- [18] T. Ding and A. Hirose, “Fading channel prediction based on combination of complex-valued neural networks and chirp Z-transform,” IEEE Trans. Neural Netw. Learn. Syst., vol. 25, no. 9, pp. 1686–1695, Sep. 2014.
- [19] J. Yuan, H. Q. Ngo and M. Matthaiou, "Machine Learning-Based Channel Prediction in Massive MIMO With Channel Aging," in IEEE Transactions on Wireless Communications, vol. 19, no. 5, pp. 2960-2973, May 2020, doi: 10.1109/TWC.2020.2969627.
- [20] Luo, Changqing, et al. "Channel state information prediction for 5G wireless communications: A deep learning approach." IEEE Transactions on Network Science and Engineering (2018).
- [21] Sutskever, Ilya, Oriol Vinyals, and Quoc V. Le. "Sequence to sequence learning with neural networks." Advances in neural information processing systems. 2014.
- [22] Huangfu, Yourui, et al. "Predicting the mumble of wireless channel with sequence-to-sequence models." 2019 IEEE 30th Annual International Symposium on Personal, Indoor and Mobile Radio Communications (PIMRC). IEEE, 2019.
- [23] Huangfu, Yourui, et al. "Realistic Channel Models Pre-training." 2019 IEEE Globecom Workshops (GC Wkshps). IEEE, 2019.
- [24] T. Gruber, S. Cammerer, J. Hoydis, and S. t Brink, “On deep learning-based channel decoding,” in 2017 51st Annual Conference on Information Sciences and Systems (CISS), Mar. 2017.
- [25] He Y, Zhang J, Wen C K, et al. TurboNet: A model-driven DNN decoder based on max-log-MAP algorithm for turbo code[C]//2019 IEEE VTS Asia Pacific Wireless Communications Symposium (APWCS). IEEE, 2019: 1-5.
- [26] Y. He, J. Zhang, Shi Jin, C.-K. Wen, G. Y. Li, “Model-Driven DNN Decoder for Turbo Codes: Design, Simulation, and Experimental Results,” IEEE Trans. Commun., vol. 68, no. 10, pp. 6127–6140, Oct. 2020
- [27] Elkelesh A, Ebada M, Cammerer S, et al. Decoder-tailored polar code design using the genetic algorithm[J]. IEEE Transactions on Communications, 2019, 67(7): 4521-4534.
- [28] Nisioti E, Thomos N. Design of Capacity-Approaching Low-Density Parity-Check Codes using Recurrent Neural Networks[J]. arXiv preprint arXiv:2001.01249, 2020.
- [29] O’Shea T J, Corgan J, Clancy T C. Convolutional radio modulation recognition networks[C]//International conference on engineering applications of neural networks. Springer, Cham, 2016: 213-226
- [30] Shental O, Hoydis J. " Machine LLRning": Learning to Softly Demodulate[J]. arXiv preprint arXiv:1907.01512, 2019.
- [31] M. Stark, F. A. Aoudia, and J. Hoydis, “Joint Learning of Geometric and Probabilistic Constellation Shaping,” in 2019 IEEE Globecom Workshops (GC Wkshps), Dec. 2019.
- [32] R. T. Jones, T. A. Eriksson, M. P. Yankov, and D. Zibar, “Deep Learning of Geometric Shaping Including Fiber Nonlinearities,” in 2018 European Conference on Optical Communication (ECOC), Sep. 2018
- [33] C. Wen, et al, “Deep Learning for Massive MIMO CSI Feedback,” in IEEE WCL, vol. 7, no. 5, pp. 748-751, Oct. 2018

- [34] J. Joungh, "Machine Learning-Based Antenna Selection in Wireless Communications," *IEEE Communications Letters*, vol, 20, no, 11, pp. 2241-2244, Nov. 2016.
- [35] F. Sohrabi, H. V. Cheng, and W. Yu, "Robust Symbol-Level Precoding Via Autoencoder-Based Deep Learning," in *2020 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, May 2020.
- [36] H. He, C.-K. Wen, S. Jin, and G. Y. Li, "A Model-Driven Deep Learning Network for MIMO Detection," in *2018 IEEE Global Conference on Signal and Information Processing (GlobalSIP)*, Nov. 2018
- [37] J. R. Hershey, J. L. Roux, and F. Weninger, "Deep Unfolding: Model-Based Inspiration of Novel Deep Architectures," [Online] <https://arxiv.org/abs/1409.2574.pdf>, Nov. 2014
- [38] Z. Zhao, M. C. Vuran, F. Guo, and S. Scott, "Deep-Waveform: A Learned OFDM Receiver Based on Deep Complex Convolutional Networks," [Online] <https://arxiv.org/pdf/1810.07181.pdf>, Nov. 2018.
- [39] M. Kim, W. Lee, and D.-H. Cho, "A Novel PAPR Reduction Scheme for OFDM System Based on Deep Learning," *IEEE Communications Letters*, vol. 22, no. 3, pp. 510-513, Mar. 2018.
- [40] A. E. Gamal, Y-H. Kim. *Network information theory*[M]. Cambridge: Cambridge University Press, 2011.
- [41] H. Cui, C. Luo, C. W. Chen and F. Wu, "Robust uncoded video transmission over wireless fast fading channel," *IEEE INFOCOM 2014 - IEEE Conference on Computer Communications*, Toronto, ON, Canada, 2014, pp. 73-81.
- [42] S. Jakubczak and D. Katabi, "SoftCast: Clean-slate scalable wireless video," *2010 48th Annual Allerton Conference on Communication, Control, and Computing (Allerton)*, Monticello, IL, USA, 2010, pp. 530-533
- [43] Bourtsoulatze E, Kurka D B, Gündüz D. Deep joint source-channel coding for wireless image transmission[J]. *IEEE Transactions on Cognitive Communications and Networking*, 2019, 5(3): 567-579.
- [44] L. Huang, H. Zhang, R. Li, Y. Ge, and J. Wang, "AI Coding: Learning to Construct Error Correction Codes," *IEEE Transactions on Communications*, vol. 68, no. 1, pp. 26-39, Jan. 2020.
- [45] Huang, Lingchen, et al. "Reinforcement learning for nested polar code construction." *2019 IEEE Global Communications Conference (GLOBECOM)*. IEEE, 2019.
- [46] Wang, Jun, et al. "Artificial intelligence and wireless communications." *Frontiers of Information Technology & Electronic Engineering* (2020): 1-13.
- [47] R. Atallah, C. Assi, and M. Khabbaz, "Deep reinforcement learningbased scheduling for roadside communication networks," in *2017 15th International Symposium on Modeling and Optimization in Mobile, Ad Hoc, and Wireless Networks (WiOpt)*. IEEE, 2017, pp. 1–8.
- [48] S. Chinchali, P. Hu, T. Chu, M. Sharma, M. Bansal, R. Misra, M. Pavone, and S. Katti, "Cellular network traffic scheduling with deep reinforcement learning," in *Thirty-Second AAAI Conference on Artificial Intelligence*, 2018.
- [49] Y. Wei, Z. Zhang, F. R. Yu, and Z. Han, "Joint user scheduling and content caching strategy for mobile edge networks using deep reinforcement learning," in *2018 IEEE International Conference on Communications Workshops (ICC Workshops)*. IEEE, 2018, pp. 1–6.
- [50] M. Chu, H. Li, X. Liao, and S. Cui, "Reinforcement learning based multi-access control and battery prediction with energy harvesting in iot systems," *IEEE Internet of Things Journal*, 2018.

- [51] Zhang, Lin, and Ying-Chang Liang. "Deep Reinforcement Learning for Multi-Agent Non-Cooperative Power Control in Heterogeneous Networks." arXiv preprint arXiv:2004.12095 (2020).
- [52] Zhao, Nan, et al. "Deep reinforcement learning for user association and resource allocation in heterogeneous cellular networks." IEEE Transactions on Wireless Communications 18.11 (2019): 5141-5152.
- [53] Nasir, Yasar Sinan, and Dongning Guo. "Multi-agent deep reinforcement learning for dynamic power allocation in wireless networks." IEEE Journal on Selected Areas in Communications 37.10 (2019): 2239-2250.
- [54] Naderializadeh, Navid, et al. "Resource Management in Wireless Networks via Multi-Agent Deep Reinforcement Learning." arXiv preprint arXiv:2002.06215 (2020).
- [55] Wang, Jian, et al. "Deep reinforcement learning for scheduling in cellular networks." 2019 11th International Conference on Wireless Communications and Signal Processing (WCSP). IEEE, 2019.
- [56] Xu, Chen, et al. "Buffer-aware wireless scheduling based on deep reinforcement learning." 2020 IEEE Wireless Communications and Networking Conference (WCNC). IEEE, 2020.
- [57] H. Ye, G. Y. Li and B.-H. Juang, "Power of deep learning for channel estimation and signal detection in OFDM systems," IEEE Wireless Communications Letters, vol. 7, no. 1, pp. 114-117, February 2018.
- [58] D. Neumann, T. Wiese and W. Utschick, "Learning the MMSE channel estimator," IEEE Transactions on Signal Processing, vol.11, no. 66, pp. 2905-2917, June 2018.
- [59] X. Cheng, D. Liu, C. Wang, S. Yan and Z. Zhu, "Deep-learning based channel estimation and equalization scheme for FBMC/OQAM systems," in IEEE Wireless Communications Letters, 2019.
- [60] Y. Yang, F. Gao, X. Ma and S. Zhang, "Deep learning-based channel estimation for doubly selective fading channels," in IEEE Access, 2019.
- [61] A. Aboutaleb, W. Fatnassi, M. Soltani, and Z. Rezki, "Symbol detection and channel estimation using neural networks in optical communication systems," IEEE International Conference on Communications (ICC): Wireless Communications Symposium, 2019.
- [62] E. Balevi and J. G. Andrews, "Deep learning-based channel estimation for high-dimensional signals," preprint arXiv:1904.09346, 2019.
- [63] T.-H. Li, M. R. A. Khandaker, F. Tariq, K.-K. Wong and R. T. Khan, "Learning the wireless V2I channels using deep neural networks," preprint arXiv:1907.04831, 2019.
- [64] S. Han, Y. Oh and C. Song, "A deep learning based channel estimation scheme for IEEE 802.11p systems," in Proc. IEEE International Conference on Communications (ICC), 2019.
- [65] H. Mao, H. Lu, Y. Lu and D. Zhu, "RoemNet: Robust meta learning based channel estimation in OFDM systems," in Proc. IEEE International Conference on Communications (ICC), 2019.
- [66] E. Balevi, A. Doshi and J. G. Andrews, "Massive MIMO channel estimation with an untrained deep neural network," preprint arXiv:1908.00144, 2019.
- [67] S. Gao, P. Dong, Z. Pan and G. Y. Li, "Deep-learning based channel estimation for massive MIMO with mixed-resolution ADCs," preprint arXiv:1908.06245, 2019.
- [68] Q. Bai, J. Wang, Y. Zhang and J. Song, "Deep-learning based channel estimation algorithm over time selective fading channels," preprint arXiv:1908.11013, 2019.

- [69] Ö. T. Demir and E. Björnson, "Channel estimation in massive MIMO under hardware non-linearities: Bayesian methods versus deep learning," preprint arXiv:1911.07316, 2019.
- [70] M. B. Mashhadi, and D. Gündüz, "Deep learning for massive MIMO channel state acquisition and feedback," preprint arXiv:2002.06945, 2020.
- [71] X. Ma and Z. Gao, "Data-Driven Deep Learning to Design Pilot and Channel Estimator For Massive MIMO," IEEE Transactions on Vehicular Technology, vol. 69, no. 5, pp. 5677-5682, May 2020.
- [72] Foad Sohrabi, Kareem M. Attiah, Wei Yu, "Deep Learning for Distributed Channel Feedback and Multiuser Precoding in FDD Massive MIMO", arXiv:2007.06512
- [73] M. Soltani, V. Pourahmadi, and H. Sheikhzadeh, "Pilot Pattern Design for Deep Learning-Based Channel Estimation in OFDM Systems," preprint arXiv:2003.08980, 2020.
- [74] Y.-S. Jeon, J. Li, N. Tavangaran, and H. V. Poor, "Data-Aided Channel Estimator for MIMO Systems via Reinforcement Learning," preprint arXiv:2003.10084, 2020.
- [75] H. He, C. Wen, S. Jin and G. Y. Li, "Deep Learning-Based Channel Estimation for Beam-space mmWave Massive MIMO Systems," in IEEE Wireless Communications Letters, vol. 7, no. 5, pp. 852-855, Oct. 2018, doi: 10.1109/LWC.2018.2832128.
- [76] H. T. He, R. Wang, S. Jin, C.-K. Wen and G. Y. Li, "Beam-space channel estimation in Terahertz communications: A model-driven unsupervised learning approach," 2020, arXiv:2006.16628.
- [77] H. He, C.-K. Wen, S. Jin and G. Y. Li, "Model-driven deep learning for joint MIMO channel estimation and signal detection," preprint arXiv:1907.09439, 2019.
- [78] X. Ru, L. Wei, and Y. Xu, "Model-driven channel estimation for OFDM systems based on image super-resolution network," preprint arXiv:1911.13106, 2019.
- [79] Dong C, Loy C C, He K, et al. Image Super-Resolution Using Deep Convolutional Networks. IEEE Trans Pattern Anal Mach Intell, 2016, 38(2):295-307
- [80] Kai Z, Zuo W, Chen Y, et al. Beyond a Gaussian Denoiser: Residual Learning of Deep CNN for Image Denoising. IEEE Transactions on Image Processing, 2016, 26(7):3142-3155.
- [81] W. Jiang and H. D. Schotten, "Neural Network-Based Channel Prediction and Its Performance in Multi-Antenna Systems," in 2018 IEEE 88th Vehicular Technology Conference (VTC-Fall), Aug. 2018, pp. 1–6, doi: 10.1109/VTCFall.2018.8690590.
- [82] W. Jiang and H. D. Schotten, "Recurrent Neural Network-Based Frequency-Domain Channel Prediction for Wideband Communications," in 2019 IEEE 89th Vehicular Technology Conference (VTC2019-Spring), Apr. 2019, pp. 1–6, doi: 10.1109/VTCSpring.2019.8746352.
- [83] J. Ahrens, L. Ahrens and H. D. Schotten, "A machine learning method for prediction of multipath channels," preprint arXiv:1909.04824, 2019.
- [84] Y. Yang, F. Gao, Z. Zhong, B. Ai, and A. Alkhateeb, "Deep transfer learning based downlink channel prediction for FDD massive MIMO systems," preprint arXiv:1912.12265, 2019.
- [85] Y. Wang, X. Chen, H. Yin, and W. Wang, "Learnable sparse transformation based massive MIMO CSI recovery network," IEEE Commun. Lett., vol. 24, no. 7, pp. 1468-1471, Jul. 2020.
- [86] M. Safari and V., "Deep UL2DL: Channel knowledge transfer from uplink to downlink," preprint arXiv:1812.07518, 2018.

- [87] M. Alrabeiah and A. Alkhateeb, "Deep learning for TDD and FDD massive MIMO: Mapping channels in space and frequency," preprint arXiv:1905.03761, 2019.
- [88] F. Gao, 'title to be updated by Feifei Gao'
- [89] Z. Xiao, Z. Zhang, Z. Chen, Z. Yang and R. Jin, "Mobile MIMO Channel Prediction with ODE-RNN: a Physics-Inspired Adaptive Approach," accepted by 2022 IEEE 33rd Annual International Symposium on Personal, Indoor and Mobile Radio Communications (PIMRC).
- [90] Z. Xiao, Z. Zhang, C. Huang, X. Chen, C. Zhong, and M. Debbah, "C-GRBFnet: A Physics-Inspired Generative Deep Neural Network for Channel Representation and Prediction," in IEEE Journal on Selected Areas in Communications (IF=13.081), 2022, doi: 10.1109/JSAC.2022.3180800.
- [91] C. K. Wen, W. T. Shih, and S. Jin, "Deep learning for massive MIMO CSI feedback," IEEE Wireless Commun. Lett., vol. 7, no. 5, pp. 748-751, Oct. 2018
- [92] T. Wang, C. Wen, S. Jin and G. Y. Li, "Deep learning-based CSI feedback approach for time-varying massive MIMO channels," IEEE Wireless Commun. Lett., vol. 8, no. 2, pp. 416-419, Apr. 2019.
- [93] J. Guo, C. Wen, S. Jin, and G. Y. Li, "Convolutional neural network- based multiple-rate compressive sensing for massive MIMO CSI feed- back: Design, simulation, and analysis," IEEE Trans. Wireless Commun., vol. 19, no. 4, pp. 2827–2840, 2020.
- [94] J. Guo, C. Wen, S. Jin, "Deep Learning-Based CSI Feedback for Beamforming in Single-and Multi-cell Massive MIMO Systems," IEEE Journal on Selected Areas in Communications, 2021.
- [95] Z. Chen, Z. Zhang and Z. Xiao, "Viewing the MIMO Channel as Sequence Rather than Image: A Seq2Seq Approach for Efficient CSI Feedback," 2022 IEEE Wireless Communications and Networking Conference (WCNC), 2022, pp. 2292-2297, doi: 10.1109/WCNC51071.2022.9771730.
- [96] Y. Jiang, H. Kim, H. Asnani, S. Kannan, S. Oh, and P. Viswanath, "Turbo autoencoder: Deep learning based channel codes for point-to-point communication channels," arXiv preprint arXiv: 1911.03038v1, 2019.
- [97] T. O'Shea and J. Hoydis, "An introduction to deep learning for the physical layer," IEEE Trans. Cog. Commun. Netw., vol. 3, no. 4, pp. 563–575, 2017.
- [98] S. D'orner, S. Cammerer, J. Hoydis, and S. T. Brink, "Deep learning based communication over the air," IEEE J. Sel. Topics Signal Process., vol. 12, no. 1, pp. 132–143, Feb. 2018.
- [99] F. Ait Aoudia and J. Hoydis, "Trimming the Fat from OFDM: Pilot- and CP-less Communication with End-to-end Learning," *arXiv:2101.08213v3*, Apr. 2021.
- [100] E. Arikan, "Channel Polarization: A Method for Constructing Capacity-Achieving Codes for Symmetric Binary-Input Memoryless Channels," in IEEE Transactions on Information Theory, vol. 55, no. 7, pp. 3051-3073, July 2009.
- [101] E. Nachmani, Y. Be'ery and D. Burshtein, "Learning to decode linear codes using deep learning," 2016 54th Annual Allerton Conference on Communication, Control, and Computing (Allerton), Monticello, IL, 2016, pp. 341-346.
- [102] J. Zhang, Y. Huang, Y. Zhou, and X. You, "Beam alignment and tracking for millimeter wave communications via bandit learning," IEEE Trans. Commun., vol. 68, no. 9, pp. 5519-5533, 2020.
- [103] J. Zhang, Y. Huang, Q. Shi, J. Wang, and L. Yang, "Codebook design for beam alignment in millimeter wave communication systems," IEEE Trans. Commun., vol. 65, no. 11, pp. 4980–4995, Nov 2017.

- [104] J. Zhang, Y. Huang, J. Wang, X. You, and C. Masouros, "Intelligent interactive beam training for millimeter wave communications," *IEEE Trans. Wireless Commun.*, pp. 1-1, 2020.
- [105] J. Zhang, Y. Huang, J. Wang, and X. You, "Intelligent beam training for millimeter-wave communications via deep reinforcement learning," in 2019 IEEE GLOBECOM, Dec 2019, pp. 1–7.
- [106] J. Zhang, Y. Huang, J. Wang, X. You, and C. Masouros, "Intelligent interactive beam training for millimeter wave communications," *IEEE Trans. Wireless Commun.*, pp. 1–1, 2020.
- [107] E. Nachmani, E. Marciano, L. Lugosch, W. J. Gross, D. Burshtein and Y. Be'ery, "Deep Learning Methods for Improved Decoding of Linear Codes," in *IEEE Journal of Selected Topics in Signal Processing*, vol. 12, no. 1, pp. 119-131, Feb. 2018.
- [108] Y. Huang, Z. Zhang, J. Che, Z. Yang, Q. Yang, and W. Kai-Kit "Self-Attention Reinforcement Learning for Multi-Beam Combining in mmWave 3D-MIMO Systems," *Sci. China. Inf. Sci. (SCIS)*, to appear, 2022.
- [109] S. Cammerer, T. Gruber, J. Hoydis and S. ten Brink, "Scaling Deep Learning-Based Decoding of Polar Codes via Partitioning," *GLOBECOM 2017 - 2017 IEEE Global Communications Conference*, Singapore, 2017, pp. 1-6.
- [110] F. Liang, C. Shen and F. Wu, "An Iterative BP-CNN Architecture for Channel Decoding," in *IEEE Journal of Selected Topics in Signal Processing*, vol. 12, no. 1, pp. 144-159, Feb. 2018.
- [111] J. Wang, Y. Ding, S. Bian, Y. Peng, M. Liu, and G. Gui, "UL-CSI datadriven deep learning for predicting DL-CSI in cellular FDD systems," *IEEE Access*, vol. 7, pp. 96105–96112, 2019.
- [112] C. Chen, C. Teng and A. A. Wu, "Low-Complexity LSTM-Assisted Bit-Flipping Algorithm For Successive Cancellation List Polar Decoder," *ICASSP 2020 - 2020 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, Barcelona, Spain, 2020, pp. 1708-1712.
- [113] H. Huang, Y. Song, J. Yang, G. Gui and F. Adachi, "Deep-Learning-Based Millimeter-Wave Massive MIMO for Hybrid Precoding," in *IEEE Transactions on Vehicular Technology*, vol. 68, no. 3, pp. 3027-3032, March 2019.
- [114] T. Lin and Y. Zhu, "Beamforming design for large-scale antenna arrays using deep learning," *IEEE Wireless Commun. Lett.*, vol. 9, no. 1, pp. 103–107, Jan. 2020.
- [115] A. Alkhateeb, S. P. Alex, P. Varkey, Y. Li, Q. Z. Qu, and D. Tujkovic, "Deep learning coordinated beamforming for highly-mobile millimeter wave systems," *IEEE Access*, vol. 6, pp. 37328–37348, Jun. 2018.
- [116] M. Elbir, "CNN-based precoder and combiner design in mmWave MIMO systems," *IEEE Commun. Lett.*, vol. 23, no. 7, pp. 1240–1243, Jul. 2019.
- [117] M. Elbir and K. V. Mishra, "Joint antenna selection and hybrid beamformer design using unquantized and quantized deep learning networks," *arXiv:1905.03107*, May 2019.
- [118] M. Elbir and A. K. Papazafeiropoulos, "Hybrid Precoding for Multiuser Millimeter Wave Massive MIMO Systems: A Deep Learning Approach," in *IEEE Transactions on Vehicular Technology*, vol. 69, no. 1, pp. 552-563, Jan. 2020.
- [119] X. Li and A. Alkhateeb, "Deep Learning for Direct Hybrid Precoding in Millimeter Wave Massive MIMO Systems," *2019 53rd Asilomar Conference on Signals, Systems, and Computers*, Pacific Grove, CA, USA, 2019, pp. 800-805.

- [120] Chen, Wei, et al. "Solving Sparse Linear Inverse Problems in Communication Systems: A Deep Learning Approach With Adaptive Depth." *IEEE Journal on Selected Areas in Communications*, 2021.
- [121] X. Gao, L. Dai, Y. Zhang, T. Xie, X. Dai and Z. Wang, "Fast Channel Tracking for Terahertz Beam-space Massive MIMO Systems," in *IEEE Transactions on Vehicular Technology*, vol. 66, no. 7, pp. 5689-5696, July 2017.
- [122] A. Alkhateeb, S. Alex, P. Varkey, Y. Li, Q. Qu, and D. Tujkovic, "Deep learning coordinated beamforming for highly-mobile millimeter wave systems," *IEEE Access*, vol. 6, pp. 37 328–37 348, 2018.
- [123] V. Va, J. Choi, T. Shimizu, G. Bansal, and R. W. Heath, "Inverse multipath fingerprinting for millimeter wave V2I beam alignment," *IEEE Trans. Veh. Technol.*, vol. 67, no. 5, pp. 4042–4058, May 2018.
- [124] J. C. Aviles and A. Kouki, "Position-aided mm-wave beam training under nlos conditions," *IEEE Access*, vol. 4, pp. 8703–8714, 2016.
- [125] J. Zhang, Y. Huang, Y. Zhou, and X. You, "Beam Alignment and Tracking for Millimeter Wave Communications via Bandit Learning," *IEEE Transactions on Communications*, Apr. 2020.
- [126] G. Gui, H. Huang, Y. Song and H. Sari, "Deep Learning for an Effective Nonorthogonal Multiple Access Scheme," in *IEEE Transactions on Vehicular Technology*, vol. 67, no. 9, pp. 8440-8450, Sept. 2018, doi: 10.1109/TVT.2018.2848294.
- [127] Z. Zhang, Y. Li, C. Huang, Q. Guo, C. Yuen and Y. L. Guan, "DNN-Aided Block Sparse Bayesian Learning for User Activity Detection and Channel Estimation in Grant-Free Non-Orthogonal Random Access," in *IEEE Transactions on Vehicular Technology*, vol. 68, no. 12, pp. 12000-12012, Dec. 2019, doi: 10.1109/TVT.2019.2947214.
- [128] W. Kim, Y. Ahn and B. Shim, "Deep Neural Network-Based Active User Detection for Grant-Free NOMA Systems," in *IEEE Transactions on Communications*, vol. 68, no. 4, pp. 2143-2155, April 2020, doi: 10.1109/TCOMM.2020.2969184.
- [129] W. Kim, G. Lim, Y. Ahn and B. Shim, "Active User Detection of Machine-Type Communications via Dimension Spreading Neural Network," *ICC 2019 - 2019 IEEE International Conference on Communications (ICC)*, Shanghai, China, 2019, pp. 1-6, doi: 10.1109/ICC.2019.8761407.
- [130] G. I. Kechriotis and E. S. Manolakos, "Hopfield neural network implementation of the optimal CDMA multiuser detector," in *IEEE Transactions on Neural Networks*, vol. 7, no. 1, pp. 131-141, Jan. 1996, doi: 10.1109/72.478397.
- [131] N. Samuel, T. Diskin and A. Wiesel, "Deep MIMO detection," 2017 IEEE 18th International Workshop on Signal Processing Advances in Wireless Communications (SPAWC), Sapporo, 2017, pp. 1-5, doi: 10.1109/SPAWC.2017.8227772.
- [132] N. Samuel, T. Diskin and A. Wiesel, "Learning to Detect," in *IEEE Transactions on Signal Processing*, vol. 67, no. 10, pp. 2554-2564, 15 May 2019, doi: 10.1109/TSP.2019.2899805.
- [133] Tan, Xiaosi, et al. "Improving massive MIMO belief propagation detector with deep neural network." *arXiv preprint arXiv:1804.01002* (2018).
- [134] He H, Wen C K, Jin S, et al. A model-driven deep learning network for MIMO detection[C]//2018 IEEE Global Conference on Signal and Information Processing (GlobalSIP). IEEE, 2018: 584-588.
- [135] Bai Y, Ai B, Chen W. Deep learning based fast multiuser detection for massive machine-type communication[C]//2019 IEEE 90th Vehicular Technology Conference (VTC2019-Fall). IEEE, 2019: 1-5.

- [136] Khani, Mehrdad, et al. "Adaptive neural signal detection for massive MIMO." *IEEE Transactions on Wireless Communications* (2020).
- [137] Zhang C. Deep Learning Based Multi-user Interference Cancellation Technology[J]. *Science Discovery*, 2019, 7(6).
- [138] Q. Zhang, M. Lin, L. T. Yang, Z. Chen and P. Li, "Energy-Efficient Scheduling for Real-Time Systems Based on Deep Q-Learning Model," in *IEEE Transactions on Sustainable Computing*, vol. 4, no. 1, pp. 132-141, 1 Jan.-March 2019, doi: 10.1109/TSUSC.2017.2743704.
- [139] Atallah, Ribal et al. "Deep reinforcement learning-based scheduling for roadside communication networks." 2017 15th International Symposium on Modeling and Optimization in Mobile, Ad Hoc, and Wireless Networks (WiOpt) (2017): 1-8.
- [140] Haoran Sun, Xiangyi Chen, Qingjiang Shi, Mingyi Hong, Xiao Fu, and Nikos D Sidiropoulos. Learning to optimize: Training deep neural networks for wireless resource management. In *Proc. 18th IEEE International Workshop on Signal Processing Advances in Wireless Communications (SPAWC)*, pages 1–6, 2017.
- [141] Zhiyuan Xu, Yanzhi Wang, Jian Tang, Jing Wang, and Mustafa Cenk Gursoy. A deep reinforcement learning based framework for power efficient resource allocation in cloud RANs. In *Proc. 2017 IEEE International Conference on Communications (ICC)*, pages 1–6.
- [142] Zhi Zhou, Xu Chen, En Li, Liekang Zeng, Ke Luo, and Junshan Zhang. "Edge Intelligence: Paving the Last Mile of Artificial Intelligence With Edge Computing", *Proceedings of the IEEE (PIEEE)*, Vol. 107, No. 8, pp.1738 – 1762, Aug. 2019.
- [143] C. Pandana and K. J. R. Liu, "Near-optimal reinforcement learning framework for energy-aware sensor communications," in *IEEE Journal on Selected Areas in Communications*, vol. 23, no. 4, pp. 788-797, April 2005, doi: 10.1109/JSAC.2005.843547.
- [144] G. Naddafzadeh-Shirazi, P. Kong and C. Tham, "Distributed Reinforcement Learning Frameworks for Cooperative Retransmission in Wireless Networks," in *IEEE Transactions on Vehicular Technology*, vol. 59, no. 8, pp. 4157-4162, Oct. 2010, doi: 10.1109/TVT.2010.2059055.
- [145] N. Mastronarde and M. van der Schaar, "Fast Reinforcement Learning for Energy-Efficient Wireless Communication," in *IEEE Transactions on Signal Processing*, vol. 59, no. 12, pp. 6262-6266, Dec. 2011, doi: 10.1109/TSP.2011.2165211.
- [146] L. Liang, H. Ye and G. Y. Li, "Spectrum Sharing in Vehicular Networks Based on Multi-Agent Reinforcement Learning," in *IEEE Journal on Selected Areas in Communications*, vol. 37, no. 10, pp. 2282-2292, Oct. 2019, doi: 10.1109/JSAC.2019.2933962.
- [147] S. Maghsudi and S. Stańczak, "Hybrid Centralized–Distributed Resource Allocation for Device-to-Device Communication Underlying Cellular Networks," in *IEEE Transactions on Vehicular Technology*, vol. 65, no. 4, pp. 2481-2495, April 2016, doi: 10.1109/TVT.2015.2423691.
- [148] Y. Wei, F. R. Yu, M. Song and Z. Han, "User Scheduling and Resource Allocation in HetNets With Hybrid Energy Supply: An Actor-Critic Reinforcement Learning Approach," in *IEEE Transactions on Wireless Communications*, vol. 17, no. 1, pp. 680-692, Jan. 2018.
- [149] L. Xiao, Y. Li, C. Dai, H. Dai and H. V. Poor, "Reinforcement Learning-Based NOMA Power Allocation in the Presence of Smart Jamming," in *IEEE Transactions on Vehicular Technology*, vol. 67, no. 4, pp. 3377-3389, April 2018.

- [150] W. Cui, K. Shen and W. Yu, "Spatial Deep Learning for Wireless Scheduling," 2018 IEEE Global Communications Conference (GLOBECOM), Abu Dhabi, United Arab Emirates, 2018, pp. 1-6, doi: 10.1109/GLOCOM.2018.8647453.
- [151] C. Fan, B. Li, C. Zhao, W. Guo and Y. Liang, "Learning-Based Spectrum Sharing and Spatial Reuse in mm-Wave Ultradense Networks," in IEEE Transactions on Vehicular Technology, vol. 67, no. 6, pp. 4954-4968, June 2018.
- [152] M. Chen, W. Saad and C. Yin, "Echo State Networks for Self-Organizing Resource Allocation in LTE-U With Uplink–Downlink Decoupling," in IEEE Transactions on Wireless Communications, vol. 16, no. 1, pp. 3-16, Jan. 2017.
- [153] S. Wang, H. Liu, P. H. Gomes and B. Krishnamachari, "Deep Reinforcement Learning for Dynamic Multichannel Access in Wireless Networks," in IEEE Transactions on Cognitive Communications and Networking, vol. 4, no. 2, pp. 257-265, June 2018.
- [154] J. Zhu, Y. Song, D. Jiang and H. Song, "A New Deep-Q-Learning-Based Transmission Scheduling Mechanism for the Cognitive Internet of Things," in IEEE Internet of Things Journal, vol. 5, no. 4, pp. 2375-2385, Aug. 2018.
- [155] Y. S. Nasir and D. Guo, "Multi-Agent Deep Reinforcement Learning for Dynamic Power Allocation in Wireless Networks," in IEEE Journal on Selected Areas in Communications, vol. 37, no. 10, pp. 2239-2250, Oct. 2019.
- [156] G. Alnwaimi, S. Vahid and K. Moessner, "Dynamic Heterogeneous Learning Games for Opportunistic Access in LTE-Based Macro/Femtocell Deployments," in IEEE Transactions on Wireless Communications, vol. 14, no. 4, pp. 2294-2308, April 2015.
- [157] L. Wang, Y. Chao, S. Cheng and Z. Han, "An Integrated Affinity Propagation and Machine Learning Approach for Interference Management in Drone Base Stations," in IEEE Transactions on Cognitive Communications and Networking, vol. 6, no. 1, pp. 83-94, March 2020.
- [158] Barcelo J, Bellalta B, Cano C, et al. Learning-BEB: Avoiding Collisions in WLANs[J]. Carrier Sense Multiple Access with Enhanced Collision Avoidance, 2009: 23.
- [159] K. W. Choi and E. Hossain, "Opportunistic Access to Spectrum Holes Between Packet Bursts: A Learning-Based Approach," in IEEE Transactions on Wireless Communications, vol. 10, no. 8, pp. 2497-2509, August 2011.
- [160] Yibo Zhu, Hagga Eran, Daniel Firestone, Chuanxiong Guo, Marina Lipshteyn, Yehonatan Liron, Jitendra Padhye, Shachar Raindel, Mohamad Haj Yahia, and Ming Zhang. Congestion Control for Large-Scale RDMA Deployments. In SIGCOMM, 2015.
- [161] Zhang L , Wang M , Yang Z , et al. Machine Learning for Internet Congestion Control: Techniques and Challenges[J]. IEEE Internet Computing, 2019, 23(5):59-64.
- [162] Hongzi Mao, Ravi Netravali, and Mohammad Alizadeh. Neural Adaptive Video Streaming with Pensieve, 2017, SIGCOMM '17. ACM, New York, NY, USA, 197-210.
- [163] Qi Chen, Wei Wang, F. Richard Yu, Meixia Tao, Zhaoyang Zhang, "Content Caching Oriented Popularity Prediction: A Weighted Clustering Approach," IEEE Transactions on Wireless Communications, early access.
- [164] N. Jay, N. Rotman, B. Godfrey, M. Schapira, and A. Tamar, "A deep reinforcement learning perspective on Internet congestion control," in Proc. 36th Int. Conf. Mach. Learn., 2019, vol. 97, pp. 3050–3059.
- [165] Letaief K. B., Chen W., Shi Y., et al. "The roadmap to 6G: AI empowered wireless networks." IEEE Communications Magazine 57.8 (2019): 84-90.
- [166] S. M. S. Tanzil, W. Hoiles and V. Krishnamurthy, "Adaptive Scheme for Caching YouTube Content in a Cellular Network: Machine Learning Approach," in IEEE Access, vol. 5, pp. 5870-5881, 2017, doi: 10.1109/ACCESS.2017.2678990.

- [167] Y. Jiang, M. Ma, M. Bennis, F. Zheng and X. You, "User Preference Learning-Based Edge Caching for Fog Radio Access Network," in *IEEE Transactions on Communications*, vol. 67, no. 2, pp. 1268-1283, Feb. 2019, doi: 10.1109/TCOMM.2018.2880482.
- [168] Qi Chen, Wei Wang, Wei Chen, F. Richard Yu, Zhaoyang Zhang, "Cache-Enabled Multicast Content Pushing with Structured Deep Learning," *IEEE Journal of Selected Areas in Communications*, submitted.
- [169] P. Cheng et al., "Localized Small Cell Caching: A Machine Learning Approach Based on Rating Data," in *IEEE Transactions on Communications*, vol. 67, no. 2, pp. 1663-1676, Feb. 2019, doi: 10.1109/TCOMM.2018.2878231.
- [170] Juan Wen, Min Sheng, Jiandong Li, and Kaibin Huang, "Assisting Intelligent Wireless Networks with Traffic Prediction: Exploring and Exploiting Predictive Causality in Wireless Traffic," *IEEE Commun. Mag.*, vol. 58, no. 6, June 2020, pp 26-31
- [171] Z. Yang, Y. Liu, Y. Chen and L. Jiao, "Learning Automata Based Q-Learning for Content Placement in Cooperative Caching," in *IEEE Transactions on Communications*, vol. 68, no. 6, pp. 3667-3680, June 2020, doi: 10.1109/TCOMM.2020.2982136.
- [172] L. Ale, N. Zhang, H. Wu, D. Chen and T. Han, "Online Proactive Caching in Mobile Edge Computing Using Bidirectional Deep Recurrent Neural Network," in *IEEE Internet of Things Journal*, vol. 6, no. 3, pp. 5520-5530, June 2019, doi: 10.1109/JIOT.2019.2903245.
- [173] W. Chen and H. V. Poor, "Content Pushing With Request Delay Information," in *IEEE Transactions on Communications*, vol. 65, no. 3, pp. 1146-1161, March 2017, doi: 10.1109/TCOMM.2017.2648800.
- [174] Y. Lu, W. Chen and H. V. Poor, "Coded Joint Pushing and Caching With Asynchronous User Requests," in *IEEE Journal on Selected Areas in Communications*, vol. 36, no. 8, pp. 1843-1856, Aug. 2018, doi: 10.1109/JSAC.2018.2844918.
- [175] W. Chen and H. V. Poor, "Caching With Time Domain Buffer Sharing," in *IEEE Transactions on Communications*, vol. 67, no. 4, pp. 2730-2745, April 2019, doi: 10.1109/TCOMM.2018.2884973.
- [176] H. Hui, W. Chen and L. Wang, "Caching with Finite Buffer and Request Delay Information: A Markov Decision Process Approach," in *IEEE Transactions on Wireless Communications*, doi: 10.1109/TWC.2020.2989513.
- [177] C. Jiang, H. Zhang, Y. Ren, Z. Han, K. Chen and L. Hanzo, "Machine Learning Paradigms for Next-Generation Wireless Networks," *IEEE Wireless Communications*, vol. 24, no. 2, pp. 98-105, April 2017.
- [178] N. C. Luong, D. T. Hoang, S. Gong, D. Niyato, P. Wang, Y. Liang and D. I. Kim, "Applications of Deep Reinforcement Learning in Communications and Networking: A Survey," *IEEE Communications Surveys & Tutorials*, vol. 21, no. 4, pp. 3133-3174, May 2019.
- [179] N. Zhao, Y. Liang, D. Niyato, Y. Pei, M. Wu and Y. Jiang, "Deep Reinforcement Learning for User Association and Resource Allocation in Heterogeneous Cellular Networks," *IEEE Transactions on Wireless Communications*, vol. 18, no. 11, pp. 5141-5152, Nov. 2019
- [180] H. Ye, G. Y. Li and B. F. Juang, "Deep Reinforcement Learning Based Resource Allocation for V2V Communications," *IEEE Transactions on Vehicular Technology*, vol. 68, no. 4, pp. 3163-3173, April 2019.
- [181] A. Zappone, E. Björnson, L. Sanguinetti, and E. Jorswieck, "Globally optimal energy-efficient power control and receiver design in wireless networks," *IEEE Transactions on Signal Processing*, vol. 65, no. 11, pp. 2844-2859, Jun. 2017.

- [182] J. Hu, H. Zhang, L. Song, Z. Han and H. V. Poor, "Reinforcement Learning for a Cellular Internet of UAVs: Protocol Design, Trajectory Control, and Resource Management," *IEEE Wireless Communications*, vol. 27, no. 1, pp. 116-123, Feb. 2020
- [183] M. Chu, H. Li, X. Liao and S. Cui, "Reinforcement Learning-Based Multiaccess Control and Battery Prediction with Energy Harvesting in IoT Systems," *IEEE Internet of Things Journal*, vol. 6, no. 2, pp. 2009-2020, April 2019
- [184] H. Wang, Y. Wu, G. Min, J. Xu and P. Tang, "Data-driven dynamic resource scheduling for network slicing: A deep reinforcement learning approach," *Information Sciences*, vol. 498, pp. 106-116, Sept. 2019.
- [185] J. Perolat, JZ. Leibo, V. Zambaldi, C. Beattie, K. Tuyls and T. Graepel, "A Multi-Agent Reinforcement Learning Model of Common-Pool Resource Appropriation, " in *Proc. Advances in Neural Information Processing Systems*, 2017, pp. 3643-3652.
- [186] H. Sun, X. Chen, Q. Shi, M. Hong, X. Fu and N. D. Sidiropoulos, "Learning to Optimize: Training Deep Neural Networks for Interference Management," *IEEE Transactions on Signal Processing*, vol. 66, no. 20, pp. 5438-5453, Oct. 2018.
- [187] J. Liu, H. Dai and W. Chen, "Delay Optimal Scheduling for Energy Harvesting Based Communications, " *IEEE Journal on Selected Areas in Communications*, vol. 33, no. 3, pp. 452-466, Mar. 2015.
- [188] M. Wang, J. Liu, W. Chen, and A. Ephremides, "Joint Queue-Aware and Channel-Aware Delay Optimal Scheduling of Arbitrarily Bursty Traffic over Multi-State Time-Varying Channels," *IEEE Transactions on Communications*, vol. 67, no. 1, pp. 503-517, Jan. 2019.
- [189] X. Zhao and W. Chen, "Non-Orthogonal Multiple Access for Delay-Sensitive Communications: A Cross-Layer Approach," *IEEE Transactions on Communications*, vol. 67, no. 7, pp. 5053-5068, July 2019.
- [190] Danni Guo, Wei Wang, Qi Chen, Nan Zhao, and Zhaoyang Zhang, "Queue-Stable Dynamic Compression and Transmission with Mobile Edge Computing," *IEEE International Conference on Communications (ICC 2019)*, May 2019.
- [191] Yang K., Jiang T., Shi Y., et al. Federated learning via over-the-air computation[J]. *IEEE Transactions on Wireless Communications*, 2020, 19(3): 2022-2035.
- [192] Chen M., Yang Z., Saad W., et al. A joint learning and communications framework for federated learning over wireless networks[J]. *arXiv preprint arXiv:1909.07972*, 2019.
- [193] Chen M., Poor H. V., Saad W., et al. Convergence time optimization for federated learning over wireless networks[J]. *arXiv preprint arXiv:2001.07845*, 2020.
- [194] S. Luo, X. Chen, Q. Wu, Z. Zhou and S. Yu. "HFEL: Joint Edge Association and Resource Allocation for Cost-Efficient Hierarchical Federated Edge Learning", *IEEE Transactions on Wireless Communications*, Vol. 19, No. 10, pp. 6535 – 6548, 2020.
- [195] Wang S., Tuor T., Salonidis T., et al. Adaptive federated learning in resource constrained edge computing systems[J]. *IEEE Journal on Selected Areas in Communications*, 2019, 37(6): 1205-1221.
- [196] Yang Y., Zhang Z., and Yang Z. Over-the-Air Split Learning with MIMO-Based Neural Network and Constellation-Based Activation, to appear in 32nd IEEE Workshop on Machine Learning for Signal Processing (MLSP 2022), Xi'an, China, Aug. 2022.
- [197] S. Zheng, C. Shen, and X. Chen, "Design and Analysis of Uplink and Downlink Communications for Federated Learning," *IEEE Journal on Selected Areas in Communications*, vol. 39, no. 7, pp. 2150-2167, Dec. 2020, doi: 10.1109/JSAC.2020.3041388.

- [198] Y. Tian, Z. Zhang, Z. Yang and R. Jin, " Hierarchical Federated Learning with Adaptive Clustering on Non-IID Data Distribution," 2022 IEEE Global Communications Conference, pp 1-6, 2022.
- [199] Yang Z., Chen M., Saad W., et al. Delay Minimization for Federated Learning Over Wireless Communication Networks[J]. arXiv preprint arXiv:2007.03462, 2020.
- [200] Li T., Sahu A. K., Talwalkar A., et al. Federated learning: Challenges, methods, and future directions[J]. IEEE Signal Processing Magazine, 2020, 37(3): 50-60.
- [201] Yang Z., Chen M., Saad W., et al. Energy efficient federated learning over wireless communication networks[J]. arXiv preprint arXiv:1911.02417, 2019.
- [202] Hosseinalipour S., Brinton C. G., Aggarwal V., et al. From Federated Learning to Fog Learning: Towards Large-Scale Distributed Machine Learning in Heterogeneous Wireless Networks[J]. arXiv preprint arXiv:2006.03594, 2020.
- [203] Han D, Chen W, Bai B, et al. Offloading optimization and bottleneck analysis for mobile cloud computing. IEEE Transactions on Communications, 2019, 67(9):6153-6167.
- [204] Fa Rsad N, Rao M , Goldsmith A . Deep Learning for Joint Source-Channel Coding of Text, in Proc. IEEE Int'l. Conf. Acoustics Speech Signal Process. (ICASSP'18), Calgary, AB, Canada, 2018: 2326–2330.
- [205] Bourtsoulatze E, Kurka D B , Gunduz D . Deep Joint Source-Channel Coding for Wireless Image Transmission, in Proc. IEEE Int'l. Conf. Acoustics Speech Signal Process. (ICASSP'18), Calgary, AB, Canada, 2018: 4774-4778.
- [206] Shi, G., Gao, D., Song, X., Chai, J., Yang, M., Xie, X., Li, L., & Li, X. A new communication paradigm: from bit accuracy to semantic fidelity. ArXiv, 2021: abs/2101.12649.
- [207] Han D, Chen W, Fang Y. Joint channel and queue aware scheduling for latency sensitive mobile edge computing with power constraints. accepted by IEEE Transactions on Wireless Communications, 2020.
- [208] Huangfu, Yourui, et al. "Predicting the mumble of wireless channel with sequence-to-sequence models." 2019 IEEE 30th Annual International Symposium on Personal, Indoor and Mobile Radio Communications (PIMRC). IEEE, 2019.
- [209] Huangfu, Yourui, et al. "Realistic Channel Models Pre-training." 2019 IEEE Globecom Workshops (GC Wkshps). IEEE, 2019.
- [210] Study on channel model for frequencies from 0.5 to 100 GHz, 3GPP TR 38.901 version 17.0.0 Std., April 2022.
- [211] Alkhateeb, A. DeepMIMO: A generic deep learning dataset for millimeter wave and massive MIMO applications. arXiv preprint arXiv:1902.06435, 2019.
- [212] Klautau, A., Batista, P., González-Prelcic, N., Wang, Y., & Heath, R. W. 5G MIMO data for machine learning: Application to beam-selection using deep learning. In IEEE 2018 Information Theory and Applications Workshop (ITA), pp. 1-9, 2018.
- [213] O'Shea, T. J., Roy, T., & Clancy, T. C. Over-the-air deep learning based radio signal classification. IEEE Journal of Selected Topics in Signal Processing, 12(1), 168-179, 2018.
- [214] Han D, Chen W, Fang Y. A dynamic pricing strategy for vehicle assisted mobile edge computing systems. IEEE Wireless Communications Letters, 2018, 8(2):420-423.
- [215] Han D, Bai B, Chen W. Secure V2V communications via relays: Resource allocation and performance analysis. IEEE Wireless Communications Letters, 2017, 6(3):342-345.
- [216] 索士强,王映民. 未来 6G 网络内生智能的探讨与分析[J]. 移动通信, 2020,44(6): 126-130.

- [217] 《新一代人工智能发展规划》，国务院
- [218] 《新一代人工智能治理原则——发展负责任的人工智能》，国家新一代人工智能治理专业委员会
- [219] 《国家新一代人工智能标准体系建设指南》，国家标准化管理委员会、中央网信办、国家发展改革委、科技部、工业和信息化部
- [220] White Paper on Artificial Intelligence: a European approach to excellence and trust, EU commission.
- [221] F. Liu, W. Tong, Z. Sun, et al., “Task-Oriented Semantic Communication Systems Based on Extended Rate-Distortion Theory,” arXiv preprint arXiv:2201.10929, 2022.
- [222] D. B. Kurka and D. Gundüz, “Deepjscf: Deep joint source-channel coding of images with feedback,” IEEE Journal on Selected Areas in Information Theory, vol. 1, no. 1, pp. 178–193, 2020.
- [223] M. Yang, C. Bian, and H.-S. Kim, “Deep joint source channel coding for wireless image transmission with ofdm,” in ICC 2021-IEEE International Conference on Communications, pp. 1–6, IEEE, 2021.
- [224] Zhang Z, Yang Q, He S, et al. Wireless transmission of images with the assistance of multi-level semantic information[J]. arXiv preprint arXiv:2202.04754, 2022.
- [225] C.-H. Lee, J.-W. Lin, P.-H. Chen, and Y.-C. Chang, “Deep learning constructed joint transmission-recognition for internet of things,” IEEE Access, vol. 7, pp. 76547–76561, 2019.
- [226] M. Jankowski, D. Gundüz, and K. Mikołajczyk, “Joint device-edge inference over wireless links with pruning,” in 2020 IEEE 21st International Workshop on Signal Processing Advances in Wireless Communications (SPAWC), pp. 1–5, IEEE, 2020.
- [227] H. Xie, Z. Qin, X. Tao, and K. B. Letaief, “Task-oriented multi-user semantic communications,” arXiv preprint arXiv:2112.10255, Dec. 2021.
- [228] Han, Q Yang, Z Shi, S He, Z Zhang. Semantic-aware Speech to Text Transmission with Redundancy Removal. in Proc. IEEE Int. Conf. Commun. (ICC), May 2022
- [229] B. Hu, J. Wang, C. Xu, G. Zhang and R. Li, “A Kalman-Based Autoencoder Framework for End-To-End Communication Systems,” PIMRC wks. 2021.
- [230] J. Wang, C. Xu, R. Li, Y. Ge, & J. Wang. "Smart scheduling based on deep reinforcement learning for cellular networks." 2021 IEEE 32nd Annual International Symposium on Personal, Indoor and Mobile Radio Communications (PIMRC). IEEE, 2021.

贡献单位

本报告得到 IMT-2030（6G）推进组各位领导、专家的大力支持和指导、IMT-2030（6G）无线 AI 任务组各成员单位的大力支持以及多位学术界、产业界同仁的关心和支持。主要贡献单位如下表所示。

表7-2 主要贡献单位

序号	主要贡献单位
1	浙江大学
2	华为技术有限公司
3	中国信息通信研究院
4	中国移动通信集团有限公司研究院
5	东南大学
6	清华大学
7	OPPO广东移动通信有限公司
8	中国科学技术大学
9	北京交通大学
10	中兴通讯股份有限公司
11	西安电子科技大学
12	中山大学
13	广东省新一代通信与网络创新研究院
14	中信科移动通信技术股份有限公司
15	维沃移动通信有限公司
16	中国电信研究院
17	上海诺基亚贝尔
18	南京邮电大学
19	电子科技大学

附录：缩略词表

缩略词	英文全称	中文全称
AI	artificial intelligence	人工智能
ML	machine learning	机器学习
DNN	deep neural network	深度神经网络
eMBB	enhanced mobile broadband	增强移动通信
uRLLC	ultra-reliable low latency communications	超高可靠低时延
mMTC	massive machine type communications	海量机器类型通信
AR	auto-regressive	自回归
MA	moving average	移动平均
CNN	convolutional neural network	卷积神经网络
LSTM	long short term with memory	长短期记忆
CSI	channel state information	信道状态信息
FDD	frequency division duplexity	频分双工制式
UE	user equipment	用户端
SRN	super resolution network	超分辨率网络
PMI	precoding matrix index	预编码矩阵索引
CQI	channel quality indicator	信道质量指数
OFDM	orthogonal frequency-division multiplexing	正交频分复用
LS	least square	最小平方差
MMSE	minimum mean square error	最小均方误差
DL	deep learning	深度学习
RF	radio frequency	射频
LDAMP	learned denosing-based approximate message passing network	去噪近似信息传递网络
DnCNN	denoising neural network	去噪卷积神经网络
NMSE	normalized mean square error	标准化均方差
DOA	direction of arrivals	到达角
SNR	signal-to-noise ratio	信噪比
GMM-EM	Gaussian mixture model-expectation maximization algorithm	期望最大算法

AE	autoencoder	自动编码器
BS	base station	基站
SVD	singular value decomposition	奇异值分解
AWGN	additive white Gaussian noise	加性高斯白噪声
QAM	quadrature amplitude modulation	正交幅度调制
LDPC	low density parity check	低密度奇偶校验
BP	belief propagation	改进置信传播
MAP	maximum a posteriori	最大后验概率算法
GA	genetic algorithm	遗传算法
RL	reinforcement learning	强化学习
DE	density evolution	密度进化
GA	Gaussian approximation	高斯近似
BER	bit error rate	位误码率
SC	successive cancellation	串行抵消
LLRs	log likelihood ratios	对数似然比
BLER	block error rate	块错误率
PAPR	peak to average ratio	低峰均功率比
MLPs	multi-layer perceptrons	多层感知器
CDMA	code-division multiple access	码分多址制式
AMP	approximate message passing	近似消息传递算法
ZF	zero forcing	迫零算法
AMP	approximate message passing	近似消息传递算法
SDR	semidefinite relaxation	半定松弛算法
HAD	heuristic automatic damping	启发式自动舍弃
SER	symbol error rate	误符号率
UCB	upper confidence bound	置信区间上界
CS	compressed sensing	压缩感知
NOMA	non-orthogonal multiple access	非正交接入
AUD	active user detection	活跃用户检测
CE	channel estimation	信道估计
DRL	deep reinforcement learning	深度强化学习
MBS	macro base station	宏基站

SBS	small-cell base station	微型基站
UAV	unmanned aerial vehicle	无人机
AP	access point	接入点
QoS	quality of service	用户质量
MAC	media access control	媒体访问控制
MDP	Markov dynamic programing	马尔可夫决策过程
NE	nash equilibrium	纳什均衡
ESNs	echo state networks	回声状态网络
eNB	evolved node B	演进基站
DQL	deep Q-learning	深度 Q-learning
HMM	hidden Markov model	隐马尔可夫模型
V2I	vehicle to infrastructure	车辆到基础设施
MARL	multi-agent RL	多智能体 RL
DQN	deep Q-learning network	深度 Q-learning 网络
D2D	device-to-device	物与物
TCP	transmission control protocol	传输控制协议
ECN	explicit congestion notification	显式拥塞通告
RTT	round-trip time	往返时延
QoE	quality of experience	体验质量
OGD	online gradient descent	在线梯度下降
ARIMA	autoregressive integrated moving average model	差分整合移动平均自回归模型
GBDT	gradient boosting decision tree	梯度提升决策树
FL	federated learning	联邦学习



微信公众号

联系方式

邮箱: imt2030@caict.ac.cn

COPYRIGHT@2022 IMT-2030(6G)PROMOTION GROUP.

ALL RIGHTS RESERVED.